

Data Analytics - Esempio esame

1 ora e 30 minuti

Alessio Matessi - SM321657

30 - 06 - 2026

Riportare di seguito i comandi e le risposte necessarie allo svolgimento dell'esame. I file pdf e Rmd entrambi vanno consegnati tramite moodle.

1. Accertarsi che il file compili correttamente prima di iniziare l'esame
2. Compilare spesso
3. Se non si riesce a risolvere l'errore di compilazione, utilizzare l'opzione `eval = F` nelle opzioni del chunk, ad esempio:

PARTE 1: R

Punto 1. Scrivere una funzione che prenda in input due scalari numerici interi diciamo $n > 1$ e $p > 0$. La funzione, dopo avere controllato che i due argomenti rispettino le condizioni date, creerà una matrice che abbia n righe e p colonne popolata da numeri generati casualmente da una variabile gaussiana di media 0 e varianza 1. La funzione restituirà una lista contenente la matrice suddetta, il vettore delle medie delle colonne, il vettore delle varianze delle colonne e la matrice di correlazione delle colonne. Chiamare la funzione `funzione`.

Svolgimento

```
funzione <- function(n, p)
{
  # Controllo input
  if (
    !is.numeric(n) ||
    !is.numeric(p) ||
    n <= 1 ||
    p <= 0 ||
    n != round(n) ||
    p != round(p))
  {
    stop ("n deve essere un intero > 1, p un intero > 0")
  }

  # Creo la matrice
  mat <- matrix(rnorm(n * p), nrow = n, ncol = p)

  # Calcolo medie, varianze, correlazione
```

```

col_means <- apply(mat, 2, mean)
col_vars <- apply(mat, 2, var)
col_cor <- cor(mat)

# Restituisco la lista
return(list(
  matrice = mat,
  medie = col_means,
  varianze = col_vars,
  correlazione = col_cor
))
}

# Test
funzione(5, 3)

```

```

## $matrice
##           [,1]      [,2]      [,3]
## [1,] -2.2347695  1.2954162  0.81327640
## [2,]  0.3819809  1.4317501  1.41204740
## [3,]  1.4130946  0.4784662 -0.85379352
## [4,]  0.3766126  0.6028837  0.05367217
## [5,] -0.4309058  0.2953529  1.26384569
##
## $medie
## [1] -0.09879744  0.82077381  0.53780963
##
## $varianze
## [1] 1.8539132 0.2598238 0.8845626
##
## $correlazione
##           [,1]      [,2]      [,3]
## [1,]  1.0000000 -0.4202576 -0.5355582
## [2,] -0.4202576  1.0000000  0.4512130
## [3,] -0.5355582  0.4512130  1.0000000

```

Risposta:

La funzione `funzione(n, p)`:

- Controlla che $n > 1$ e $p > 0$ e che siano interi
- Genera una matrice $n \times p$ con valori da $N(0,1)$
- Restituisce una lista con: **matrice**, **medie** delle colonne, **varianze** delle colonne, **matrice di correlazione**

Punto 2. Fornire un'istruzione R che su un data frame che contiene un fattore y con $k \geq 4$ modalità, selezioni solo le unità corrispondenti al secondo e quarto livello del fattore. Testare la funzione sul data frame contenuto nel file `testR2.RData`.

Svolgimento

```
# Soluzione teorica
# df[df$y %in% levels(df$y)[c(2, 4)], ]

# Test su un dataset fittizio (per dimostrare che la logica funziona)
set.seed(123)
df_test <- data.frame(
  id = 1:10,
  y = factor(rep(c("A", "B", "C", "D", "E"), each = 2)),
  valore = rnorm(10)
)

levels(df_test$y)
```

```
## [1] "A" "B" "C" "D" "E"
```

```
df_test[df_test$y %in% levels(df_test$y)[c(2, 4)], ]
```

```
##   id y      valore
## 3  3 B  1.55870831
## 4  4 B  0.07050839
## 7  7 D  0.46091621
## 8  8 D -1.26506123
```

Risposta:

L'istruzione `df[df$y %in% levels(df$y)[c(2, 4)], ]` seleziona le righe corrispondenti al **secondo** e **quarto** livello del fattore `y`.

Nel dataset fittizio con livelli A, B, C, D, E, la selezione mantiene solo le righe con `y = B` (secondo livello) e `y = D` (quarto livello).

Parte 2: Analisi dei dati

Si considerino i dati contenuti nel file `fev.csv`. Si tratta di informazioni raccolte su 654 bambini e adolescenti. La variabile chiave è `FEV`, la capacità polmonare (in litri). Inoltre si dispone dell'età (`AGE`), della statura (`HEIGHT`, in pollici) e di due variabili dicotomiche, genere (`SEX`) e fumo (`SMOKE`).

Punto 1: Quanto vale la devianza della variabile `HEIGHT`?

Svolgimento

```
# Carico il dataset
fev <- read.csv("fev.csv", sep = ";")

# Calcolo la devianza di HEIGHT
dev_height <- sum((fev$height - mean(fev$height))^2)
dev_height
```

```
## [1] 16232.41
```

Risposta:

La devianza di HEIGHT è **16232.41**

Punto 2: Si trasformino le variabili quantitative mediante standardizzazione e si calcoli la matrice di covarianza fra tali nuove variabili. Quale delle tre ha la covarianza più elevata?

Svolgimento

```
# Standardizzo le variabili qualitative
fev_scaled <- scale(fev[, c("age", "fev", "height")])

# Matrice di covarianza
cov_matrix <- cov(fev_scaled)
cov_matrix
```

```
##           age      fev    height
## age      1.000000 0.7283901 0.7579478
## fev      0.7283901 1.0000000 0.8534572
## height  0.7579478 0.8534572 1.0000000
```

Risposta:

- Le variabili standardizzate hanno **media 0** e **varianza 1** (diagonale della matrice = 1)
 - La covarianza più elevata (in valore assoluto) è tra **height** e **fev**, pari a **0.853**
-

Punto 3: Si calcoli la statistica X^2 per valutare l'associazione fra le variabili SMOKE e SEX. Quanto vale?

Svolgimento

```
# Tabella di contingenza SMOKE vs SEX
tab <- table(fev$smoking, fev$gender)
tab
```

```
##
##      f    m
## 0 255 290
## 1  37  24
```

```
# Test chi-quadrato
chisq.test(tab)
```

```
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tab
## X-squared = 3.6879, df = 1, p-value = 0.05481
```

Risposta:

La statistica χ^2 vale **3.6879** (p-value = 0.0548). Il p-value è leggermente superiore a 0.05, quindi non possiamo rifiutare l'ipotesi di indipendenza tra **SMOKE** e **SEX** al livello di significatività del 5%.

Punto 4: Si vuole usare come misura di asimmetria l'indice K definito come

$$K = \frac{x_{0.9} + x_{0.1} - 2x_{0.5}}{x_{0.9} - x_{0.1}}$$

per la variabile FEV. Quanto vale?

Svolgimento

```
# Funzione per l'indice di asimmetria K
K <- function(x)
{
  q <- quantile(x, probs = c(0.1, 0.5, 0.9))
  (q[3] + q[1] - 2*q[2]) / (q[3] - q[1])
}

# Applico a FEV
K(fev$fev)
```

```
##          90%
## 0.1708578
```

Risposta:

L'indice di asimmetria K per la variabile **FEV** vale **0.171** (approssimato). Poiché $K > 0$, la distribuzione è **leggermente asimmetrica a destra**.

Punto 5: A partire dalle variabili **SMOKE** e **SEX** si consideri la variabile che è il prodotto logico delle due (ovvero una variabile che ha 4 modalità: “M e Fumatore”, “F e Fumatore”, “M e Non Fumatore”, “F e Non Fumatore”). Per quale gruppo identificato da questa nuova variabile risulta la mediana di **FEV** più piccola?

Svolgimento

```
# Creo la variabile combinata SMOKE e SEX
fev$gruppo <- interaction(fev$gender, fev$smoking)
levels(fev$gruppo) <- c("F_NO", "M_NO", "F_Smoke", "M_smoke")

# Mediana di FEV per gruppo
tapply(fev$fev, fev$gruppo, median)
```

```
##      F_NO      M_NO F_Smoke M_smoke
##      2.463      2.598      3.069      3.775
```

Risposta:

Il gruppo con la mediana di FEV più piccola è **F_No** (femmine non fumatrici), con mediana **2.463**.

Punto 6: Si determinino i parametri della funzione di regressione multipla che ha come variabile risposta FEV e come variabili esplicative AGE e SMOKE.

Svolgimento

```
# Modello di regressione multipla
mod <- lm(fev ~ age + smoking, data = fev)
summary(mod)

##
## Call:
## lm(formula = fev ~ age + smoking, data = fev)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.48912 -0.35667 -0.04028  0.34263  2.04484
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.204008   0.099401   2.052  0.04057 *
## age          0.247930   0.009833  25.213 < 2e-16 ***
## smoking     -0.235833   0.083327  -2.830  0.00481 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5655 on 603 degrees of freedom
## Multiple R-squared:  0.5367, Adjusted R-squared:  0.5352
## F-statistic: 349.3 on 2 and 603 DF, p-value: < 2.2e-16
```

Risposta:

Il modello di regressione multipla stimato è:

$$\text{FEV} = 0.204 + 0.248 * \text{AGE} - 0.236 * \text{SMOKE}$$

- Per ogni anno in più di età, la capacità polmonare aumenta in media di **0.248 litri** (p-value < 0.001).
- A parità di età, i fumatori hanno in media una capacità polmonare inferiore di **0.236 litri** rispetto ai non fumatori (p-value = 0.0048).
- $R^2 = 0.5367$, quindi il modello spiega circa il **53.7%** della variabilità di FEV.
- Il modello è complessivamente significativo (p-value < 0.001).

Parte 3: Rispondi alle seguenti domande:

- **6.1** La devianza spiegata dalla regressione vale circa:

```
# Devianza spiegata dalla regressione
dev_spiegata <- sum((fitted(mod) - mean(fev$fev))^2)
dev_spiegata
```

```
## [1] 223.424
```

Risposta:

La devianza spiegata dalla regressione è **223.424**

-
- **6.2** Quale tra le seguenti affermazioni è accettabile:
 - a. ☐ a parità di età la capacità polmonare dei fumatori è inferiore in media a quella dei non fumatori di circa 0.21 litri
 - b. ☐ la capacità polmonare dei fumatori è inferiore in media a quella dei non fumatori di circa 0.21 litri
 - c. ☐ a parità di età la capacità polmonare dei fumatori è superiore in media a quella dei non fumatori di circa 0.21 litri
 - d. ☐ la capacità polmonare dei fumatori è superiore in media a quella dei non fumatori di circa 0.21 litri

Risposta:

a. *a parità di età la capacità polmonare dei fumatori è inferiore in media a quella dei non fumatori di circa 0.21 litri*

-
- **6.3** Quale delle seguenti affermazioni non è supportata dalle analisi. La variabile AGE:
 - a. ☐ è molto rilevante per spiegare la capacità polmonare
 - b. ☐ all'aumentare dell'età la capacità polmonare aumenta in media del 23%
 - c. ☐ all'aumentare dell'età di 1 anno la capacità polmonare aumenta in media di 0.23 litri
 - d. ☐ per un soggetto di 10 anni e fumatore, la capacità polmonare prevista è di circa 2.46 litri

Risposta:

- b. *“all’aumentare dell’età la capacità polmonare aumenta in media del 23%”* → **non supportata**.

Il coefficiente di **age** è 0.248 **litri**, non una percentuale. L’affermazione corretta sarebbe: *“all’aumentare dell’età di 1 anno, la capacità polmonare aumenta in media di 0.248 litri”*.

- **6.4** Qual è la percentuale di devianza dei residui della funzione di regressione?

```
# Devianza residua
dev_res <- sum(residuals(mod)^2)

# Devianza totale
dev_tot <- sum((fev$fev - mean(fev$fev))^2)

# Percentuale devianza residui
dev_res / dev_tot * 100
```

```
## [1] 46.32937
```

Risposta:

La percentuale di devianza dei residui è circa **46.33%**.