

Data Analytics - Esempio esame

1 ora e 30 minuti

Alessio Matessi - SM321657

30 - 06 - 2026

Riportare di seguito i comandi e le risposte necessarie allo svolgimento dell'esame. I file pdf e Rmd entrambi vanno consegnati tramite moodle.

1. Accertarsi che il file compili correttamente prima di iniziare l'esame
2. Compilare spesso
3. Se non si riesce a risolvere l'errore di compilazione, utilizzare l'opzione `eval = F` nelle opzioni del chunk, ad esempio:

PARTE 1: R

1. Scrivere una funzione che prenda in input due scalari numerici interi diciamo $n > 1$ e $p > 0$. La funzione, dopo avere controllato che i due argomenti rispettino le condizioni date, creerà una matrice che abbia n righe e p colonne popolata da numeri generati casualmente da una variabile gaussiana di media 0 e varianza 1. La funzione restituirà una lista contenente la matrice suddetta, il vettore delle medie delle colonne, il vettore delle varianze delle colonne e la matrice di correlazione delle colonne. Chiamare la funzione `funzione`.

Svolgimento

```
funzione <- function(n, p)
{
  # Controllo input
  if (
    !is.numeric(n) ||
    !is.numeric(p) ||
    n <= 1 ||
    p <= 0 ||
    n != round(n) ||
    p != round(p))
  {
    stop ("n deve essere un intero > 1, p un intero > 0")
  }

  # Creo la matrice
  mat <- matrix(rnorm(n * p), nrow = n, ncol = p)

  # Calcolo medie, varianze, correlazione
```

```

col_means <- apply(mat, 2, mean)
col_vars <- apply(mat, 2, var)
col_cor <- cor(mat)

# Restituisco la lista
return(list(
  matrice = mat,
  medie = col_means,
  varianze = col_vars,
  correlazione = col_cor
))
}

# Test
funzione(5, 3)

```

```

## $matrice
##           [,1]      [,2]      [,3]
## [1,] -0.3095272 -0.7933544 -1.2842600
## [2,] -1.3926606 -1.2146522  1.1325620
## [3,]  0.8810206  0.8851978  0.1178290
## [4,] -0.4706999  2.3401637  0.5796478
## [5,]  0.5956510 -2.2643170  0.8703114
##
## $medie
## [1] -0.1392432 -0.2093924  0.2832180
##
## $varianze
## [1] 0.8227308 3.3181595 0.9095688
##
## $correlazione
##           [,1]      [,2]      [,3]
## [1,]  1.0000000  0.0183084 -0.18299545
## [2,]  0.0183084  1.0000000 -0.08204921
## [3,] -0.1829954 -0.08204921  1.00000000

```

Risposta:

La funzione `funzione(n, p)`:

- Controlla che $n > 1$ e $p > 0$ e che siano interi
- Genera una matrice $n \times p$ con valori da $N(0,1)$
- Restituisce una lista con: **matrice**, **medie** delle colonne, **varianze** delle colonne, **matrice di correlazione**

-
2. Fornire un'istruzione R che su un data frame che contiene un fattore y con $k \geq 4$ modalità, selezioni solo le unità corrispondenti al secondo e quarto livello del fattore. Testare la funzione sul data frame contenuto nel file `testR2.RData`.

Svolgimento

```
# Soluzione teorica
# df[df$y %in% levels(df$y)[c(2, 4)], ]

# Test su un dataset fittizio (per dimostrare che la logica funziona)
set.seed(123)
df_test <- data.frame(
  id = 1:10,
  y = factor(rep(c("A", "B", "C", "D", "E"), each = 2)),
  valore = rnorm(10)
)

levels(df_test$y)
```

```
## [1] "A" "B" "C" "D" "E"
```

```
df_test[df_test$y %in% levels(df_test$y)[c(2, 4)], ]
```

```
##   id y      valore
## 3  3 B  1.55870831
## 4  4 B  0.07050839
## 7  7 D  0.46091621
## 8  8 D -1.26506123
```

Risposta:

L'istruzione `df[df$y %in% levels(df$y)[c(2, 4)], ]` seleziona le righe corrispondenti al **secondo** e **quarto** livello del fattore `y`.

Nel dataset fittizio con livelli A, B, C, D, E, la selezione mantiene solo le righe con `y = B` (secondo livello) e `y = D` (quarto livello).

Analisi dei dati

Si considerino i dati contenuti nel file `fev.csv`. Si tratta di informazioni raccolte su 654 bambini e adolescenti. La variabile chiave è `FEV`, la capacità polmonare (in litri). Inoltre si dispone dell'età (`AGE`), della statura (`HEIGHT`, in pollici) e di due variabili dicotomiche, genere (`SEX`) e fumo (`SMOKE`).

1. Quanto vale la devianza della variabile `HEIGHT`?
2. Si trasformino le variabili quantitative mediante standardizzazione e si calcoli la matrice di covarianza fra tali nuove variabili. Quale delle tre ha la covarianza più elevata?
3. Si calcoli la statistica X^2 per valutare l'associazione fra le variabili `SMOKE` e `SEX`. Quanto vale?
4. Si vuole usare come misura di asimmetria l'indice K definito come

$$K = \frac{x_{0.9} + x_{0.1} - 2x_{0.5}}{x_{0.9} - x_{0.1}}$$

per la variabile FEV. Quanto vale?

5. A partire dalle variabili **SMOKE** e **SEX** si consideri la variabile che è il prodotto logico delle due (ovvero una variabile che ha 4 modalità: “M e Fumatore”, “F e Fumatore”, “M e Non Fumatore”, “F e Non Fumatore”). Per quale gruppo identificato da questa nuova variabile risulta la mediana di **FEV** più piccola?

6. Si determinino i parametri della funzione di regressione multipla che ha come variabile risposta **FEV** e come variabili esplicative **AGE** e **SMOKE**.

6.1 La devianza spiegata dalla regressione vale circa:

6.2 Quale tra le seguenti affermazioni è accettabile:

- a. ☐ a parità di età la capacità polmonare dei fumatori è inferiore in media a quella dei non fumatori di circa 0.21 litri
- b. ☐ la capacità polmonare dei fumatori è inferiore in media a quella dei non fumatori di circa 0.21 litri
- c. ☐ a parità di età la capacità polmonare dei fumatori è superiore in media a quella dei non fumatori di circa 0.21 litri
- d. ☐ la capacità polmonare dei fumatori è superiore in media a quella dei non fumatori di circa 0.21 litri

6.3 Quale delle seguenti affermazioni non è supportata dalle analisi. La variabile **AGE**:

- a. ☐ è molto rilevante per spiegare la capacità polmonare
- b. ☐ all'aumentare dell'età la capacità polmonare aumenta in media del 23%
- c. ☐ all'aumentare dell'età di 1 anno la capacità polmonare aumenta in media di 0.23 litri
- d. ☐ per un soggetto di 10 anni e fumatore, la capacità polmonare prevista è di circa 2.46 litri

6.4 Qual è la percentuale di devianza dei residui della funzione di regressione?