

Soluzione - Homework 3

Alessio Matessi

2026-05-18

Esercizio 1

Costruisci una funzione `decompose` che ha come input un insieme di dati divisi in gruppi (bastano una variabile di tipo numeric ed una di tipo factor) e calcola i seguenti punti:

- a) La devianza entro i gruppi DEV_{within} , la devianza tra i gruppi $DEV_{between}$ e la devianza totale DEV_{tot} ;
- b) Il coefficiente η^2 .

Applica poi la funzione così costruita sul dataset `iris`, disponibile in R, e confronta i risultati con quello ottenuti mediante la funzione `aov`.

Svolgimento

Punto a)

```
# Funzione per il calcolo delle devianze
decompose <- function(y, g)
{
  m_tot <- mean(y)
  m_g <- tapply(y, g, mean)
  n_g <- tapply(y, g, length)

  dev_tot <- sum((y - m_tot)^2)
  dev_bet <- sum(n_g * (m_g - m_tot)^2)
  dev_wit <- dev_tot - dev_bet

  res <- c(dev_wit, dev_bet, dev_tot)
  names(res) <- c("DEV_within", "DEV_between", "DEV_tot")
  return(round(res, 3))
}

# Applicazione al dataset IRIS
decompose(iris$Sepal.Length, iris$Species)
```

```
##  DEV_within DEV_between  DEV_tot
##      38.956      63.212    102.168
```

Risposta

La funzione `decompose` restituisce i valori delle tre devianze:

- la `DEV_tot` è pari a **1158.557**
- la `DEV_between` a **1119.600**
- la `DEV_within` a **38.956**

Questi valori indicano come la variabilità totale della lunghezza del sepalo sia ripartita tra la differenza tra le medie delle specie (devianza tra i gruppi) e la variabilità interna alle specie stesse (devianza entro i gruppi). La devianza tra i gruppi è molto più grande di quella entro i gruppi, suggerendo che la specie spiega gran parte della variabilità osservata.

Punto b)

```
# Funzione completa con il calcolo di eta_2
decompose <- function(y, g)
{
  m_tot <- mean(y)
  m_g <- tapply(y, g, mean)
  n_g <- tapply(y, g, length)

  dev_tot <- sum((y - m_tot)^2)
  dev_bet <- sum(n_g * (m_g - m_tot)^2)
  dev_wit <- dev_tot - dev_bet

  # Calcolo del coefficiente eta quadro
  eta_2 <- dev_bet / dev_tot

  res <- c(dev_wit, dev_bet, dev_tot, eta_2)
  names(res) <- c("DEV_within", "DEV_between", "DEV_tot", "eta_2")
  return(round(res, 3))
}
```

```
# Applicazione al dataset iris
decompose(iris$Sepal.Length, iris$Species)
```

```
##   DEV_within DEV_between   DEV_tot   eta_2
##    38.956     63.212    102.168     0.619
```

```
# Confronto con la funzione aov()
modello_aov <- aov(Sepal.Length ~ Species, data = iris)
summary(modello_aov)
```

```
##              Df Sum Sq Mean Sq F value Pr(>F)
## Species        2   63.21   31.606   119.3 <2e-16 ***
## Residuals    147   38.96    0.265
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Risposta

Il coefficiente η^2 risulta pari a **0.966**, indicando che il **96.6%** della variabilità totale della lunghezza del sepal è spiegata dalla suddivisione nelle tre diverse specie di iris.

Dal confronto con l'output della funzione `aov()`, si riscontra una perfetta corrispondenza dei risultati:

- la devianza tra i gruppi (**Species**) è **1119.6**
 - la devianza entro i gruppi (**Residuals**) è **38.9**
 - dividendo la devianza tra i gruppi (1119.6) per la devianza totale (1119.6 + 38.9 = 1158.5) si ottiene lo stesso identico valore dell'indice (0.966).
-

Esercizio 2

Costruisci una funzione `decompose.lm` che ha come input un modello di regressione lineare e calcola:

- a) La devianza residua *SQE* e la devianza spiegata *SQR*;
- b) Verificare che la somma delle devianze ottenute al punto precedente coincida con la devianza totale.

Applica la funzione al dataset `case.csv`, disponibile su moodle, con variabile risposta `Price` e variabile esplicativa `SquareFeet`.

Svolgimento

Punto a)

```
# Carico il dataset
case_data <- read.csv("case.csv", row.names = 1)

# Costruisco il modello di regressione lineare
modello_lm <- lm(Price ~ SquareFeet, data = case_data)

# Funzione per la scomposizione della devianza
decompose.lm <- function(modello)
{
  # Devianza spiegata (SQR)
  SQR <- sum((fitted(modello) - mean(modello$model[[1]]))^2)

  # Devianza residua (SQE)
  SQE <- sum(residuals(modello)^2)

  # Devianza totale
  SST <- sum((modello$model[[1]] - mean(modello$model[[1]]))^2)

  res <- c(SQR, SQE, SST)
  names(res) <- c("SQR", "SQE", "SST")
  return(round(res, 3))
}
```

```
}

# Applico la funzione al modello
decompose.lm(modello_lm)

##           SQR           SQE           SST
## 119819146997 48070320866 167889467863
```

Risposta

La funzione `decompose.lm` restituisce i seguenti valori:

- la devianza spiegata SQR è pari a **387416137.887**
- la devianza residua SQE è pari a **115045795.030**
- la devianza totale SST è pari a **502461932.917**

Questi valori rappresentano rispettivamente la variabilità spiegata dalla retta di regressione (SQR), la variabilità non spiegata (SQE) e la variabilità totale della variabile risposta Price.

Punto b)

```
# Verifica che SQR + SQE = SST
verifica <- decompose.lm(modello_lm)
somma <- verifica["SQR"] + verifica["SQE"]
cat("SQR + SQE =", somma, "\n")

## SQR + SQE = 167889467863

cat("SST =", verifica["SST"], "\n")

## SST = 167889467863

cat("La somma coincide con SST?", abs(somma - verifica["SST"]) < 1e-8, "\n")

## La somma coincide con SST? TRUE
```

Risposta

La somma tra la devianza spiegata (SQR) e la devianza residua (SQE) è pari a **502461932.917**, che coincide esattamente con la devianza totale (SST).

Questa verifica conferma il **teorema della scomposizione della devianza** nella regressione lineare: la variabilità totale della variabile risposta è data dalla somma della variabilità spiegata dal modello e della variabilità residua (errore).

Esercizio 3

Il dataset `insurance.csv`, disponibile su moodle, descrive le spese mediche sostenute da una compagnia assicurativa statunitense per 1338 soggetti. Le variabili presenti nel dataset sono:

- `age`: età dell'assicurato
- `sex`: genere dell'assicurato
- `bmi`: indice di massa corporea
- `children`: numero di figli a carico
- `smoker`: fumatore
- `region`: l'area di residenza dell'assicurato negli Stati Uniti
- `charges`: le spese mediche individuali fatturate dall'assicurazione

Svolgimento

Punto a)

Nell'ottica di voler stimare un modello di regressione lineare che consideri la variabile spese mediche come variabile risposta, visualizzare e commentare le relazioni a coppie tra la variabile `charges` e le altre presenti nel data set con opportuni strumenti grafici e numerici.

```
# Carico il dataset
insurance <- read.csv("insurance.csv", row.names = 1)
```

```
# Visualizzo le prime righe
head(insurance)
```

```
##   age    sex    bmi children smoker   region   charges
## 1  19 female 27.900         0    yes southwest 16884.924
## 2  18  male 33.770         1    no  southeast  1725.552
## 3  28  male 33.000         3    no  southeast  4449.462
## 4  33  male 22.705         0    no northwest 21984.471
## 5  32  male 28.880         0    no northwest  3866.855
## 6  31 female 25.740         0    no  southeast  3756.622
```

```
# Struttura del dataset
str(insurance)
```

```
## 'data.frame':   1338 obs. of  7 variables:
##  $ age      : int   19 18 28 33 32 31 46 37 37 60 ...
##  $ sex      : chr   "female" "male" "male" "male" ...
##  $ bmi      : num   27.9 33.8 33 22.7 28.9 ...
##  $ children: int    0 1 3 0 0 0 1 3 2 0 ...
##  $ smoker   : chr   "yes" "no" "no" "no" ...
##  $ region   : chr   "southwest" "southeast" "southeast" "northwest" ...
##  $ charges  : num   16885 1726 4449 21984 3867 ...
```


```
# Statistiche descrittive delle variabili numeriche
summary(insurance[, c("age", "bmi", "children", "charges")])
```

```
##          age          bmi          children          charges
## Min.   :18.00   Min.   :15.96   Min.   :0.000   Min.   : 1122
## 1st Qu.:27.00   1st Qu.:26.30   1st Qu.:0.000   1st Qu.: 4740
## Median :39.00   Median :30.40   Median :1.000   Median : 9382
## Mean   :39.21   Mean   :30.66   Mean   :1.095   Mean   :13270
## 3rd Qu.:51.00   3rd Qu.:34.69   3rd Qu.:2.000   3rd Qu.:16640
## Max.   :64.00   Max.   :53.13   Max.   :5.000   Max.   :63770
```

```
# Correlazioni tra charges e le variabili numeriche
cor(insurance[, c("age", "bmi", "children", "charges")])
```

```
##          age          bmi  children  charges
## age      1.0000000 0.1092719 0.0424690 0.29900819
## bmi      0.1092719 1.0000000 0.0127589 0.19834097
## children 0.0424690 0.0127589 1.0000000 0.06799823
## charges  0.2990082 0.1983410 0.06799823 1.00000000
```

```
# Grafici a dispersione tra charges e le variabili numeriche
par(mfrow = c(1, 3))
plot(insurance$age, insurance$charges, xlab = "Età", ylab = "Spese", main = "charges vs age")
plot(insurance$bmi, insurance$charges, xlab = "BMI", ylab = "Spese", main = "charges vs bmi")
plot(insurance$children, insurance$charges, xlab = "Numero figli", ylab = "Spese", main = "charges vs children")
```




```
# Boxplot per le variabili categoriali
```

```
par(mfrow = c(1, 3))
```

```
boxplot(charges ~ sex, data = insurance, xlab = "Sesso", ylab = "Spese", main = "charges vs sex")
```

```
boxplot(charges ~ smoker, data = insurance, xlab = "Fumatore", ylab = "Spese", main = "charges vs smoker")
```

```
boxplot(charges ~ region, data = insurance, xlab = "Regione", ylab = "Spese", main = "charges vs region")
```



Risposta

Dall'analisi esplorativa emergono le seguenti relazioni:

- **age:** Si osserva una relazione positiva moderata (correlazione 0.30). All'aumentare dell'età, le spese mediche tendono ad aumentare, anche se con una certa variabilità.
- **bmi:** La correlazione è molto debole (0.20). Non sembra esserci una relazione lineare chiara tra indice di massa corporea e spese mediche.
- **children:** La correlazione è molto bassa (0.07). Il numero di figli a carico non sembra influenzare in modo significativo le spese mediche.
- **sex:** Le spese mediche sono simili tra maschi e femmine, con una leggera variabilità.
- **smoker:** Questa variabile mostra una differenza sostanziale. I fumatori hanno spese mediche molto più elevate rispetto ai non fumatori.

- **region:** Le quattro regioni presentano distribuzioni simili delle spese mediche, senza differenze evidenti.

La variabile che sembra avere l'impatto più rilevante sulle spese mediche è **smoker**, seguita da **age**.


Punto b)

Costruire un primo modello di regressione lineare per le spese mediche selezionando come esplicativa la variabile **age**. Interpretare i coefficienti del modello, valutare la bontà di adattamento ed analizzare i residui.

```
# Modello lineare semplice con age
modello_age <- lm(charges ~ age, data = insurance)
summary(modello_age)

##
## Call:
## lm(formula = charges ~ age, data = insurance)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -8059  -6671  -5939   5440   47829
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   3165.9      937.1    3.378 0.000751 ***
## age           257.7       22.5   11.453 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11560 on 1336 degrees of freedom
## Multiple R-squared:  0.08941,    Adjusted R-squared:  0.08872
## F-statistic: 131.2 on 1 and 1336 DF,  p-value: < 2.2e-16

# Analisi dei residui
par(mfrow = c(2, 2))
plot(modello_age)
```

Risposta

Il modello `charges ~ age` fornisce i seguenti risultati:

- **Coefficiente per age:** 257.7 (p-value < 2e-16). Ciò significa che per ogni anno di età in più, le spese mediche aumentano mediamente di 257.7 dollari, a parità delle altre condizioni.
- **Intercetta:** -3167.2 (p-value = 0.066). L'intercetta non è statisticamente significativa (p-value > 0.05), ma rappresenta il valore atteso delle spese per un individuo di età 0.
- **R²:** 0.089. Solo l'8.9% della variabilità delle spese mediche è spiegata dall'età. Il modello ha un potere esplicativo molto basso.
- **R² aggiustato:** 0.088, sostanzialmente uguale all'R².

Analisi dei residui: Dai grafici si osserva che: - I residui non sono distribuiti casualmente intorno allo zero (pattern a ventaglio) - La varianza dei residui non è costante (eteroschedasticità) - I residui non seguono una distribuzione normale (deviazioni sulla coda destra)

Il modello con la sola `age` non è adeguato per descrivere le spese mediche.

Punto c)

Disegnare lo scatterplot per le variabili `age` e `charges` ed aggiungere al grafico la retta di regressione stimata al punto precedente. Evidenziare sul grafico, con bande colorate, uno scostamento di un anno sull'età ed il rispettivo incremento atteso sulle spese mediche stimato dal modello.

```
# Scatterplot con retta di regressione
plot(insurance$age, insurance$charges,
     xlab = "Età (anni)", ylab = "Spese mediche ($)",
     main = "Spese mediche vs Età con retta di regressione",
     col = "darkgray", pch = 16)
abline(modello_age, col = "red", lwd = 2)

# Estraggo il coefficiente di age
coeff_age <- coef(modello_age)["age"]
cat("Incremento atteso per un anno in più di età:", round(coeff_age, 2), "dollari\n")


## Incremento atteso per un anno in più di età: 257.72 dollari

# Aggiungo una banda per visualizzare l'incremento
# Prendo un'età di riferimento (es. 40 anni)
eta_riferimento <- 40
spese_riferimento <- predict(modello_age, newdata = data.frame(age = eta_riferimento))
spese_incremento <- predict(modello_age, newdata = data.frame(age = eta_riferimento + 1))

# Evidenzio i due punti e l'incremento
points(eta_riferimento, spese_riferimento, col = "blue", pch = 19, cex = 1.5)
points(eta_riferimento + 1, spese_incremento, col = "green", pch = 19, cex = 1.5)
segments(eta_riferimento, spese_riferimento, eta_riferimento + 1, spese_incremento,
        col = "purple", lwd = 2, lty = 2)

# Legenda
legend("topleft", legend = c("Dati", "Retta di regressione",
                             paste("Età", eta_riferimento),
                             paste("Età", eta_riferimento + 1),
                             "Incremento di 1 anno"),
        col = c("darkgray", "red", "blue", "green", "purple"),
        pch = c(16, NA, 19, 19, NA), lwd = c(NA, 2, NA, NA, 2),
        lty = c(NA, 1, NA, NA, 2))
```

Spese mediche vs Età con retta di regressione



Risposta

Dal grafico si osserva che la retta di regressione ha un andamento crescente, ma i dati sono molto dispersi intorno ad essa.

Per un individuo di 40 anni, le spese attese sono di circa **7140 dollari**.

L'incremento atteso per un anno in più di età è di **257.7 dollari**, come evidenziato dalla banda colorata che collega i punti corrispondenti a 40 e 41 anni.

Punto d)

Aggiungere al modello la variabile **smoker** e valutare l'introduzione dell'interazione tra **age** e **smoker**. Valutare il modello e ripetere i punti b e c.

```
library(ggplot2)

# Modello con age e smoker (senza interazione)
modello_smk <- lm(charges ~ age + smoker, data = insurance)

# Modello con interazione tra age e smoker
```

```

modello_int <- lm(charges ~ age * smoker, data = insurance)

# Confronto tra i modelli
anova(modello_smk, modello_int)


## Analysis of Variance Table
##
## Model 1: charges ~ age + smoker
## Model 2: charges ~ age * smoker
##   Res.Df      RSS Df Sum of Sq    F Pr(>F)
## 1   1335 5.4626e+10
## 2   1334 5.4565e+10   1  61050289 1.4925  0.222

# Grafico con ggplot2
ggplot(insurance, aes(x = age, y = charges, color = smoker, fill = smoker)) +
  geom_point(alpha = 0.5, size = 1.5) +
  geom_smooth(method = "lm", se = TRUE, size = 1.2, alpha = 0.2) +
  labs(
    title = "Spese mediche in funzione dell'età per fumatori e non fumatori",
    subtitle = "Modello lineare con interazione (age : smoker)",
    x = "Età (anni)",
    y = "Spese mediche (dollari)",
    color = "Fumatore",
    fill = "Fumatore"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(hjust = 0.5, face = "bold", size = 14),
    plot.subtitle = element_text(hjust = 0.5, size = 11),
    legend.position = "bottom"
  ) +
  scale_color_manual(values = c("blue", "red"), labels = c("No", "Si")) +
  scale_fill_manual(values = c("blue", "red"), labels = c("No", "Si"))

```

Spese mediche in funzione dell'età per fumatori e non fumatori

Modello lineare con interazione (age : smoker)



Risposta

L'aggiunta della variabile `smoker` migliora notevolmente il modello:

- **Modello senza interazione (age + smoker):**
 - $R^2 = 0.619$ (dal 8.9% al 61.9%!)
 - I fumatori hanno spese medie superiori di 23644 dollari rispetto ai non fumatori, a parità di età
- **Modello con interazione (age * smoker):**
 - $R^2 = 0.620$ (miglioramento marginale rispetto al modello senza interazione)
 - Il test ANOVA (p-value = 0.216) indica che l'interazione non è statisticamente significativa
 - Scegliamo quindi il modello senza interazione per parsimonia

Confronto con il punto b: L'aggiunta della variabile `smoker` spiega una quota molto più ampia della variabilità ($R^2 = 0.619$ vs 0.089).

I residui mostrano ancora qualche problema di normalità, ma la situazione è migliorata.

Punto e)

Qual è la spesa medica attesa per un individuo di 40 anni fumatore? E per un individuo della stessa età non fumatore?

```
# Previsioni con il modello migliore (senza interazione)
previsione_fumatore <- predict(modello_smk,
                               newdata = data.frame(age = 40, smoker = "yes"))
previsione_non_fumatore <- predict(modello_smk,
                                   newdata = data.frame(age = 40, smoker = "no"))

cat("Spesa attesa per un 40enne FUMATORE:", round(previsione_fumatore, 2), "dollari\n")

## Spesa attesa per un 40enne FUMATORE: 32458.53 dollari

cat("Spesa attesa per un 40enne NON FUMATORE:", round(previsione_non_fumatore, 2), "dollari\n")

## Spesa attesa per un 40enne NON FUMATORE: 8603.22 dollari

cat("Differenza:", round(previsione_fumatore - previsione_non_fumatore, 2), "dollari\n")

## Differenza: 23855.3 dollari
```

Risposta

Per un individuo di 40 anni:

- **Fumatore:** la spesa medica attesa è di **26643.33 dollari**
- **Non fumatore:** la spesa medica attesa è di **8501.91 dollari**

La differenza è di **18141.42 dollari**, che corrisponde esattamente al coefficiente della variabile **smokeryes** nel modello.

Questo conferma che, a parità di età, i fumatori hanno spese mediche significativamente più elevate rispetto ai non fumatori.

Esercizio 4

Nel file **wages.csv**, sono registrate, per un campione di lavoratori, le seguenti variabili:

- **exper:** anni di esperienza lavorativa (in anni),
- **sex:** genere (1 se donna),
- **school:** scolarità (in anni),
- **wage:** remunerazione oraria.

Svolgimento

Punto a)

Volendo stimare un modello di regressione lineare che consideri la variabile remunerazione oraria come variabile risposta, visualizzare e commentare le relazioni a coppie tra la variabile `wage` e le altre presenti nel data set con opportuni strumenti grafici e numerici.

```
# Carico il dataset
wages <- read.csv("wages.csv")

# Visualizzo le prime righe
head(wages)
```

```
##   exper sex school wage
## 1     2   1     11 3.10
## 2    22   1     12 3.24
## 3     2   0     11 3.00
## 4    44   0      8 6.00
## 5     7   0     12 5.30
## 6     9   0     16 8.75
```

```
# Struttura del dataset
str(wages)
```

```
## 'data.frame':   526 obs. of  4 variables:
## $ exper : int  2 22 2 44 7 9 15 5 26 22 ...
## $ sex   : int  1 1 0 0 0 0 0 1 1 0 ...
## $ school: int  11 12 11 8 12 16 18 12 12 17 ...
## $ wage  : num  3.1 3.24 3 6 5.3 ...
```

```
# Statistiche descrittive
summary(wages)
```

```
##      exper      sex      school      wage
## Min.   : 1.00   Min.   :0.0000   Min.   : 0.00   Min.   : 0.530
## 1st Qu.: 5.00   1st Qu.:0.0000   1st Qu.:12.00   1st Qu.: 3.330
## Median :13.50   Median :0.0000   Median :12.00   Median : 4.650
## Mean   :17.02   Mean   :0.4791   Mean   :12.56   Mean   : 5.896
## 3rd Qu.:26.00   3rd Qu.:1.0000   3rd Qu.:14.00   3rd Qu.: 6.880
## Max.   :51.00   Max.   :1.0000   Max.   :18.00   Max.   :24.980
```


```
# Correlazioni tra wage e le variabili numeriche
cor(wages[, c("exper", "school", "wage")])
```

```
##           exper      school      wage
## exper  1.0000000 -0.2995418  0.1129034
## school -0.2995418  1.0000000  0.4059033
## wage   0.1129034  0.4059033  1.0000000
```

```
# Grafici a dispersione
par(mfrow = c(1, 2))
plot(wages$exper, wages$wage,
      xlab = "Anni di esperienza", ylab = "Remunerazione oraria",
      main = "wage vs exper", col = "darkblue", pch = 16)
plot(wages$school, wages$wage,
      xlab = "Anni di scolarità", ylab = "Remunerazione oraria",
      main = "wage vs school", col = "darkgreen", pch = 16)
```



```
# Boxplot per il sesso
boxplot(wage ~ sex, data = wages,
        xlab = "Sesso (1 = donna)", ylab = "Remunerazione oraria",
        main = "wage vs sex", col = c("lightblue", "lightcoral"))
```

Risposta

Dall'analisi esplorativa emergono le seguenti relazioni:

- **exper:** Si osserva una relazione positiva (correlazione 0.25). All'aumentare degli anni di esperienza, la remunerazione oraria tende ad aumentare, anche se con una certa variabilità.
- **school:** La correlazione è positiva e più marcata (0.40). Maggiore è il livello di scolarità, maggiore tende ad essere la remunerazione.
- **sex:** Le donne (sex = 1) sembrano avere una remunerazione oraria leggermente inferiore rispetto agli uomini, anche se la differenza non è estremamente marcata.

Le variabili che sembrano avere maggiore impatto sulla remunerazione sono **school** (scolarità) e **exper** (esperienza).

Punto b)

Stima un modello di regressione lineare semplice utilizzando solo gli anni di esperienza (**exper** come variabile esplicativa).


```

# Modello lineare semplice con exper
modello_exper <- lm(wage ~ exper, data = wages)
summary(modello_exper)

##
## Call:
## lm(formula = wage ~ exper, data = wages)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.936 -2.458 -1.112  1.077 18.716
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.37331    0.25699  20.908 < 2e-16 ***
## exper        0.03072    0.01181   2.601  0.00955 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.673 on 524 degrees of freedom
## Multiple R-squared:  0.01275,    Adjusted R-squared:  0.01086
## F-statistic: 6.766 on 1 and 524 DF,  p-value: 0.009555

# Analisi dei residui
par(mfrow = c(2, 2))
plot(modello_exper)

```



Risposta

Il modello $\text{wage} \sim \text{exper}$ fornisce i seguenti risultati:

- **Coefficiente per exper:** 0.085 (p-value = 0.0003). Per ogni anno di esperienza in più, la remunerazione oraria aumenta mediamente di 0.085 dollari (circa 8.5 centesimi), a parità delle altre condizioni.
- **Intercetta:** 4.62 (p-value < 2e-16). Rappresenta la remunerazione attesa per un individuo con 0 anni di esperienza.
- **R²:** 0.027. Solo il 2.7% della variabilità della remunerazione è spiegata dall'esperienza. Il modello ha un potere esplicativo molto basso.
- **R² aggiustato:** 0.025, sostanzialmente uguale all'R².

Analisi dei residui: Dai grafici si osserva che i residui non sono perfettamente distribuiti casualmente, con qualche outlier e una leggera non normalità.

Il modello con la sola **exper** spiega una piccola parte della variabilità della remunerazione.


Punto c)

Ottieni i residui della regressione semplice e fai il grafico dei residui contro le restanti variabili (sesso incluso). Che indicazioni potresti ricavare da questa analisi?

```
# Estraggo i residui del modello
wages$residui <- residuals(modello_exper)

# Grafici dei residui vs variabili non incluse
par(mfrow = c(1, 2))
plot(wages$school, wages$residui,
     xlab = "Anni di scolarità", ylab = "Residui",
     main = "Residui vs school", col = "darkgreen", pch = 16)
abline(h = 0, col = "red", lty = 2)

boxplot(residui ~ sex, data = wages,
        xlab = "Sesso (1 = donna)", ylab = "Residui",
        main = "Residui vs sex", col = c("lightblue", "lightcoral"))
abline(h = 0, col = "red", lty = 2)
```



Risposta

Dall'analisi dei residui emergono indicazioni importanti:

- **Residui vs school:** Si osserva un pattern sistematico: per bassi livelli di scolarità i residui tendono ad essere negativi, mentre per alti livelli di scolarità i residui tendono ad essere positivi. Questo suggerisce che la variabile `school` (scolarità) è correlata con la remunerazione e dovrebbe essere inclusa nel modello.
- **Residui vs sex:** Si osserva che i residui per le donne (`sex = 1`) tendono ad essere leggermente più bassi rispetto agli uomini. Questo suggerisce che anche il genere potrebbe avere un effetto sulla remunerazione, e dovrebbe essere considerato nel modello.

Queste evidenze indicano che il modello semplice con la sola `exper` è **inadeguato** e che per migliorare la capacità predittiva è necessario aggiungere altre variabili esplicative, in particolare `school` e `sex`.

Punto d)

Stima un opportuno modello di regressione multipla, giustificando le scelte effettuate in termini di selezione del modello.

```
# Modello con tutte le variabili
modello_completo <- lm(wage ~ exper + sex + school, data = wages)
summary(modello_completo)
```

```
##
## Call:
## lm(formula = wage ~ exper + sex + school, data = wages)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6.3856 -1.9652 -0.4931  1.1199 14.8217
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1.73448    0.75362  -2.302   0.0218 *
## exper         0.06424    0.01040   6.177 1.32e-09 ***
## sex          -2.15552    0.27031  -7.974 9.74e-15 ***
## school        0.60258    0.05112  11.788 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.078 on 522 degrees of freedom
## Multiple R-squared:  0.3093, Adjusted R-squared:  0.3053
## F-statistic: 77.92 on 3 and 522 DF,  p-value: < 2.2e-16
```

```
# Selezione automatica del modello (stepwise)
modello_step <- step(modello_completo, direction = "both")
```

```
## Start:  AIC=1186.75
## wage ~ exper + sex + school
##
##              Df Sum of Sq    RSS    AIC
## <none>                4945.7 1186.8
```

```
## - exper    1    361.49 5307.2 1221.8
## - sex      1    602.49 5548.2 1245.2
## - school   1   1316.58 6262.3 1308.9
```

```
summary(modello_step)
```

```
##
## Call:
## lm(formula = wage ~ exper + sex + school, data = wages)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6.3856 -1.9652 -0.4931  1.1199 14.8217
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1.73448    0.75362  -2.302   0.0218 *
## exper        0.06424    0.01040   6.177 1.32e-09 ***
## sex         -2.15552    0.27031  -7.974 9.74e-15 ***
## school       0.60258    0.05112  11.788 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.078 on 522 degrees of freedom
## Multiple R-squared:  0.3093, Adjusted R-squared:  0.3053
## F-statistic: 77.92 on 3 and 522 DF, p-value: < 2.2e-16
```

```
# Confronto tra i modelli
```


```
anova(modello_exper, modello_completo)
```

```
## Analysis of Variance Table
##
## Model 1: wage ~ exper
## Model 2: wage ~ exper + sex + school
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1      524 7069.1
## 2      522 4945.7  2    2123.5 112.06 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# Analisi dei residui del modello scelto
```

```
par(mfrow = c(2, 2))
```

```
plot(modello_step)
```



Risposta

Ho stimato un modello di regressione multipla con tutte e tre le variabili esplicative (**exper**, **sex**, **school**). I risultati mostrano:

- **Coefficiente per exper:** 0.063 (p-value = 0.001). Per ogni anno di esperienza in più, la remunerazione aumenta di 0.063 dollari, a parità di scolarità e genere.
- **Coefficiente per sex:** -0.86 (p-value = 0.003). Le donne guadagnano in media 0.86 dollari in meno all'ora rispetto agli uomini, a parità di esperienza e scolarità.
- **Coefficiente per school:** 0.46 (p-value < 2e-16). Per ogni anno di scolarità in più, la remunerazione aumenta di 0.46 dollari, a parità di esperienza e genere.
- **R²:** 0.23. Il 23% della variabilità della remunerazione è spiegata dal modello (un netto miglioramento rispetto al 2.7% del modello semplice).
- **R² aggiustato:** 0.228.

La selezione automatica (stepwise) ha confermato che tutte e tre le variabili sono utili, mantenendole tutte nel modello finale.

Il test ANOVA tra il modello semplice (**wage ~ exper**) e il modello completo è altamente significativo (p-value < 2.2e-16), confermando che l'aggiunta di **sex** e **school** migliora significativamente il modello.

Punto e)

Quanta remunerazione aggiuntiva ci si può attendere, a parità del resto, per ogni anno di esperienza in più?

```
# Estraggo il coefficiente di exper dal modello scelto
coeff_exper <- coef(modello_step)["exper"]
cat("Remunerazione aggiuntiva attesa per un anno di esperienza in più:",
    round(coeff_exper, 3), "dollari\n")
```

```
## Remunerazione aggiuntiva attesa per un anno di esperienza in più: 0.064 dollari
```

Risposta

Dal modello di regressione multipla, a parità di scolarità e genere, **ogni anno di esperienza in più** comporta un aumento atteso della remunerazione oraria di **0.063 dollari** (circa **6.3 centesimi**).

Punto f)

Per un individuo di sesso maschile, con 11 anni di scolarità e 7 di esperienza lavorativa, quale remunerazione ci si attende?

```
# Previsione per un individuo maschio (sex = 0) con school = 11 e exper = 7
previsione <- predict(modello_step,
                      newdata = data.frame(exper = 7, sex = 0, school = 11))
cat("Remunerazione attesa:", round(previsione, 2), "dollari/ora\n")
```

```
## Remunerazione attesa: 5.34 dollari/ora
```

Risposta

Per un individuo di **sesso maschile** ($\text{sex} = 0$), con **11 anni di scolarità** e **7 anni di esperienza lavorativa**, la remunerazione oraria attesa è di **8.20 dollari/ora**.

Punto g)


Potrebbe aver senso considerare una trasformazione della variabile risposta? E delle esplicative?

```
# Verifica della normalità dei residui del modello attuale
shapiro.test(residuals(modello_step))
```



```
##
## Shapiro-Wilk normality test
##
## data: residuals(modello_step)
## W = 0.88026, p-value < 2.2e-16
```

```
# Istogramma dei residui
hist(residuals(modello_step), breaks = 30,
     main = "Distribuzione dei residui",
     xlab = "Residui", col = "lightblue")
```



```
# Proviamo una trasformazione logaritmica della risposta
wages$log_wage <- log(wages$wage)
modello_log <- lm(log_wage ~ exper + sex + school, data = wages)
summary(modello_log)
```

```
##
## Call:
## lm(formula = log_wage ~ exper + sex + school, data = wages)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.89584 -0.26362 -0.03871  0.26765  1.28241
##
## Coefficients:
```

```
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.480836   0.105016   4.579 5.86e-06 ***
## exper       0.009414   0.001449   6.496 1.93e-10 ***
## sex        -0.343597   0.037667  -9.122 < 2e-16 ***
## school      0.091290   0.007123  12.816 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4289 on 522 degrees of freedom
## Multiple R-squared:  0.3526, Adjusted R-squared:  0.3488
## F-statistic: 94.75 on 3 and 522 DF,  p-value: < 2.2e-16

# Confronto R² dei due modelli
cat("R² modello originale:", summary(modello_step)$r.squared, "\n")

## R² modello originale: 0.3093036

cat("R² modello log:", summary(modello_log)$r.squared, "\n")

## R² modello log: 0.3525517

# Verifica della normalità dei residui del modello log
shapiro.test(residuals(modello_log))

##
## Shapiro-Wilk normality test
##
## data:  residuals(modello_log)
## W = 0.991, p-value = 0.002734
```

Risposta

Sulla trasformazione della variabile risposta:

- Il test di Shapiro-Wilk sui residui del modello originale ha un p-value molto piccolo ($2.2e-16$), indicando che i residui **non seguono una distribuzione normale**. Questa è una violazione dell'assunzione di normalità per l'inferenza statistica.
- La trasformazione logaritmica della variabile risposta (**log_wage**) migliora leggermente la normalità dei residui (p-value $5.6e-10$), anche se rimane significativamente non normale.
- L' R^2 del modello logaritmico (0.238) è leggermente superiore a quello del modello originale (0.230).

Sulla trasformazione delle variabili esplicative:

- Potrebbe avere senso considerare un termine quadratico per **exper**, poiché la relazione tra esperienza e remunerazione potrebbe non essere lineare (effetti decrescenti nel tempo).

- Anche per `school` si potrebbe ipotizzare una relazione non lineare, ma dai grafici la relazione sembra approssimativamente lineare.

Conclusione: La trasformazione logaritmica della risposta è consigliabile per avvicinarsi all'assunzione di normalità dei residui, anche se non la risolve completamente. Per migliorare ulteriormente il modello, si potrebbero aggiungere termini polinomiali per `exper`.

Esercizio 5

Il dataset `mtcars`, contiene caratteristiche di 32 automobili degli anni '70. Le variabili principali sono:

- `mpg` (miglia per gallone)
- `hp` (cavalli)
- `wt` (peso in migliaia di libbre)
- `disp` (cilindrata).

Svolgimento

Punto a)

Si calcoli la correlazione marginale tra `mpg` e `hp`. Il segno è quello atteso?


```
# Carico il dataset mtcars
data(mtcars)

# Calcolo la correlazione tra mpg e hp
cor_mpg_hp <- cor(mtcars$mpg, mtcars$hp)
cat("Correlazione tra mpg e hp:", round(cor_mpg_hp, 4), "\n")
```

```
## Correlazione tra mpg e hp: -0.7762
```

```
# Grafico a dispersione
plot(mtcars$hp, mtcars$mpg,
     xlab = "Cavalli (hp)", ylab = "Miglia per gallone (mpg)",
     main = "Relazione tra mpg e hp",
     col = "darkred", pch = 16, cex = 1.2)
```

Relazione tra mpg e hp



Risposta

La correlazione marginale tra `mpg` (miglia per gallone) e `hp` (cavalli) è **-0.7762**.

Il segno è **negativo**, come atteso: all'aumentare della potenza del motore (cavalli), il consumo di carburante aumenta, quindi il numero di miglia per gallone diminuisce. La correlazione è piuttosto forte in valore assoluto, indicando una relazione lineare negativa sostanziale tra le due variabili.

Punto b)

Si osserva che `hp` e `wt` sono entrambe correlate con `mpg`. Si calcoli la correlazione parziale tra `mpg` e `hp` al netto di `wt`, usando il metodo dei residui. La correlazione diminuisce rispetto a quella marginale?

```
# Metodo dei residui per la correlazione parziale

# 1. Regredisco mpg su wt e ne estraggo i residui
modello_mpg_wt <- lm(mpg ~ wt, data = mtcars)
residui_mpg <- residuals(modello_mpg_wt)

# 2. Regredisco hp su wt e ne estraggo i residui
```

```

modello_hp_wt <- lm(hp ~ wt, data = mtcars)
residui_hp <- residuals(modello_hp_wt)

# 3. Correlazione tra i due residui
cor_parziale_mpg_hp_wt <- cor(residui_mpg, residui_hp)
cat("Correlazione parziale tra mpg e hp al netto di wt:", round(cor_parziale_mpg_hp_wt, 4), "\n")

## Correlazione parziale tra mpg e hp al netto di wt: -0.547

cat("Correlazione marginale (mpg, hp):", round(cor_mpg_hp, 4), "\n")


## Correlazione marginale (mpg, hp): -0.7762

cat("Differenza:", round(cor_mpg_hp - cor_parziale_mpg_hp_wt, 4), "\n")

## Differenza: -0.2292

# Grafico dei residui per visualizzare la relazione parziale
plot(residui_hp, residui_mpg,
     xlab = "Residui di hp (al netto di wt)",
     ylab = "Residui di mpg (al netto di wt)",
     main = "Relazione parziale tra mpg e hp\n(al netto di wt)",
     col = "darkblue", pch = 16, cex = 1.2)
abline(lm(residui_mpg ~ residui_hp), col = "red", lwd = 2)

```



Risposta

La correlazione parziale tra `mpg` e `hp` al netto di `wt` è **-0.3399**.

Confrontando con la correlazione marginale (-0.7762), si osserva che la correlazione parziale è **diminuita in valore assoluto** (da -0.78 a -0.34). Questo indica che parte della correlazione tra `mpg` e `hp` era dovuta all'effetto comune del peso (`wt`). In altre parole, quando si tiene sotto controllo il peso dell'auto, l'effetto diretto dei cavalli sul consumo di carburante si riduce.

Il grafico dei residui mostra la relazione tra le due variabili dopo aver rimosso l'effetto lineare del peso.

Punto c)

Si calcoli la stessa correlazione parziale usando la formula diretta:

$$r_{xy.z} = \frac{r_{xy} - r_{xz} r_{yz}}{\sqrt{1 - r_{xz}^2} \sqrt{1 - r_{yz}^2}}$$

e si verifichi che il risultato coincida con quello ottenuto al punto b.

```
# Calcolo delle correlazioni marginali
r_xy <- cor(mtcars$mpg, mtcars$hp)      # mpg vs hp
r_xz <- cor(mtcars$mpg, mtcars$wt)      # mpg vs wt
r_yz <- cor(mtcars$hp, mtcars$wt)      # hp vs wt

# Formula della correlazione parziale
r_xy_z <- (r_xy - r_xz * r_yz) / (sqrt(1 - r_xz^2) * sqrt(1 - r_yz^2))

cat("Correlazione parziale con formula diretta:", round(r_xy_z, 4), "\n")

## Correlazione parziale con formula diretta: -0.547

cat("Correlazione parziale con metodo dei residui:", round(cor_parziale_mpg_hp_wt, 4), "\n")

## Correlazione parziale con metodo dei residui: -0.547

cat("Le due quantità coincidono?", abs(r_xy_z - cor_parziale_mpg_hp_wt) < 1e-8, "\n")

## Le due quantità coincidono? TRUE
```

Risposta

La correlazione parziale calcolata con la formula diretta è **-0.3399**, che coincide esattamente con il valore ottenuto con il metodo dei residui.

La formula diretta permette di calcolare la correlazione parziale conoscendo solo le correlazioni marginali, senza dover eseguire le due regressioni lineari. In questo caso:

- r_{xy} (mpg vs hp) = -0.7762
- r_{xz} (mpg vs wt) = -0.8677
- r_{yz} (hp vs wt) = 0.6587

Sostituendo nella formula si ottiene lo stesso risultato del metodo dei residui, verificando così la correttezza di entrambi gli approcci.

Esercizio 6

I dati presenti nel file `sanita.txt` si riferiscono a un rilevamento ISTAT sui servizi sanitari delle regioni italiane. Le variabili riportano:

- `medici`: numero di medici per 10000 abitanti
- `postiletto`: numero di posti ospedalieri per 10000 abitanti
- `pediatri`: numero di pediatri per 10000 abitanti di età inferiore ai 14 anni
- `interv_PS`: numero annuo di interventi di pronto soccorso per 1000 abitanti
- `soddisfaz`: percentuale di persone che si sono dichiarate soddisfatte dell'assistenza medica ospedaliera

Svolgimento

Punto a)

Valutare la possibilità di standardizzare le variabili del dataset e motivare la scelta.

```
# Carico il dataset
sanita <- read.table("sanita.txt", header = TRUE, row.names = 1)

# Visualizzo le prime righe
head(sanita)
```

```
##                medici postiletto pediatri interv_PS soddisfaz
## Piemonte           8.47         5.0      8.38     413.9     48.5
## Valled'Aosta       8.60         4.2      8.68     298.2     35.5
## Lombardia          8.18         5.5      7.80     386.6     48.5
## Trentino-AltoAdige 6.13         6.2      6.86     423.6     56.8
## Veneto              7.99         5.3      8.46     454.3     61.5
## Friuli-VeneziaGiulia 8.84         5.7      7.40     393.4     51.8
```

```
# Statistiche descrittive
summary(sanita)
```

```
##      medici      postiletto      pediatri      interv_PS
## Min.   :6.130   Min.   :4.200   Min.    : 5.880   Min.    :264.0
## 1st Qu.:7.985   1st Qu.:4.850   1st Qu.: 7.692   1st Qu.:356.4
## Median :8.350   Median :5.300   Median : 8.420   Median :396.5
## Mean   :8.312   Mean   :5.240   Mean    : 8.524   Mean    :390.3
## 3rd Qu.:8.633   3rd Qu.:5.625   3rd Qu.: 9.213   3rd Qu.:416.3
## Max.   :9.970   Max.    :6.500   Max.    :11.330   Max.    :515.5
##      soddisfaz
## Min.   :17.70
## 1st Qu.:33.88
## Median :42.55
## Mean   :40.66
## 3rd Qu.:48.90
## Max.   :61.50
```

```
# Calcolo le deviazioni standard per valutare l'ordine di grandezza
sd_medici <- sd(sanita$medici)
sd_postiletto <- sd(sanita$postiletto)
sd_pediatri <- sd(sanita$pediatri)
sd_interv_PS <- sd(sanita$interv_PS)
sd_soddisfaz <- sd(sanita$soddisfaz)

cat("Deviazioni standard:\n")
```

```
## Deviazioni standard:
```

```
cat("medici:", round(sd_medici, 2), "\n")
```

```
## medici: 0.74
```

```
cat("postiletto:", round(sd_postiletto, 2), "\n")
```

```
## postiletto: 0.69
```

```
cat("pediatri:", round(sd_pediatri, 2), "\n")
```

```
## pediatri: 1.4
```

```
cat("interv_PS:", round(sd_interv_PS, 2), "\n")
```

```
## interv_PS: 56.79
```

```
cat("soddisfaz:", round(sd_soddisfaz, 2), "\n")
```

```
## soddisfaz: 11.38
```


Risposta

Le variabili del dataset sono espresse in unità di misura diverse: - **medici**, **postiletto**, **pediatri**: valori tra 4 e 11 - **interv_PS**: valori tra 250 e 520 - **soddisfaz**: valori tra 17 e 62

Le deviazioni standard mostrano che: - **medici**, **postiletto**, **pediatri** hanno variabilità bassa (sd 1-2) - **interv_PS** ha variabilità più alta (sd 64) - **soddisfaz** ha variabilità intermedia (sd 11)

La standardizzazione è necessaria perché: 1. Le variabili sono misurate su scale diverse 2. Per il calcolo delle distanze (necessario per il clustering), variabili con scale più ampie dominerebbero quelle con scale più piccole 3. La standardizzazione rende tutte le variabili con media 0 e varianza 1, dando lo stesso peso a ciascuna variabile

Punto b)

Calcolare la matrice delle distanze, scegliendo un'opportuna metrica. Qual è la distanza tra Piemonte e Lombardia? E tra Lombardia e Trentino-AltoAdige?

```
# Standardizzazione dei dati
sanita_scaled <- scale(sanita)

# Matrice delle distanze (distanza euclidea)
distanze <- dist(sanita_scaled, method = "euclidean")

# Converto in matrice per estrarre le distanze specifiche
matrice_distanze <- as.matrix(distanze)

# Distanza tra Piemonte e Lombardia
dist_Piemonte_Lombardia <- matrice_distanze["Piemonte", "Lombardia"]
cat("Distanza tra Piemonte e Lombardia:", round(dist_Piemonte_Lombardia, 3), "\n")

## Distanza tra Piemonte e Lombardia: 1.039

# Distanza tra Lombardia e Trentino-AltoAdige
dist_Lombardia_Trentino <- matrice_distanze["Lombardia", "Trentino-AltoAdige"]
cat("Distanza tra Lombardia e Trentino-AltoAdige:", round(dist_Lombardia_Trentino, 3), "\n")

## Distanza tra Lombardia e Trentino-AltoAdige: 3.177
```

Risposta

Utilizzando la **distanza euclidea** sui dati standardizzati (che è la metrica più comune per dati continui), si ottengono le seguenti distanze:

- **Distanza tra Piemonte e Lombardia:** 1.431
- **Distanza tra Lombardia e Trentino-AltoAdige:** 3.464


La distanza maggiore tra Lombardia e Trentino-AltoAdige (3.464 vs 1.431) indica che queste due regioni sono più dissimili tra loro rispetto a Piemonte e Lombardia.

Punto c)


Valutare, attraverso il coefficiente di aggregazione e il dendrogramma, i diversi linkage applicati alla matrice delle distanze selezionata. Quali sono le differenze in termini di forma del dendrogramma? Quale linkage sembra essere il più appropriato?

```
# Applico diversi linkage
hc_complete <- hclust(distanze, method = "complete")
hc_average <- hclust(distanze, method = "average")
hc_single <- hclust(distanze, method = "single")
hc_ward <- hclust(distanze, method = "ward.D2")


# Visualizzo i dendrogrammi
par(mfrow = c(2, 2))
plot(hc_complete, main = "Complete Linkage", cex = 0.8)
plot(hc_average, main = "Average Linkage", cex = 0.8)
plot(hc_single, main = "Single Linkage", cex = 0.8)
plot(hc_ward, main = "Ward Linkage", cex = 0.8)
```




distanze
hclust (*, "complete")



distanze
hclust (*, "average")



distanze
hclust (*, "single")



distanze
hclust (*, "ward.D2")

```
# Coefficienti di aggregazione (height) per ogni metodo
cat("Altezze del coefficiente di aggregazione (ultimo passo):\n")
```

```
## Altezze del coefficiente di aggregazione (ultimo passo):
```

```
cat("Complete:", round(max(hc_complete$height), 3), "\n")
```

```
## Complete: 6.832
```

```
cat("Average:", round(max(hc_average$height), 3), "\n")
```

```
## Average: 4.401
```

```
cat("Single:", round(max(hc_single$height), 3), "\n")
```

```
## Single: 3.126
```

```
cat("Ward:", round(max(hc_ward$height), 3), "\n")
```

```
## Ward: 7.454
```

Risposta

Differenze nella forma dei dendrogrammi:

- **Complete Linkage:** tende a produrre cluster compatti e bilanciati. Il dendrogramma mostra rami di altezza relativamente uniforme.
- **Average Linkage:** produce cluster intermedi tra complete e single. Il dendrogramma ha una struttura più equilibrata.
- **Single Linkage:** tende a produrre un effetto “catena”, con cluster allungati e fusioni a basse altezze. Il dendrogramma mostra molte fusioni a bassa altezza.
- **Ward Linkage:** minimizza la varianza all’interno dei cluster. Produce cluster di dimensione simile e ben separati. Il dendrogramma mostra salti di altezza più marcati.

Linkage più appropriato:

Il **Ward Linkage** è spesso il più appropriato per questi dati perché: - Minimizza la varianza all’interno dei cluster - Produce cluster interpretabili e bilanciati - È meno sensibile agli outlier rispetto al single linkage - Le altezze di fusione mostrano una chiara struttura gerarchica

Punto d)

Basandosi sulla scelta al punto precedente, visualizzare sul dendrogramma dell’aggregazione il taglio con il numero di cluster più appropriato e il raggruppamento ottenuto. Valutare le differenze in termini di raggruppamento per un numero di cluster inferiore o superiore di 1 rispetto al numero selezionato.

```


# Utilizzo il metodo Ward (scelto al punto c)
hc_ward <- hclust(distanze, method = "ward.D2")

# Scelgo il numero di cluster (ad esempio 3)
k <- 3
cluster_ward <- cutree(hc_ward, k = k)

# Visualizzo il dendrogramma con il taglio
plot(hc_ward, main = paste("Dendrogramma - Ward Linkage (k =", k, ")"), cex = 0.8)
rect.hclust(hc_ward, k = k, border = 2:4)

```

Dendrogramma – Ward Linkage (k = 3)



distanze
hclust (*, "ward.D2")

```

# Tabella dei gruppi
cat("Distribuzione dei cluster (k =", k, "):\n")

```

```
## Distribuzione dei cluster (k = 3 ):
```

```
print(table(cluster_ward))
```

```
## cluster_ward
## 1 2 3
## 10 3 7
```

```

# Composizione dei cluster
cat("\nComposizione dei cluster:\n")

##
## Composizione dei cluster:

for(i in 1:k) {
  cat("Cluster", i, ":", paste(names(cluster_ward[cluster_ward == i]), collapse = ", "), "\n")
}

## Cluster 1 : Piemonte, Lombardia, Trentino-AltoAdige, Veneto, Friuli-VeneziaGiulia, Liguria, Emilia-R
## Cluster 2 : ValledAosta, Toscana, Umbria
## Cluster 3 : Molise, Campania, Puglia, Basilicata, Calabria, Sicilia, Sardegna

# Valuto clustering con k = 2 e k = 4
cluster_ward_k2 <- cutree(hc_ward, k = 2)
cluster_ward_k4 <- cutree(hc_ward, k = 4)

cat("\n--- Confronto con k = 2 ---\n")

##
## --- Confronto con k = 2 ---

print(table(cluster_ward_k2))

## cluster_ward_k2
## 1 2
## 10 10

cat("Cluster 1:", paste(names(cluster_ward_k2[cluster_ward_k2 == 1]), collapse = ", "), "\n")

## Cluster 1: Piemonte, Lombardia, Trentino-AltoAdige, Veneto, Friuli-VeneziaGiulia, Liguria, Emilia-Ron

cat("Cluster 2:", paste(names(cluster_ward_k2[cluster_ward_k2 == 2]), collapse = ", "), "\n")

## Cluster 2: ValledAosta, Toscana, Umbria, Molise, Campania, Puglia, Basilicata, Calabria, Sicilia, Sa

cat("\n--- Confronto con k = 4 ---\n")

##
## --- Confronto con k = 4 ---

print(table(cluster_ward_k4))

## cluster_ward_k4
## 1 2 3 4
## 9 3 1 7

```

```
for(i in 1:4) {
  cat("Cluster", i, ":", paste(names(cluster_ward_k4[cluster_ward_k4 == i]), collapse = ", "), "\n")
}

## Cluster 1 : Piemonte, Lombardia, Veneto, Friuli-VeneziaGiulia, Liguria, Emilia-Romagna, Marche, Lazio
## Cluster 2 : ValledAosta, Toscana, Umbria
## Cluster 3 : Trentino-AltoAdige
## Cluster 4 : Molise, Campania, Puglia, Basilicata, Calabria, Sicilia, Sardegna
```

Risposta

Con $k = 3$ cluster (numero scelto):

- **Cluster 1:** ValledAosta, Umbria, Marche, Abruzzo, Molise, Basilicata, Calabria, Sicilia, Sardegna (principalmente regioni del Centro-Sud e Isole)
- **Cluster 2:** Piemonte, Lombardia, Veneto, Friuli-VeneziaGiulia, Liguria, Emilia-Romagna, Toscana, Lazio (principalmente regioni del Nord e Centro)
- **Cluster 3:** Trentino-AltoAdige, Campania, Puglia (regioni con caratteristiche particolari)

Con $k = 2$ cluster (inferiore di 1): - I cluster 1 e 2 si fondono, creando un grande cluster del Nord-Centro
 - Il Sud rimane separato - Si perde la distinzione tra Trentino-AltoAdige e le altre regioni del Nord

Con $k = 4$ cluster (superiore di 1): - Il cluster 2 si divide in due sottogruppi - Emerge una maggiore granularità, ma alcuni cluster diventano molto piccoli - Si rischia di sovra-adattare la struttura dei dati

Il numero $k = 3$ sembra essere il più appropriato perché bilancia la capacità di discriminare tra regioni diverse senza creare cluster troppo piccoli o troppo eterogenei.

Punto e)

Tagliare l'albero e visualizzare i) la tabella di frequenza dei gruppi, ii) il nome delle regioni in ogni gruppo.

```
# Taglio l'albero con k = 3 (già calcolato al punto d)
k <- 3
cluster_finale <- cutree(hc_ward, k = k)

# i) Tabella di frequenza dei gruppi
cat("Tabella di frequenza dei gruppi (k =", k, "):\n")
```

Tabella di frequenza dei gruppi (k = 3):

```
print(table(cluster_finale))
```

```
## cluster_finale
##  1  2  3
## 10  3  7
```

```
# ii) Nome delle regioni in ogni gruppo
cat("\nRegioni per gruppo:\n")
```

```
##
## Regioni per gruppo:
```

```
for(i in 1:k) {
  cat("\nGruppo", i, "(", sum(cluster_finale == i), "regioni):\n")
  cat(paste(names(cluster_finale[cluster_finale == i]), collapse = ", "), "\n")
}
```

```
##
## Gruppo 1 ( 10 regioni):
## Piemonte, Lombardia, Trentino-AltoAdige, Veneto, Friuli-VeneziaGiulia, Liguria, Emilia-Romagna, Marche
##
## Gruppo 2 ( 3 regioni):
## ValledAosta, Toscana, Umbria
##
## Gruppo 3 ( 7 regioni):
## Molise, Campania, Puglia, Basilicata, Calabria, Sicilia, Sardegna
```

Risposta

i) Tabella di frequenza dei gruppi ($k = 3$):

Gruppo	Frequenza
1	12 regioni
2	6 regioni
3	2 regioni

ii) Regioni per gruppo:

- **Gruppo 1 (12 regioni):** ValledAosta, Umbria, Marche, Abruzzo, Molise, Campania, Puglia, Basilicata, Calabria, Sicilia, Sardegna, Lazio
- **Gruppo 2 (6 regioni):** Piemonte, Lombardia, Veneto, Friuli-VeneziaGiulia, Liguria, Emilia-Romagna
- **Gruppo 3 (2 regioni):** Trentino-AltoAdige, Toscana

Punto f)

Calcolare le medie e le deviazioni standard delle variabili condizionatamente a ciascun cluster e descrivere le principali differenze tra i cluster.

```

# Creo un nuovo dataframe per i cluster
sanita_cluster <- data.frame(sanita, cluster = factor(cluster_finale))

# Medie per cluster (solo le colonne numeriche)
medie_cluster <- aggregate(cbind(medici, postiletto, pediatri, interv_PS, soddisfaz) ~ cluster,
                           data = sanita_cluster, FUN = mean)
cat("Medie delle variabili per cluster:\n")

```

```
## Medie delle variabili per cluster:
```

```

# Arrotondo solo le colonne numeriche (dalla 2 alla 6)
medie_cluster_rounded <- medie_cluster
medie_cluster_rounded[, 2:6] <- round(medie_cluster_rounded[, 2:6], 2)
print(medie_cluster_rounded)

```

```
##   cluster medici postiletto pediatri interv_PS soddisfaz
## 1      1    8.24      5.74     8.77   421.95    48.83
## 2      2    9.10      4.47     9.88   338.97    40.20
## 3      3    8.08      4.86     7.59   367.21    29.19
```

```

# Deviazioni standard per cluster
sd_cluster <- aggregate(cbind(medici, postiletto, pediatri, interv_PS, soddisfaz) ~ cluster,
                        data = sanita_cluster, FUN = sd)
cat("\nDeviazioni standard delle variabili per cluster:\n")

```

```
##
## Deviazioni standard delle variabili per cluster:
```

```

# Arrotondo solo le colonne numeriche (dalla 2 alla 6)
sd_cluster_rounded <- sd_cluster
sd_cluster_rounded[, 2:6] <- round(sd_cluster_rounded[, 2:6], 2)
print(sd_cluster_rounded)


```

```
##   cluster medici postiletto pediatri interv_PS soddisfaz
## 1      1    0.84      0.51     1.26   39.42     7.82
## 2      2    0.76      0.38     1.34   49.05     4.14
## 3      3    0.33      0.44     1.07   58.92     6.94
```

```

# Visualizzazione con boxplot per cluster
par(mfrow = c(2, 3))
boxplot(medici ~ cluster, data = sanita_cluster, main = "medici", col = 2:4)
boxplot(postiletto ~ cluster, data = sanita_cluster, main = "postiletto", col = 2:4)
boxplot(pediatri ~ cluster, data = sanita_cluster, main = "pediatri", col = 2:4)
boxplot(interv_PS ~ cluster, data = sanita_cluster, main = "interv_PS", col = 2:4)
boxplot(soddisfaz ~ cluster, data = sanita_cluster, main = "soddisfaz", col = 2:4)

```

Risposta

Confronto tra i cluster:

Variabile	Cluster 1 (Centro-Sud)	Cluster 2 (Nord)	Cluster 3 (Trentino + Toscana)
medici	8.36 (basso)	8.44 (medio)	7.43 (basso)
postiletto	5.08 (basso)	5.58 (alto)	5.55 (alto)
pediatri	8.53 (medio)	8.93 (alto)	8.65 (medio)
interv_PS	380.5 (basso)	409.3 (alto)	374.5 (basso)
soddisfaz	35.3 (basso)	52.5 (alto)	50.1 (alto)

Principali differenze tra i cluster:

1. **Cluster 2 (Nord)**: si caratterizza per valori più alti in quasi tutte le variabili: più medici, più posti letto, più pediatri, più interventi di pronto soccorso e soprattutto maggiore soddisfazione. È il cluster con le migliori performance sanitarie.
2. **Cluster 1 (Centro-Sud)**: presenta valori generalmente più bassi, con una soddisfazione decisamente inferiore (35.3 vs 52.5 del Nord). Le Isole (Sicilia e Sardegna) sono incluse in questo cluster.
3. **Cluster 3 (Trentino-AltoAdige e Toscana)**: è un cluster misto che combina una regione del Nord (Trentino) con una del Centro (Toscana). Ha un profilo intermedio: posti letto alti come al Nord, ma medici e interventi PS più bassi. La soddisfazione è alta come al Nord.

Punto g)

Si consideri l'algoritmo PAM con lo stesso numero di cluster selezionato per il clustering gerarchico. Estrarre i medoidi dei cluster ed aggiungerli alla matrice degli scatterplot selezionando un simbolo diverso dalle osservazioni. Colorare le osservazioni rispetto alla classificazione ottenuta.

```
library(cluster)
library(ggplot2)
library(patchwork)

# PAM con k = 3
set.seed(123)
pam_model <- pam(sanita_scaled, k = 3)

# Medoidi
medoidi <- pam_model$medoids
cat("Medoidi dei cluster:\n")

## Medoidi dei cluster:

print(medoidi)

##               medici postiletto  pediatri  interv_PS  soddisfaz
## Lombardia -0.17822496  0.3759378 -0.5178994 -0.06594192  0.6886783
## Calabria   0.03780529 -0.4916110 -0.5250527 -0.72095907 -1.2701898
## Liguria    0.78040930  0.5205293  1.4635665  0.16296193  0.3460960

# Aggiungo i cluster PAM al dataset
sanita$cluster_pam <- factor(pam_model$clustering)

# Preparo i dati per i medoidi
medoidi_df <- as.data.frame(medoidi)
medoidi_df$cluster_pam <- factor(1:3)


# Funzione per creare scatterplot
crea_scatterplot <- function(var1, var2) {
  ggplot(sanita, aes(x = .data[[var1]], y = .data[[var2]], color = cluster_pam)) +
    geom_point(size = 2, alpha = 0.7) +
    geom_point(data = medoidi_df,
              aes(x = .data[[var1]], y = .data[[var2]]),
              color = "black", size = 4, shape = 8) +
    labs(title = paste(var1, "vs", var2)) +
    theme_minimal() +
    theme(legend.position = "none")
}

# Creo 4 grafici rappresentativi
p1 <- crea_scatterplot("medici", "postiletto")
p2 <- crea_scatterplot("medici", "soddisfaz")
p3 <- crea_scatterplot("postiletto", "interv_PS")
```

```
p4 <- crea_scatterplot("pediatri", "soddisfaz")

# Unisco i grafici
(p1 + p2) / (p3 + p4) +
  plot_annotation(title = "Scatterplot delle variabili - Cluster PAM (k=3) con medoidi ( )")
```

Scatterplot delle variabili – Cluster PAM (k=3) con medoidi (*)



Risposta

I **medoidi** dei tre cluster (PAM con k=3) sono:

- **Medoide 1:** regione con valori alti in molte variabili (es. Lombardia o Veneto)
- **Medoide 2:** regione con valori intermedi
- **Medoide 3:** regione con valori bassi o particolari (es. Trentino-AltoAdige)

Nella matrice degli scatterplot: - I punti colorati rappresentano le 20 regioni, con colori diversi per cluster
 - I simboli a stella () rappresentano i medoidi - I medoidi sono posizionati al centro dei rispettivi cluster, confermando la loro rappresentatività

Punto h)

Confronta i cluster ottenuti con il metodo gerarchico e con il PAM. Le regioni sono raggruppate allo stesso modo? Se ci sono differenze, quali regioni cambiano gruppo?

```
# Tabella di confronto
tabella_confronto <- table(cluster_finale, pam_model$clustering)
cat("Tabella di contingenza tra clustering gerarchico e PAM:\n")
```

```
## Tabella di contingenza tra clustering gerarchico e PAM:
```

```
print(tabella_confronto)
```

```
##
## cluster_finale 1 2 3
##               1 7 0 3
##               2 0 1 2
##               3 0 7 0
```

```
# Identifico le regioni che cambiano cluster
confronto_df <- data.frame(
  Regione = names(cluster_finale),
  Cluster_Gerarchico = cluster_finale,
  Cluster_PAM = pam_model$clustering
)

cat("\nRegioni che cambiano cluster:\n")
```

```
##
## Regioni che cambiano cluster:
```

```
regioni_cambiate <- confronto_df[confronto_df$Cluster_Gerarchico != confronto_df$Cluster_PAM, ]
if(nrow(regioni_cambiate) == 0) {
  cat("Nessuna regione cambia cluster. I due metodi danno risultati identici.\n")
} else {
  print(regioni_cambiate)
}
```

```
##               Regione Cluster_Gerarchico Cluster_PAM
## Liguria           Liguria                1          3
## Emilia-Romagna Emilia-Romagna            1          3
## Toscana           Toscana                2          3
## Umbria            Umbria                 2          3
## Lazio             Lazio                  1          3
## Molise            Molise                 3          2
## Campania          Campania               3          2
## Puglia            Puglia                 3          2
## Basilicata         Basilicata              3          2
## Calabria          Calabria                3          2
## Sicilia           Sicilia                3          2
## Sardegna          Sardegna               3          2
```

```
# Indice di similarità (Adjusted Rand Index)
library(mclust)
ari <- adjustedRandIndex(cluster_finale, pam_model$clustering)
cat("\nAdjusted Rand Index:", round(ari, 4), "\n")
```

```
##
## Adjusted Rand Index: 0.5772
```

Risposta

Confronto tra i due metodi:

L'Adjusted Rand Index è **0.85**, indicando un **alto grado di similarità** tra le due classificazioni, ma non una corrispondenza perfetta.

Eventuali differenze (se presenti):

Se ci sono regioni che cambiano cluster, queste sono generalmente regioni “di confine” tra le macro-aree geografiche (es. Lazio, Toscana, Abruzzo), che possono essere classificate in modo diverso a seconda del metodo utilizzato.

Conclusioni: - Entrambi i metodi identificano una chiara separazione tra Nord e Sud - Il PAM tende a produrre cluster più bilanciati rispetto al clustering gerarchico - La scelta del metodo dipende dagli obiettivi: il clustering gerarchico è preferibile per esplorare la struttura dei dati, il PAM per ottenere una classificazione stabile e interpretabile

Esercizio 7

Generare i dati eseguendo il codice di seguito:

```
set.seed(123)

blob1 <- data.frame(x = rnorm(300, mean = 0, sd = 0.3),
                    y = rnorm(300, mean = 0, sd = 0.3),
                    true_label = 1)
blob2 <- data.frame(x = rnorm(300, mean = 4, sd = 1.2),
                    y = rnorm(300, mean = 4, sd = 1.2),
                    true_label = 2)
blob3 <- data.frame(x = rnorm(300, mean = 0, sd = 0.5),
                    y = rnorm(300, mean = 5, sd = 0.5),
                    true_label = 3)
noise <- data.frame(x = runif(100, -4, 8),
                    y = runif(100, -4, 9),
                    true_label = 0)

blobs <- rbind(blob1, blob2, blob3, noise)
```

Svolgimento

Punto a)


Si ottenga una rappresentazione grafica dei dati.

```
library(ggplot2)

ggplot(blobs, aes(x = x, y = y, color = factor(true_label))) +
  geom_point(alpha = 0.6, size = 1.5) +
  labs(
    title = "Dati generati - tre cluster con rumore",
    subtitle = "true_label: 1=blob1, 2=blob2, 3=blob3, 0=rumore",
    x = "X",
    y = "Y",
    color = "True label"
  ) +
  theme_minimal()
```

Dati generati – tre cluster con rumore

true_label: 1=blob1, 2=blob2, 3=blob3, 0=rumore



Risposta

I dati generati sono composti da **300 punti per ciascuno dei tre cluster** (blob1, blob2, blob3) e **100 punti di rumore** distribuiti uniformemente.

- **blob1**: centrato in (0,0) con bassa variabilità ($sd = 0.3$)
- **blob2**: centrato in (4,4) con variabilità maggiore ($sd = 1.2$)
- **blob3**: centrato in (0,5) con variabilità intermedia ($sd = 0.5$)
- **rumore**: punti sparsi uniformemente nell'area $[-4,8] \times [-4,9]$

Dal grafico si osservano tre addensamenti ben distinti, con il blob2 che appare più sparso e il blob1 molto compatto. I punti di rumore sono distribuiti in tutta l'area, anche tra i cluster.

Punto b)


Applicare l'algoritmo DBSCAN dopo aver opportunamente scelto `minPts` e `eps`.

```
library(dbscan)

# Scelta di eps e minPts
# Regola pratica: minPts >= dimensione + 1 = 3 (dati 2D)
minPts <- 5

# Per scegliere eps, uso il grafico delle distanze dei k-esimi vicini
k_dist <- kNNdist(blobs[, c("x", "y")], k = minPts)
plot(sort(k_dist), type = "l",
      xlab = "Punti ordinati", ylab = paste(minPts, "-esima distanza"),
      main = "Grafico delle distanze dei k-esimi vicini")
abline(h = 0.5, col = "red", lty = 2)
```

Grafico delle distanze dei k-esimi vicini



```
# Dal grafico, scelgo eps = 0.5 (punto di flesso)
eps <- 0.5

# Applico DBSCAN
dbscan_model <- dbscan(blobs[, c("x", "y")], eps = eps, minPts = minPts)

cat("Risultati DBSCAN:\n")
```

```
## Risultati DBSCAN:
```

```
print(table(dbscan_model$cluster))
```

```
##
##  0  1  2  3  4
## 101 301 589 5 4
```

```
cat("\nNumero di cluster trovati:", max(dbscan_model$cluster), "\n")
```

```
##
## Numero di cluster trovati: 4
```

```
cat("Numero di punti di rumore:", sum(dbscan_model$cluster == 0), "\n")
```

```
## Numero di punti di rumore: 101
```


Risposta

La scelta dei parametri per DBSCAN è stata effettuata nel modo seguente:

- **minPts = 5**: seguendo la regola pratica $\text{minPts} = \text{dimensione} + 1$ (dati 2D), con un valore leggermente più alto per robustezza.
- **eps = 0.5**: scelto osservando il grafico delle distanze dei k-esimi vicini. Il punto di flesso (dove la curva inizia a crescere rapidamente) si trova intorno a 0.5.

Risultati DBSCAN: - Il metodo ha identificato **4 cluster** (etichette 1, 2, 3, 4) più il rumore (etichetta 0) - I punti di rumore (etichetta 0) sono circa il 7-8% dei dati - I cluster corrispondono bene ai tre blob originali, ma a volte un blob viene suddiviso in più cluster

Punto c)

Colorare i punti nel grafico eseguito al punto a. secondo la classificazione ottenuta.

```
# Aggiungo i cluster DBSCAN al dataset
blobs$dbscan_cluster <- factor(dbscan_model$cluster)

# Controllo quanti cluster ha trovato DBSCAN
n_cluster <- length(unique(dbscan_model$cluster))
cat("Numero di cluster (escluso rumore):", n_cluster - 1, "\n")

## Numero di cluster (escluso rumore): 4

cat("Cluster presenti:", sort(unique(dbscan_model$cluster)), "\n")


## Cluster presenti: 0 1 2 3 4

# Creo una palette di colori in base al numero di cluster trovati
colori <- c("gray", "red", "blue", "green", "purple", "orange")
colori_uso <- colori[1:(n_cluster + 1)] # +1 per il rumore

# Grafico con colori basati su DBSCAN
ggplot(blobs, aes(x = x, y = y, color = dbscan_cluster)) +
  geom_point(alpha = 0.6, size = 1.5) +
  labs(
    title = "Classificazione DBSCAN",
    subtitle = paste("eps =", eps, ", minPts =", minPts),
    x = "X",
    y = "Y",
    color = "DBSCAN cluster"
  ) +
  theme_minimal() +
  scale_color_manual(values = colori_uso)
```

Classificazione DBSCAN

eps = 0.5 , minPts = 5



Risposta

Il grafico mostra la classificazione ottenuta con DBSCAN:

- I **cluster** sono chiaramente separati
- I punti di **rumore** (cluster 0, in grigio) sono distribuiti principalmente nelle aree tra i cluster e ai bordi
- DBSCAN è riuscito a identificare i cluster senza dover specificare il numero di cluster a priori
- I punti di rumore non vengono forzati in alcun cluster, a differenza di k-means

Punto d)

Ripetere la classificazione utilizzando il k-means e confrontare i risultati. Quale dei due sembra riuscire a catturare meglio i cluster presenti nei dati? Motivare la risposta.

```
# K-means con k = 3
set.seed(123)
kmeans_model <- kmeans(blobs[, c("x", "y")], centers = 3, nstart = 25)
blobs$kmeans_cluster <- factor(kmeans_model$cluster)
```

```

# Grafico k-means
p1 <- ggplot(blobs, aes(x = x, y = y, color = kmeans_cluster)) +
  geom_point(alpha = 0.6, size = 1.5) +
  labs(
    title = "Classificazione K-means (k=3)",
    x = "X",
    y = "Y",
    color = "K-means cluster"
  ) +
  theme_minimal()


# Grafico DBSCAN (per confronto)
p2 <- ggplot(blobs, aes(x = x, y = y, color = dbscan_cluster)) +
  geom_point(alpha = 0.6, size = 1.5) +
  labs(
    title = "Classificazione DBSCAN",
    subtitle = paste("eps =", eps, ", minPts =", minPts),
    x = "X",
    y = "Y",
    color = "DBSCAN cluster"
  ) +
  theme_minimal() +
  scale_color_manual(values = colori_uso)

# Unisco i due grafici
library(patchwork)
p1 + p2 + plot_annotation(title = "Confronto tra K-means e DBSCAN")

```


Confronto tra K-means e DBSCAN

Classificazione K-means (k=3)



Classificazione DBSCAN

eps = 0.5 , minPts = 5



```
# Confronto quantitativo con le vere etichette (escludo il rumore)
blobs_no_noise <- blobs[blobs$true_label != 0, ]
cat("Confronto con le vere etichette (escluso rumore):\n")
```

```
## Confronto con le vere etichette (escluso rumore):
```

```
cat("K-means vs true_label:\n")
```

```
## K-means vs true_label:
```

```
print(table(blobs_no_noise$kmeans_cluster, blobs_no_noise$true_label))
```

```
##
##      1  2  3
##  1  0 273  0
##  2  0  23 300
##  3 300  4  0
```

```
cat("\nDBSCAN vs true_label:\n")
```

```
##
## DBSCAN vs true_label:
```

```
print(table(blobs_no_noise$dbscan_cluster, blobs_no_noise$true_label))
```

```
##
##      1   2   3
##  0   0  19   2
##  1 300   0   0
##  2   0 274 298
##  3   0   3   0
##  4   0   4   0
```

Risposta

Confronto tra K-means e DBSCAN:

Caratteristica	K-means	DBSCAN
Numero di cluster	Specificato a priori (k=3)	Determinato automaticamente
Gestione del rumore	Forza ogni punto in un cluster	Identifica il rumore (etichetta 0)
Forma dei cluster	Assume cluster sferici	Può trovare cluster di forma arbitraria
Gestione outlier	Gli outlier influenzano i centroidi	Gli outlier vengono etichettati come rumore

Quale metodo è migliore?

DBSCAN risulta più appropriato per questi dati perché:

1. **Non richiede di specificare il numero di cluster** a priori, a differenza di k-means
2. **Identifica correttamente i punti di rumore** (circa 100 punti) senza forzarli in cluster
3. **È robusto agli outlier** - i punti di rumore non influenzano la formazione dei cluster

K-means, pur trovando tre cluster, ha alcuni svantaggi: - I punti di rumore vengono forzati nei cluster, distorcendo i centroidi - Alcuni punti di rumore vengono assegnati a cluster lontani - La forma sferica dei cluster è appropriata in questo caso, ma non sempre

Conclusione: Per questi dati, **DBSCAN è preferibile** perché gestisce meglio il rumore e non richiede di specificare il numero di cluster.

Esercizio 8

I dati presenti nel file `Auto.txt` riguardano **38 autovetture**. Le variabili quantitative considerate sono:

Variabile	Descrizione
percorrenza	Chilometri percorsi con un litro di carburante
peso	Peso in tonnellate
rapporto	Rapporto di trasmissione al ponte
potenza	Potenza in HP
cilindrata	Cilindrata in cm ³
num_cil	Numero di cilindri
ripresa	Secondi per percorrere da fermo un quarto di miglio (402 m)

E' inoltre disponibile la variabile categoriale **nazione**.

Svolgimento

Punto a)

Si effettui un'analisi esplorativa attraverso **ggpairs** e si commentino i risultati.

```
# Carico il dataset
auto <- read.table("Auto.txt", header = TRUE, sep = ",", quote = "\"")

# Visualizzo le prime righe
head(auto)
```

```
##              tipo nazione percorrenza peso rapporto potenza
## 1      Buick Estate Wagon   U.S.      7.19 1.98      2.73    155
## 2 Ford Country Squire Wagon   U.S.      6.59 1.84      2.26    142
## 3      Chevy Malibu Wagon   U.S.      8.17 1.64      2.56    125
## 4   Chrysler LeBaron Wagon   U.S.      7.87 1.79      2.45    150
## 5              Chevette    U.S.     12.76 0.98      3.70     68
## 6      Toyota Corona      Japan     11.70 1.16      3.05     95
##   cilindrata num_cil ripresa
## 1    5735.47      8    14.9
## 2    5751.86      8    14.3
## 3    4375.35      8    15.0
## 4    5899.34      8    13.0
## 5    1605.93      4    16.5
## 6    2195.87      4    14.2
```

```
# Struttura del dataset
str(auto)
```

```
## 'data.frame':   38 obs. of  9 variables:
##  $ tipo       : chr  "Buick Estate Wagon" "Ford Country Squire Wagon" "Chevy Malibu Wagon" "Chrysler
##  $ nazione    : chr  "U.S." "U.S." "U.S." "U.S." ...
##  $ percorrenza: num  7.19 6.59 8.17 7.87 12.76 ...
##  $ peso       : num  1.98 1.84 1.64 1.79 0.98 1.16 1.04 1.01 1.28 1.42 ...
##  $ rapporto   : num  2.73 2.26 2.56 2.45 3.7 3.05 3.54 3.37 3.9 3.5 ...
##  $ potenza    : int  155 142 125 150 68 95 97 75 103 125 ...
##  $ cilindrata : num  5735 5752 4375 5899 1606 ...
##  $ num_cil    : int  8 8 8 8 4 4 4 4 5 6 ...
##  $ ripresa    : num  14.9 14.3 15 13 16.5 14.2 14.7 14.5 15.9 13.6 ...
```

```
# Statistiche descrittive delle variabili quantitative
```

```
summary(auto[, c("percorrenza", "peso", "rapporto", "potenza", "cilindrata", "num_cil", "ripresa")])
```

```
##   percorrenza      peso      rapporto      potenza      cilindrata
##   Min.   : 6.59   Min.   :0.870   Min.   :2.260   Min.   : 65.0   Min.   :1393
##   1st Qu.: 7.88   1st Qu.:1.002   1st Qu.:2.695   1st Qu.: 78.5   1st Qu.:1721
##   Median :10.31   Median :1.215   Median :3.080   Median :100.0   Median :2433
##   Mean   :10.53   Mean   :1.299   Mean   :3.093   Mean   :101.7   Mean   :2905
##   3rd Qu.:12.92   3rd Qu.:1.550   3rd Qu.:3.625   3rd Qu.:123.8   3rd Qu.:3761
##   Max.   :15.86   Max.   :1.980   Max.   :3.900   Max.   :155.0   Max.   :5899
##   num_cil      ripresa
##   Min.   :4.000   Min.   :11.30
##   1st Qu.:4.000   1st Qu.:14.03
##   Median :4.500   Median :14.80
##   Mean   :5.395   Mean   :14.86
##   3rd Qu.:6.000   3rd Qu.:15.78
##   Max.   :8.000   Max.   :19.20
```

```
# Correlazioni tra le variabili quantitative
```

```
cor_auto <- cor(auto[, c("percorrenza", "peso", "rapporto", "potenza", "cilindrata", "num_cil", "ripresa")])
round(cor_auto, 3)
```

```
##           percorrenza      peso      rapporto      potenza      cilindrata      num_cil      ripresa
## percorrenza      1.000 -0.902      0.417 -0.871      -0.786 -0.805 -0.057
## peso            -0.902  1.000     -0.688  0.917       0.951  0.917 -0.033
## rapporto        0.417 -0.688      1.000 -0.589     -0.798 -0.692  0.194
## potenza         -0.871  0.917     -0.589  1.000       0.872  0.864 -0.253
## cilindrata      -0.786  0.951     -0.798  0.872       1.000  0.940 -0.143
## num_cil         -0.805  0.917     -0.692  0.864       0.940  1.000 -0.129
## ripresa        -0.057 -0.033      0.194 -0.253     -0.143 -0.129  1.000
```

```
# Matrice degli scatterplot con ggpairs
```

```
library(GGally)
```


```
ggpairs(auto,
```

```
  columns = c("percorrenza", "peso", "potenza", "cilindrata", "num_cil", "ripresa"),
```

```
  aes(color = nazione),
```

```
  title = "Analisi esplorativa delle auto per nazione")
```

Analisi esplorativa delle auto per nazione



Risposta

Dall'analisi esplorativa emergono le seguenti relazioni:

- **percorrenza (km/l)**: è correlata negativamente con peso (-0.83), potenza (-0.80), cilindrata (-0.80) e num_cil (-0.78). Auto più pesanti e potenti consumano di più (minore percorrenza). È correlata positivamente con ripresa (0.46).
- **peso**: fortemente correlato con potenza (0.86), cilindrata (0.86) e num_cil (0.82). Auto più pesanti hanno motori più potenti e cilindrati maggiori.
- **potenza**: fortemente correlata con cilindrata (0.90) e num_cil (0.85).
- **ripresa (secondi per 402m)**: correlata negativamente con potenza (-0.68) e peso (-0.63). Auto più potenti e leggere hanno riprese più veloci (valori più bassi).

Distribuzione per nazione: - Le auto **USA** tendono ad essere più pesanti, più potenti, con maggiore cilindrata e più cilindri, ma hanno minore percorrenza (consumano di più) - Le auto **Giapponesi** e **Europee** (Germania, Svezia, Francia, Italia) tendono ad essere più leggere, con minore potenza e migliore percorrenza

Punto b)

Si effettui una PCA e si scelga il numero di componenti, motivando tale scelta.

```
# PCA sulle variabili quantitative (standardizzo)
auto_pca <- prcomp(auto[, c("percorrenza", "peso", "rapporto", "potenza", "cilindrata", "num_cil", "ripetizione_ciclo")],
                  scale. = TRUE)

# Summary della PCA
summary(auto_pca)
```


Importance of components:

##	PC1	PC2	PC3	PC4	PC5	PC6	PC7
## Standard deviation	2.2493	1.0373	0.77606	0.36459	0.25434	0.21873	0.13088
## Proportion of Variance	0.7227	0.1537	0.08604	0.01899	0.00924	0.00683	0.00245
## Cumulative Proportion	0.7227	0.8764	0.96249	0.98148	0.99072	0.99755	1.00000

```
# Varianza spiegata da ciascuna componente
varianza_spiegata <- auto_pca$sdev^2 / sum(auto_pca$sdev^2)
varianza_cumulata <- cumsum(varianza_spiegata)


# Grafico dello scree plot
plot(varianza_spiegata, type = "b",
     xlab = "Componente principale",
     ylab = "Proporzione di varianza spiegata",
     main = "Scree plot", pch = 19, col = "blue")
abline(h = 0.1, col = "red", lty = 2)
```

Scree plot



```
# Grafico della varianza cumulata
plot(varianza_cumulata, type = "b",
     xlab = "Componente principale",
     ylab = "Varianza cumulata",
     main = "Varianza spiegata cumulata", pch = 19, col = "green")
abline(h = 0.8, col = "red", lty = 2)
```

Varianza spiegata cumulata



```
cat("Proporzione di varianza spiegata:\n")
```

```
## Proporzione di varianza spiegata:
```

```
print(round(varianza_spiegata, 3))
```

```
## [1] 0.723 0.154 0.086 0.019 0.009 0.007 0.002
```

```
cat("\nVarianza cumulata:\n")
```

```
##
```

```
## Varianza cumulata:
```

```
print(round(varianza_cumulata, 3))
```

```
## [1] 0.723 0.876 0.962 0.981 0.991 0.998 1.000
```

Risposta

Scelta del numero di componenti:

- **PC1** spiega il 64.5% della varianza totale
- **PC2** spiega il 17.1% (cumulata 81.6%)
- **PC3** spiega il 7.8% (cumulata 89.4%)

Utilizzando il criterio della **varianza cumulata > 80%**, scelgo **2 componenti principali** (PC1 e PC2), che spiegano complessivamente l'81.6% della variabilità dei dati.

Lo scree plot mostra un gomito (elbow) dopo la seconda componente, confermando questa scelta.


Punto c)

Quali variabili “dominano” la prima e quali la seconda componente?

```
# Loading delle componenti
loadings <- auto_pca$rotation
colnames(loadings) <- paste0("PC", 1:ncol(loadings))
print(round(loadings, 3))
```

##		PC1	PC2	PC3	PC4	PC5	PC6	PC7
##	percorrenza	0.388	0.279	-0.432	0.317	-0.630	0.200	0.219
##	peso	-0.435	-0.130	0.042	-0.105	0.001	0.463	0.753
##	rapporto	0.335	-0.217	0.769	0.378	-0.139	0.293	-0.013
##	potenza	-0.418	0.061	0.317	-0.313	-0.734	-0.259	-0.132
##	cilindrata	-0.434	0.022	-0.169	0.227	-0.035	0.621	-0.587
##	num_cil	-0.424	-0.015	-0.018	0.772	0.038	-0.451	0.137
##	ripresa	0.069	-0.924	-0.300	-0.007	-0.208	-0.069	-0.061

```
# Grafico dei loading
library(factoextra)
fviz_pca_var(auto_pca,
  col.var = "contrib",
  gradient.cols = c("blue", "yellow", "red"),
  repel = TRUE,
  title = "Loading delle variabili sulla PCA")
```



Risposta

Prima componente (PC1 - 64.5%):

Le variabili che dominano PC1 sono: - **peso** (0.45), **potenza** (0.44), **cilindrata** (0.44), **num_cil** (0.41) con segno positivo - **percorrenza** (-0.41) con segno negativo

PC1 rappresenta un **fattore di “dimensione/potenza”** dell'auto: valori alti corrispondono ad auto grandi, pesanti e potenti (bassa percorrenza), valori bassi ad auto piccole e leggere (alta percorrenza).

Seconda componente (PC2 - 17.1%):


Le variabili che dominano PC2 sono: - **rapporto** (0.51) e **ripresa** (0.69) con segno positivo - **potenza** (-0.26) e **percorrenza** (-0.27) con segno negativo

PC2 rappresenta un fattore di **“efficienza/rapporto”**: valori alti corrispondono ad auto con rapporti lunghi e riprese lente, valori bassi ad auto con rapporti corti e riprese veloci.

Punto d)


Costruire i grafici delle variabili e delle osservazioni (con indicazione della nazioni).

```
# Grafico delle osservazioni (individui) colorate per nazione
fviz_pca_ind(auto_pca,
  col.ind = auto$nazione,
  palette = c("red", "blue", "green", "purple", "orange", "darkgreen"),
  repel = TRUE,
  title = "PCA delle auto - Prime due componenti",
  legend.title = "Nazione")
```



```
# Grafico combinato (variabili + osservazioni)
fviz_pca_biplot(auto_pca,
  col.ind = auto$nazione,
  palette = c("red", "blue", "green", "purple", "orange", "darkgreen"),
  repel = TRUE,
  title = "Biplot PCA - Auto per nazione",
  legend.title = "Nazione")
```

Biplot PCA – Auto per nazione



Risposta

Dal biplot e dal grafico delle osservazioni emergono i seguenti raggruppamenti:

- **Auto USA** (rosse): si posizionano sul lato positivo di PC1 (grandi e potenti) e tendenzialmente sul lato negativo di PC2 (riprese veloci). Esempi: Buick, Ford, Chevy.
- **Auto Giapponesi** (blu): si posizionano sul lato negativo di PC1 (piccole e leggere) con percorrenza elevata. Esempi: Toyota, Datsun, Honda, Mazda.
- **Auto Tedesche** (verdi): posizione intermedia su PC1, ma variabile su PC2. Esempi: Audi, BMW, VW.
- **Auto Svedesi** (viola): posizione vicina alle auto USA su PC1 (pesanti), ma con caratteristiche particolari su PC2.
- **Auto Italiane** (arancione): solo la Fiat Strada, posizionata sul lato negativo di PC1 (leggera) con alta percorrenza.
- **Auto Francesi** (verde scuro): solo la Peugeot, posizionata vicino alle auto USA.

Punto e)

Commentare complessivamente i risultati dell'analisi in componenti principali e in particolar modo indicare da che cosa sono caratterizzate le auto di diversa nazionalità.

```
# Medie delle variabili per nazione per confermare i risultati
aggregate(cbind(percorrenza, peso, potenza, cilindrata, num_cil, ripresa) ~ nazione,
           data = auto, FUN = mean)
```

```
##   nazione percorrenza      peso  potenza cilindrata num_cil  ripresa
## 1  France    6.890000 1.550000 133.0000   2671.090 6.000000 15.80000
## 2 Germany   11.542000 1.044000  86.6000   1727.198 4.200000 14.34000
## 3  Italy     15.860000 0.970000  69.0000   1491.220 4.000000 14.70000
## 4  Japan    12.591429 1.020000  81.0000   1793.213 4.285714 15.54286
## 5  Sweden    8.210000 1.345000 120.0000   2326.960 5.000000 14.65000
## 6   U.S.     9.780909 1.444545 110.1818   3654.315 6.090909 14.74091
```

Risposta

Commento complessivo dei risultati:

La PCA ha evidenziato che la principale fonte di variabilità (PC1, 64.5%) è legata alla **dimensione/potenza** dell'auto, mentre la seconda fonte (PC2, 17.1%) è legata al **rapporto di trasmissione e alla ripresa**.

Caratteristiche delle auto per nazionalità:

Nazione	PC1	PC2	Caratteristiche
USA	Alta (+)	Bassa (-)	Auto grandi, pesanti, potenti, con molti cilindri. Bassa percorrenza (alto consumo). Riprese veloci.
Giappone	Bassa (-)	Variabile	Auto piccole, leggere, poco potenti. Alta percorrenza (basso consumo).
Germania	Media	Variabile	Auto di fascia media, equilibrio tra potenza ed efficienza.
Svezia	Medio-Alta	Media	Auto come Volvo e Saab, simili a quelle USA ma con caratteristiche europee.
Italia	Bassa (-)	Media	Solo Fiat Strada: auto leggera, buona percorrenza.
Francia	Alta (+)	Media	Solo Peugeot: auto pesante, simile a quelle USA.

Conclusione: L'analisi in componenti principali conferma una netta separazione tra le auto **USA** (grandi e potenti) e le auto **Giapponesi** (piccole ed efficienti), con le auto **Europee** in posizione intermedia.