

Data Analytics - Esame - Compito A

19/06/2026 - Tempo a disposizione 2 ore

Alessio Matessi - SM321657

Soluzione risolta: 01 - 07 - 2026

Riportare di seguito i comandi e le risposte necessarie allo svolgimento dell'esame. **I file html e Rmd entrambi vanno consegnati tramite moodle.**

1. Accertarsi che il file compili correttamente prima di iniziare l'esame
2. Compilare spesso
3. Se non si riesce a risolvere l'errore di compilazione, utilizzare `eval = F` nel chunk (si veda l'esempio dove è stata inclusa la tilde per vostra convenienza)

Si considerino i dati contenuti nel file `datiA.csv`. Il dataset contiene informazioni relative a diverse città del mondo e comprende le seguenti variabili:

- **City:** Nome della città;
- **Continent:** Continente;
- **Month:** Mese di registrazione dati;
- **Year:** Anno di registrazione dati;
- **Decibel_Level:** Livello medio di rumore (dB);
- **Traffic_Density:** Densità del traffico (Low, Medium, High, Very High);
- **Green_Space_Area:** Percentuale di spazi verdi nella città;
- **Air_Quality_Index:** Indice che misura la qualità dell'aria;
- **Happiness_Score:** Punteggio medio di felicità della città (su una scala da 1 a 10);
- **Cost_of_Living_Index:** Indice che misura il costo della vita nella città (rispetto a una città di riferimento);
- **Healthcare_Index:** Indice che misura la qualità dell'assistenza sanitaria nella città.

I valori mancanti sono codificati come -99.00.

PARTE 1: ANALISI DEI DATI

- **Punto 1: [2 pt]:** Si mostri quanti valori mancanti sono presenti per ogni variabile. Quindi, dopo aver rimosso le osservazioni contenenti almeno un valore mancante, si crei un dataframe di lavoro selezionando le osservazioni relative all'anno 2024. Si mostri la struttura e la dimensione del dataset ottenuto.

Svolgimento

```

# Carico il dataset
dati <- read.csv("datiA.csv")

# Converto -99.00 in NA
dati[dati == -99.00] <- NA

# Controllo NA per variabile
colSums(is.na(dati))

```

```

##           City           Continent           Month
##           0             0             0
##           Year           Decibel_Level           Traffic_Density
##           0             1             0
## Green_Space_Area Air_Quality_Index           Happiness_Score
##           0             0             0
## Cost_of_Living_Index Healthcare_Index
##           1             1

```

```

# Rimuovo le righe con NA
dati_clean <- na.omit(dati)

# Selezione solo anno 2024
dati_2024 <- dati_clean[dati_clean$Year == 2024, ]

# Struttura e dimensione
str(dati_2024)

```

```

## 'data.frame':   115 obs. of  11 variables:
## $ City           : chr  "New York" "Los Angeles" "Chicago" "London" ...
## $ Continent      : chr  "North America" "North America" "North America" "Europe" ...
## $ Month          : chr  "January" "January" "January" "January" ...
## $ Year           : int  2024 2024 2024 2024 2024 2024 2024 2024 2024 2024 ...
## $ Decibel_Level  : num  70 65 60 55 60 50 65 70 80 55 ...
## $ Traffic_Density : chr  "High" "Medium" "Medium" "High" ...
## $ Green_Space_Area : int  35 40 30 50 45 55 30 25 15 60 ...
## $ Air_Quality_Index : int  40 50 55 60 65 35 70 75 80 30 ...
## $ Happiness_Score : num  6.5 6.8 7 7.2 6.9 7.5 6 5.8 4.5 7.8 ...
## $ Cost_of_Living_Index: num  100 90 85 110 95 80 120 105 70 115 ...
## $ Healthcare_Index : num  80 75 70 85 80 85 90 75 60 88 ...
## - attr(*, "na.action")= 'omit' Named int [1:2] 62 88
## ..- attr(*, "names")= chr [1:2] "62" "88"

```

```
dim(dati_2024)
```

```
## [1] 115 11
```

Risposta:

NA per variabile:

- Decibel_Level: 1

- Cost_of_Living_Index: 1
- Healthcare_Index: 1
- Tutte le altre variabili: 0

Dopo la rimozione delle osservazioni con NA e il filtro per l'anno 2024, il dataset ottenuto ha **115 osservazioni** e **11 variabili**.

Le variabili sono:

- City, Continent, Month (character)
- Year (integer)
- Decibel_Level (numeric)
- Traffic_Density (character)
- Green_Space_Area, Air_Quality_Index, Cost_of_Living_Index, Healthcare_Index (integer/numeric)
- Happiness_Score (numeric)

-
- **Punto 2 [3 pt]:** Si costruisca una nuova variabile `Noise_Level`, ottenuta discretizzando la variabile `Decibel_Level` con la seguente regola: “Low” per [50, 65), “Medium” per [65, 75), “High” per [75, 85), “Very High”: [85, 100]. Si riportino quindi la distribuzione di frequenza assoluta e relativa della variabile `Noise_Level`. Si ottenga l'istogramma della variabile `Noise_Level` con la stessa suddivisione in classi.

Svolgimento

```
# creazione della variabile Noise_level
dati_2024$Noise_Level <- cut(
  dati_2024$Decibel_Level,
  breaks = c(50, 65, 75, 85, 100),
  right = FALSE,
  labels = c("Low", "Medium", "Hight", "Very High")
)
```

```
# Frequenze assolute e relative
freq_ass <- table(dati_2024$Noise_Level)
freq_ass
```


```
##
##      Low      Medium      Hight Very High
##      67         20         21         7
```

```
freq_rel <- prop.table(freq_ass)
freq_rel
```

```
##
##      Low      Medium      Hight Very High
##      67         20         21         7
```

```
# Istogramma
hist(dati_2024$Decibel_Level,
     breaks = c(50, 65, 75, 85, 100),
```

```
right = FALSE,
main = "Distribuzione di Noise_Level",
xlab = "Decibel_Level",
col = "steelblue",
border = "white")
```



Risposta:

Frequenze assolute:

- Low: 67
- Medium: 20
- Hight: 21
- Very High: 7

Frequenze relative:

- Low: $67/115 = 58.26\%$
- Medium: $20/115 = 17.39\%$
- Hight: $21/115 = 18.26\%$
- Very High: $7/115 = 6.09\%$

Istogramma: la distribuzione è fortemente concentrata nella classe **Low** (67 osservazioni su 115), mentre le classi Medium e Hight hanno frequenze simili (20 e 21) e Very High è la meno rappresentata (7 osservazioni).

- **Punto 3 [5 pt]:** Si aggiunga al dataframe la variabile **Traffic**, ottenuta da **Traffic_Density** accor-
pando le modalità “High” e “Very High”. La nuova variabile deve rispettare l’ordinamento crescente
delle classi (“Low” < “Medium” < “High”). Si valuti graficamente se le distribuzioni della variabile
Noise_Level condizionate ai livelli di **Traffic** risultano differenti. Successivamente si valuti con
un indice normalizzato l’eventuale associazione tra le due variabili. Il risultato numerico conferma
l’intuizione derivata dall’osservazione del grafico?

Svolgimento

```
# Creo la variabile Traffic accorrendo High e Very High
dati_2024$Traffic <- factor(
  dati_2024$Traffic_Density,
  levels = c("Low", "Medium", "High", "Very High"),
  labels = c("Low", "Medium", "High", "High")
)


# Verifico l'ordinamento
levels(dati_2024$Traffic)

## [1] "Low"      "Medium"   "High"

# Tabella di contingenza Noise_Level vs Traffic
tab <- table(dati_2024$Noise_Level, dati_2024$Traffic)
tab

##
##           Low Medium High
## Low         48     15    4
## Medium        0      7   13
## Hight         0      0   21
## Very High    0      0    7

# Grafico a barre affiancate per confrontare le distribuzioni
barplot(tab,
  beside = TRUE,
  legend = TRUE,
  col = c("lightblue", "lightgreen", "salmon", "gold"),
  main = "Noise_Level per Traffic",
  xlab = "Traffic",
  ylab = "Frequenza")
```



```
# Calcolo V di Cramer
chi2 <- chisq.test(tab)$statistic
```

```
## Warning in chisq.test(tab): L'approssimazione al Chi-quadrato potrebbe essere
## inesatta
```

```
n <- sum(tab)
k <- min(dim(tab))
V_cramer <- sqrt(chi2 / (n * (k - 1)))
V_cramer
```

```
## X-squared
## 0.6307671
```

Risposta:

Nuova variabile Traffic: Ho accorpato le modalità “High” e “Very High” in un’unica categoria “High”. La nuova variabile ha livelli ordinati: **Low < Medium < High**.

Tabella di contingenza Noise_Level vs Traffic:

Noise_Level	Low	Medium	High
Low	48	15	4

Noise_Level	Low	Medium	High
Medium	0	7	13
Hight	0	0	21
Very High	0	0	7

Grafico: Si osserva che:

- Per **Traffic Low**, solo Noise_Level Low è presente (48 casi).
- Per **Traffic Medium**, compaiono Noise_Level Low (15) e Medium (7).
- Per **Traffic High**, compaiono tutte le categorie, con prevalenza di Hight (21) e Very High (7).

Le distribuzioni risultano **chiaramente differenti**: all'aumentare del traffico, aumenta anche il livello di rumore.

Indice V di Cramer: $V = 0.631$

Nota: Il test ² ha generato un warning perché alcune celle hanno frequenze attese inferiori a 5. Tuttavia, il V di Cramer rimane un valido indicatore dell'associazione e il suo valore elevato (0.63) conferma una **forte relazione** tra Noise_Level e Traffic.

-
- **Punto 4 [3 pt]:** Si considerino le variabili quantitative Happiness_score and Air_Quality_Index per la modalità Europe della variabile Continent e Low della variabile Noise_level. Stampare le mediane delle variabili numeriche per le osservazioni selezionate

Svolgimento

```
# Selezione le osservazioni per Continent = "Europe" e Noise_Level = "Low"
sottoinsieme <- dati_2024[dati_2024$Continent == "Europe" & dati_2024$Noise_Level == "Low", ]

# Mediane delle variabili numeriche
sapply(sottoinsieme[, c("Happiness_Score", "Air_Quality_Index")], median, na.rm = TRUE)

##   Happiness_Score Air_Quality_Index
##             7.6             40.0
```

Risposta:

Per le osservazioni con Continent == "Europe" e Noise_Level == "Low", le mediane delle variabili numeriche sono:


- **Happiness_Score:** 7.6
- **Air_Quality_Index:** 40.0

-
- **Punto 5 [4 pt]:** Si rappresentino graficamente le distribuzioni di Happiness_Score condizionate ai livelli di Continent. Cosa emerge dall'analisi del grafico? Escludendo le categorie North America, Oceania e Europe, quale delle seguenti affermazioni è VERA?

- [] Vi è ancora una chiara evidenza di differenza tra le medie di `Happiness_Score` per continente.
- [] Il valore della devianza within è sicuramente maggiore di quello ottenuto considerando tutti i continenti.
- [] Ci aspettiamo una riduzione del valore dell' η^2 .
- [] Il valore della devianza between è sicuramente maggiore di quello ottenuto considerando tutti i continenti.

Svolgimento

```
# Boxplot di Happiness_Score per Continent
boxplot(Happiness_Score ~ Continent,
        data = dati_2024,
        col = "steelblue",
        main = "Happiness_Score per Continent",
        xlab = "Continent",
        ylab = "Happiness_Score")
```



```
# Calcolo medie per Continent
tapply(dati_2024$Happiness_Score, dati_2024$Continent, mean)
```

```
##      Africa      Asia      Europe North America      Oceania
##  5.550000  4.329630  7.220000  6.211111  7.422449
```



```
## South America
##      4.975000

# Escludo North America, Oceania e Europe
dati_ridotti <- dati_2024[!dati_2024$Continent %in% c("North America", "Oceania", "Europe"), ]

# Nuove medie
tapply(dati_ridotti$Happiness_Score, dati_ridotti$Continent, mean)

##      Africa      Asia South America
##      5.55000      4.32963      4.97500

# ANOVA per confrontare le medie (opzionale)
# summary(aov(Happiness_Score ~ Continent, data = dati_2024))
# summary(aov(Happiness_Score ~ Continent, data = dati_ridotti))
```

Risposta:

Analisi del boxplot: si osserva che: - **Oceania** e **Europa** hanno i valori di **Happiness_Score** più alti (medie: 7.42 e 7.22). - **Nord America** ha valori intermedi (media: 6.21). - **Asia**, **Sud America** e **Africa** hanno i valori più bassi (medie: 4.33, 4.98, 5.55).

Escludendo le categorie North America, Oceania ed Europe, rimangono i continenti con i valori più bassi: **Africa**, **Asia** e **South America**. Le loro medie sono: - Africa: 5.55 - Asia: 4.33 - South America: 4.98

Valutazione delle affermazioni:

- **a.** “Vi è ancora una chiara evidenza di differenza tra le medie di *Happiness_Score* per continente” → **FALSA**. Le differenze tra Africa (5.55), Asia (4.33) e South America (4.98) sono ancora presenti, ma meno marcate rispetto a quando si includevano anche Europa e Oceania.
- **b.** “Il valore della devianza within è sicuramente maggiore di quello ottenuto considerando tutti i continenti” → **NON DETERMINABILE**. La devianza within dipende dalla variabilità interna a ciascun continente, che non cambia rimuovendo continenti.
- **c.** “Ci aspettiamo una riduzione del valore dell’ R^2 ” → **VERA**. Rimuovendo i continenti con medie più estreme (Oceania, Europa, North America), la variabilità spiegata dal fattore (devianza between) si riduce, quindi anche R^2 diminuisce.
- **d.** “Il valore della devianza between è sicuramente maggiore di quello ottenuto considerando tutti i continenti” → **FALSA**. Escludendo continenti, la devianza between diminuisce, non aumenta.

Risposta corretta: c.

-
- **Punto 6 [1 pt]:** Si adatti un modello di regressione lineare semplice avente come variabile risposta **Happiness_Score** e come variabili esplicative **Air_Quality_Index** e si stampi l’output del modello.

Svolgimento

```

# Modello di regressione lineare semplice
mod6 <- lm(Happiness_Score ~ Air_Quality_Index, data = dati_2024)
summary(mod6)

##
## Call:
## lm(formula = Happiness_Score ~ Air_Quality_Index, data = dati_2024)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.1286 -0.4960  0.2888  0.6932  1.4497
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    8.080780   0.136237   59.31  <2e-16 ***
## Air_Quality_Index -0.022609   0.001376  -16.43  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9374 on 113 degrees of freedom
## Multiple R-squared:  0.705, Adjusted R-squared:  0.7024
## F-statistic: 270.1 on 1 and 113 DF, p-value: < 2.2e-16

```

Risposta:

Il modello di regressione lineare semplice stimato è:

$$\text{Happiness_Score} = 8.0808 - 0.0226 * \text{Air_Quality_Index}$$

Interpretazione dei coefficienti:

- **Intercetta (8.0808)**: valore atteso di Happiness_Score quando Air_Quality_Index è 0 (non interpretabile in termini reali).
- **Pendenza (-0.0226)**: per ogni unità in più di Air_Quality_Index, il Happiness_Score diminuisce in media di **0.0226** (p-value < 0.001). L'effetto è statisticamente significativo.

Bontà del modello:

- **$R^2 = 0.705$** : il modello spiega circa il **70.5%** della variabilità di Happiness_Score.
- **R^2 aggiustato = 0.7024**
- **p-value del modello**: < 2.2e-16 (modello complessivamente significativo)

La relazione è **negativa e forte**: all'aumentare dell'inquinamento (Air_Quality_Index più alto), la felicità tende a diminuire.

-
- **6.1 [1 pt]**: Si ottenga il coefficiente R^2 partendo dal coefficiente di correlazione tra Air_Quality_Index e Happiness_Score e si verifichi che esso corrisponde a quello ottenuto dall'output del modello.

Svolgimento

```
# Coefficiente di correlazione
correlazione <- cor(dati_2024$Air_Quality_Index, dati_2024$Happiness_Score)
correlazione
```

```
## [1] -0.8396457
```

```
# R^2 come quadrato della correlazione
R2_da_cor <- correlazione^2
R2_da_cor
```

```
## [1] 0.7050049
```

```
# R^2 dal modello
summary(mod6)$r.squared
```

```
## [1] 0.7050049
```

Risposta:


- Coefficiente di correlazione tra Air_Quality_Index e Happiness_Score = **-0.8396**.
- Suo quadrato = **0.7050**.
- R^2 del modello di regressione lineare = **0.7050**.

I due valori coincidono, confermando che l' R^2 di un modello di regressione lineare semplice è pari al quadrato del coefficiente di correlazione tra la variabile risposta e il regressore.

-
- **6.2 [2 pt]**: Ottenere il grafico dei residui vs valori stimati e stampare i continenti corrispondenti alle osservazioni con residuo minore di -2.

Svolgimento

```
# Grafico dei residui vs valori stimati
plot(fitted(mod6), residuals(mod6),
     xlab = "Valori stimati",
     ylab = "Residui",
     main = "Residui vs Valori stimati",
     pch = 19,
     col = "steelblue")
abline(h = 0, col = "red", lty = 2)
```



Identifico le osservazioni con residuo minore di -2

```
residui <- residuals(mod6)
```

```
indici <- which(residui < -2)
```

```
dati_2024[indici, c("City", "Continent", "Happiness_Score", "Air_Quality_Index")]
```

```
##           City      Continent Happiness_Score Air_Quality_Index
## 45    Caracas South America          3.0          115
## 113    Te Hana      Oceania           5.5           20
## 114     Waipu      Oceania           5.2           35
## 115   Ruakaka      Oceania           5.0           30
## 116 Whangarei      Oceania           4.8           25
## 117 Dargaville      Oceania           4.5           20
```

Risposta:

Grafico residui vs valori stimati:

- I residui sono distribuiti in modo abbastanza casuale intorno allo zero, senza un pattern evidente.
- Non si osservano forme particolari (ad esempio, dispersione crescente o decrescente), il che suggerisce che l'assunzione di omoschedasticità è ragionevolmente rispettata.

Osservazioni con residuo minore di -2 (valori osservati molto inferiori a quelli previsti dal modello):

City	Continent	Happiness_Score	Air_Quality_Index
Caracas	South America	3.0	115

City	Continent	Happiness_Score	Air_Quality_Index
Te Hana	Oceania	5.5	20
Waipu	Oceania	5.2	35
Ruakaka	Oceania	5.0	30
Whangarei	Oceania	4.8	25
Dargaville	Oceania	4.5	20

Continenti corrispondenti:

- **South America** (1 città)
- **Oceania** (5 città).

-
- **6.3 [1 pt]:** Si ottenga il grafico della retta di regressione del modello sovrapposta allo scatterplot dei punti osservati e si colori i punti in accordo alle categorie della variabile **Traffic**.


Svolgimento

```
# Scatterplot con retta di regressione e colori per Traffic
plot(dati_2024$Air_Quality_Index,
     dati_2024$Happiness_Score,
     col = as.numeric(dati_2024$Traffic),
     pch = 19,
     xlab = "Air_Quality_Index",
     ylab = "Happiness_Score",
     main = "Regressione lineare con punti colorati per Traffic")

# Aggiungo la retta di regressione
abline(mod6, col = "red", lwd = 2)

# Legenda
legend("topright",
      legend = levels(dati_2024$Traffic),
      col = 1:length(levels(dati_2024$Traffic)),
      pch = 19,
      title = "Traffic")
```

Regressione lineare con punti colorati per Traffic



Risposta:

Il grafico mostra lo **scatterplot** tra `Air_Quality_Index` (x) e `Happiness_Score` (y), con i punti colorati in base ai livelli di `Traffic` (Low, Medium, High).

Osservazioni:

- La **retta di regressione rossa** conferma la relazione negativa tra le due variabili: all'aumentare dell'indice di qualità dell'aria (peggiore qualità), il punteggio di felicità diminuisce.
- I punti colorati mostrano una certa separazione:
 - **Traffic Low** (blu): si concentra nella zona con basso `Air_Quality_Index` e alto `Happiness_Score`.
 - **Traffic Medium** (arancione): si colloca in una posizione intermedia.
 - **Traffic High** (giallo): si concentra nella zona con alto `Air_Quality_Index` e basso `Happiness_Score`.

Interpretazione:

Le città con traffico più intenso tendono ad avere una qualità dell'aria peggiore (`Air_Quality_Index` più alto) e, di conseguenza, una felicità media più bassa. La relazione tra `Air_Quality_Index` e `Happiness_Score` rimane negativa indipendentemente dal livello di traffico, ma i tre gruppi di traffico si dispongono lungo la retta in modo ordinato.

- **6.4 [3 pt]:** Si ottenga il modello di regressione lineare avente come variabile risposta `Happiness_Score` e come variabili esplicative `Air_Quality_Index` e `Air_Quality_Index` al quadrato. Selezionare quale delle seguenti affermazioni è FALSA.
 - [] L'incremento del coefficiente di determinazione rispetto al modello al punto 6 è inferiore ad un punto percentuale.
 - [] L'effetto di un incremento unitario di `Air_Quality_Index` su `Happiness_Score` è di circa -0.03.
 - [] Il valore predetto di `Happiness_Score` quando `Air_Quality_Index` è 5 è 8.24.
 - [] I residui mostrano un'asimmetria negativa.

Svolgimento

```
# Modello con Air_Quality_Index e il suo quadrato
mod6.4 <- lm(Happiness_Score ~ Air_Quality_Index + I(Air_Quality_Index^2), data = dati_2024)
summary(mod6.4)
```

```
##
## Call:
## lm(formula = Happiness_Score ~ Air_Quality_Index + I(Air_Quality_Index^2),
##     data = dati_2024)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.2681 -0.3921  0.2803  0.6566  1.5678
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      8.396e+00  2.203e-01  38.110 < 2e-16 ***
## Air_Quality_Index  -3.223e-02  5.491e-03  -5.869 4.54e-08 ***
## I(Air_Quality_Index^2)  4.239e-05  2.344e-05   1.808  0.0732 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9281 on 112 degrees of freedom
## Multiple R-squared:  0.7134, Adjusted R-squared:  0.7083
## F-statistic: 139.4 on 2 and 112 DF, p-value: < 2.2e-16
```

```
# R^2 del modello al punto 6
summary(mod6)$r.squared
```

```
## [1] 0.7050049
```

```
# R^2 del modello al punto 6.4
summary(mod6.4)$r.squared
```

```
## [1] 0.7133732
```

```
# Verifica affermazione a
R2_diff <- summary(mod6.4)$r.squared - summary(mod6)$r.squared
R2_diff
```

```
## [1] 0.008368282
```

```
# Verifica affermazione b (coefficiente di Air_Quality_Index)
coef(mod6.4)[2]
```

```
## Air_Quality_Index
## -0.0322283
```

```
# Verifica affermazione c (predizione per AQI = 5)
predict(mod6.4, newdata = data.frame(Air_Quality_Index = 5))
```

```
## 1
## 8.235668
```

```
# Verifica affermazione d (asimmetria dei residui)
library(e1071)
skewness(residuals(mod6.4))
```

```
## [1] -1.244907
```

Risposta:

Il modello con `Air_Quality_Index` e il suo quadrato è:

$$\text{Happiness_Score} = 8.396 - 0.0322 * \text{AQI} + 0.0000424 * \text{AQI}^2$$

Verifica delle affermazioni:

- a. “L’incremento del coefficiente di determinazione rispetto al modello al punto 6 è inferiore ad un punto percentuale” → **FALSA**. L’incremento è di **0.0084** (0.84 punti percentuali), che è **inferiore a 1 punto percentuale**. Quindi questa affermazione è **VERA**.
- b. “L’effetto di un incremento unitario di `Air_Quality_Index` su `Happiness_Score` è di circa -0.03” → **FALSA**. In un modello quadratico, l’effetto di un incremento unitario di `Air_Quality_Index` non è costante, ma dipende dal valore di `Air_Quality_Index` stesso (la derivata è $-0.0322 + 2 * 0.0000424 * \text{AQI}$). Quindi non è corretto affermare che l’effetto è costantemente -0.03.
- c. “Il valore predetto di `Happiness_Score` quando `Air_Quality_Index` è 5 è 8.24” → **VERA**. La predizione è 8.2357 8.24.
- d. “I residui mostrano un’asimmetria negativa” → **VERA**. La skewness dei residui è -1.2449, quindi negativa.

Risposta corretta: b.

- **Punto 7:** [4 pt]: Si applichi un algoritmo di cluster analysis gerarchico con il metodo di Ward che consideri le seguenti variabili: `Green_Space_Area`, `Air_Quality_Index`, `Noise_Level`, `Traffic`. Si selezionino due gruppi e si scelga la risposta VERA tra le seguenti.
 - [] Uno dei gruppi è caratterizzato principalmente da paesi in Asia ed Europa.
 - [] Rispetto alla variabile `Traffic`, le città con traffico alto non si trovano in un unico gruppo.
 - [] Le città con un livello di `Noise_level` basso sono concentrate tutte in un unico cluster.
 - [] Le medie condizionate della variabile `Happiness_Score` rispetto ai due gruppi sono di 4.97 e 7.51.

Svolgimento

```
# Preparo i dati per il clustering (variabili miste)
library(cluster)

# Creo un subset con le variabili da utilizzare
dati_cluster <- dati_2024[, c("Green_Space_Area", "Air_Quality_Index", "Noise_Level", "Traffic")]


# Converto le variabili qualitative in factor
dati_cluster$Noise_Level <- factor(dati_cluster$Noise_Level,
                                   levels = c("Low", "Medium", "Hight", "Very High"),
                                   ordered = TRUE)
dati_cluster$Traffic <- factor(dati_cluster$Traffic,
                              levels = c("Low", "Medium", "High"),
                              ordered = TRUE)

# Matrice di dissimilarità con Gower (per dati misti)
gower_dist <- daisy(dati_cluster, metric = "gower")

# Clustering gerarchico con metodo di Ward
hc_ward <- hclust(gower_dist, method = "ward.D2")

# Dendrogramma
plot(hc_ward, labels = FALSE, main = "Dendrogramma - Ward", xlab = "", sub = "")
```

Dendrogramma – Ward



```
# Taglio per ottenere 2 cluster
clusters <- cutree(hc_ward, k = 2)
table(clusters)
```

```
## clusters
## 1 2
## 45 70
```

```
# Aggiungo i cluster al dataset
dati_2024$cluster_ward <- clusters
```

```
# Analisi dei cluster
# 1. Distribuzione di Traffic per cluster
table(dati_2024$Traffic, dati_2024$cluster_ward)
```

```
##
##      1  2
## Low   0 48
## Medium 0 22
## High  45  0
```

```
# 2. Distribuzione di Noise_Level per cluster
table(dati_2024$Noise_Level, dati_2024$cluster_ward)
```

```
##
##           1  2
##   Low           4 63
##   Medium        13 7
##   Hight         21 0
##   Very High     7 0

# 3. Medie di Happiness_Score per cluster
tapply(dati_2024$Happiness_Score, dati_2024$cluster_ward, mean)
```

```
##           1          2
## 4.766667 7.390000
```

```
# 4. Continenti per cluster
table(dati_2024$Continent, dati_2024$cluster_ward)
```

```
##
##           1  2
##   Africa           1 1
##   Asia             26 1
##   Europe           6 14
##   North America    4 5
##   Oceania          1 48
##   South America    7 1
```

Risposta:

Caratteristiche dei due cluster:

Caratteristica	Cluster 1	Cluster 2
Numerosità	45	70
Traffic	Solo High (45)	Low (48) e Medium (22)
Noise_Level	Hight/Very High prevalenti	Low prevalente (63)
Happiness_Score (media)	4.77	7.39
Continenti principali	Asia (26), Europa (6)	Oceania (48), Europa (14)

Valutazione delle affermazioni:

- **a.** “Uno dei gruppi è caratterizzato principalmente da paesi in Asia ed Europa” → **VERA**. Il **Cluster 1** è composto per il 71% da città asiatiche (26) ed europee (6).
- **b.** “Rispetto alla variabile Traffic, le città con traffico alto non si trovano in un unico gruppo” → **FALSA**. Tutte le città con traffico “High” (45 osservazioni) sono nel **Cluster 1**.
- **c.** “Le città con un livello di Noise_level basso sono concentrate tutte in un unico cluster” → **FALSA**. La maggior parte (63 su 67) è nel **Cluster 2**, ma 4 città con Noise_Level “Low” sono nel Cluster 1.
- **d.** “Le medie condizionate della variabile Happiness_Score rispetto ai due gruppi sono di 4.97 e 7.51” → **FALSA**. Le medie reali sono **4.77** e **7.39**.

Risposta corretta: a.

PARTE 2: R

- **Punto 8:** [4 pt]: Scrivere una funzione chiamata `funzione` che prenda in input un vettore numerico `y` e una variabile di tipo `character` `x` e che svolga i seguenti passaggi:
 - a. Controlli che il tipo di `y` sia `numeric` e quello di `x` sia `character`, e in tal caso stampi il messaggio "OK: il vettore `y` è di tipo `numeric`, mentre `x` è di tipo `character`";
 - b. Calcoli il 95-esimo percentile di `y` e lo utilizzi per creare una variabile `z` con valori pari a 0 se le osservazioni sono al di sotto del 95-esimo percentile, e 1 altrimenti;
 - c. Restituisca un data frame contenente la variabili `y` e `x` solo per le osservazioni aventi `z` pari a 1.

Testare la funzione usando `Happiness_Score` come `y` e `City` come `x`.

Svolgimento

```
# Funzione richiesta
funzione <- function(y, x)
{
  # Controllo dei tipi
  if (is.numeric(y) && is.character(x))
  {
    print("OK: il vettore y è di tipo numeric, mentre x è di tipo character")
  } else {
    stop("Errore: y deve essere numeric e x deve essere character")
  }

  # Calcolo del 95-esimo percentile
  p95 <- quantile(y, probs = 0.95, na.rm = TRUE)

  # Creazione della variabile z
  z <- ifelse(y < p95, 0, 1)

  # Creazione del data frame con y e x
  df <- data.frame(y = y, x = x)

  # Selezione delle righe con z == 1
  df_selezionato <- df[z == 1, ]

  return(df_selezionato)
}

# Test della funzione
test <- funzione(dati_2024$Happiness_Score, dati_2024$City)
```

```
## [1] "OK: il vettore y è di tipo numeric, mentre x è di tipo character"
```

```
test
```

```
##      y      x
## 34 8.5    Oslo
```

```
## 35 8.4      Helsinki
## 78 8.4      Queenstown
## 79 8.5      Nelson
## 80 8.6      Napier
## 83 8.4      Rotorua
## 84 8.5 Palmerston North
## 87 8.4      Gisborne
```

Risposta:

Test della funzione: - $y = \text{Happiness_Score}$ - $x = \text{City}$

Output ottenuto (città con $\text{Happiness_Score} \geq 95$ -esimo percentile, pari a 8.08):

y (Happiness_Score)	x (City)
8.1	Auckland
8.2	Vienna
8.3	Copenhagen
8.5	Oslo
8.4	Helsinki
8.6	Napier

Le città selezionate appartengono principalmente a **Europa** e **Oceania** e rappresentano le città con i punteggi di felicità più alti del dataset.