

Data Analytics - Esame - Compito B

19/06/2026 - Tempo a disposizione 2 ore

Alessio Matessi - SM321657

Soluzione risolta: 02 - 07 - 2026

Riportare di seguito i comandi e le risposte necessarie allo svolgimento dell'esame. **I file html e Rmd entrambi vanno consegnati tramite moodle.**

1. Accertarsi che il file compili correttamente prima di iniziare l'esame
2. Compilare spesso
3. Se non si riesce a risolvere l'errore di compilazione, utilizzare `eval = F` nel chunk (si veda l'esempio dove è stata inclusa la tilde per vostra convenienza)

Si considerino i dati contenuti nel file `datiB.csv`. Il dataset contiene informazioni relative a diverse città del mondo e comprende le seguenti variabili:

- **City:** Nome della città;
- **Continent:** Continente;
- **Month:** Mese di registrazione dati;
- **Year:** Anno di registrazione dati;
- **Decibel_Level:** Livello medio di rumore (dB);
- **Traffic_Density:** Densità del traffico (Low, Medium, High, Very High);
- **Green_Space_Area:** Percentuale di spazi verdi nella città;
- **Air_Quality_Index:** Indice che misura la qualità dell'aria;
- **Happiness_Score:** Punteggio medio di felicità della città (su una scala da 1 a 10);
- **Cost_of_Living_Index:** Indice che misura il costo della vita nella città (rispetto a una città di riferimento);
- **Healthcare_Index:** Indice che misura la qualità dell'assistenza sanitaria nella città.

I valori mancanti sono codificati come ?.

PARTE 1: ANALISI DEI DATI

- **Punto 1: [2 pt]:** Si mostri quanti valori mancanti sono presenti per ogni variabile. Quindi, dopo aver rimosso le osservazioni contenenti almeno un valore mancante, si crei un dataframe di lavoro selezionando le osservazioni relative all'anno 2024. Si mostri la struttura e la dimensione del dataset ottenuto.

Svolgimento

```
# Carico il dataset
dati <- read.csv("datiB.csv")

# Converto "?" in NA
dati[dati == "?"] <- NA

# Converto le colonne numeriche (che sono lette come character a causa di "?")
dati$Decibel_Level <- as.numeric(dati$Decibel_Level)
dati$Green_Space_Area <- as.numeric(dati$Green_Space_Area)
dati$Air_Quality_Index <- as.numeric(dati$Air_Quality_Index)
dati$Happiness_Score <- as.numeric(dati$Happiness_Score)
dati$Cost_of_Living_Index <- as.numeric(dati$Cost_of_Living_Index)
dati$Healthcare_Index <- as.numeric(dati$Healthcare_Index)

# Controllo NA per variabile
colSums(is.na(dati))
```

```
##           City           Continent           Month
##           0             0             0
##           Year           Decibel_Level           Traffic_Density
##           0             0             0
## Green_Space_Area Air_Quality_Index           Happiness_Score
##           0             0             0
## Cost_of_Living_Index Healthcare_Index
##           0             0
```

```
# Rimuovo le righe con NA
dati_clean <- na.omit(dati)

# Selezione solo anno 2024
dati_2024 <- dati_clean[dati_clean$Year == 2024, ]

# Struttura e dimensione
str(dati_2024)
```

```
## 'data.frame':   117 obs. of  11 variables:
## $ City          : chr  "New York" "Los Angeles" "Chicago" "London" ...
## $ Continent     : chr  "North America" "North America" "North America" "Europe" ...
## $ Month         : chr  "January" "January" "January" "January" ...
## $ Year          : int   2024 2024 2024 2024 2024 2024 2024 2024 2024 ...
## $ Decibel_Level : num   70 65 60 55 60 50 65 70 80 55 ...
## $ Traffic_Density : chr  "High" "Medium" "Medium" "High" ...
## $ Green_Space_Area : num   35 40 30 50 45 55 30 25 15 60 ...
## $ Air_Quality_Index : num   40 50 55 60 65 35 70 75 80 30 ...
## $ Happiness_Score : num   6.5 6.8 7 7.2 6.9 7.5 6 5.8 4.5 7.8 ...
## $ Cost_of_Living_Index: num  100 90 85 110 95 80 120 105 70 115 ...
## $ Healthcare_Index : num   80 75 70 85 80 85 90 75 60 88 ...
```

```
dim(dati_2024)
```

```
## [1] 117 11
```

Risposta:

NA per variabile: tutte le variabili hanno **0** valori mancanti.

Dopo il filtro per l'anno 2024, il dataset ottenuto ha **117 osservazioni** e **11 variabili**.

Le variabili sono:

- City, Continent, Month (character)
- Year (integer)
- Decibel_Level (numeric)
- Traffic_Density (character)
- Green_Space_Area, Air_Quality_Index, Cost_of_Living_Index, Healthcare_Index (numeric)
- Happiness_Score (numeric)

-
- **Punto 2 [3 pt]:** Si costruisca una nuova variabile `Noise_Level`, ottenuta discretizzando la variabile `Decibel_Level` con la seguente regola: “Low” per [50, 62.5), “Medium” per [62.5, 75), “High” per [75, 87.5), “Very High”: [87.5, 100]. Si riportino quindi la distribuzione di frequenza assoluta e relativa della variabile `Noise_Level`. Si ottenga l’istogramma della variabile `Noise_Level` con la stessa suddivisione in classi.

Svolgimento

```
# Creazione della variabile Noise_level
dati_2024$Noise_Level <- cut(
  dati_2024$Decibel_Level,
  breaks = c(50, 62.5, 75, 87.5, 100),
  right = FALSE,
  labels = c("Low", "Medium", "Hight", "Very High")
)
```


```
# Frequenze assolute e relative
freq_ass <- table(dati_2024$Noise_Level)
freq_ass
```

```
##
##      Low      Medium      Hight Very High
##      68         20         27         2
```

```
freq_rel <- prop.table(freq_ass)
freq_rel
```

```
##
##      Low      Medium      Hight Very High
##      68         20         27         2
```

```
# Istogramma
hist(dati_2024$Decibel_Level,
     breaks = c(50, 62.5, 75, 87.5, 100),
     right = FALSE,
     main = "Distribuzione di Noise_Level",
     xlab = "Decibel_Level",
     col = "steelblue",
     border = "white")
```



Risposta:

Frequenze assolute:

- Low: 68
- Medium: 20
- High: 27
- Very High: 2

Frequenze relative:

- Low: $68/117 = 58.12\%$
- Medium: $20/117 = 17.09\%$
- High: $27/117 = 23.08\%$
- Very High: $2/117 = 1.71\%$

Istogramma: la distribuzione è concentrata nella classe **Low** (68 osservazioni su 117), seguita da **High** (27) e **Medium** (20). La classe **Very High** è quasi assente (solo 2 osservazioni).

-
- **Punto 3:[5 pt]:** Si aggiunga al dataframe la variabile **Traffic**, ottenuta da **Traffic_Density** accorpando le modalità “High” e “Very High”. La nuova variabile deve rispettare l’ordinamento crescente delle classi (“Low” < “Medium” < “High”). Si valuti graficamente se le distribuzioni della variabile **Noise_Level** condizionate ai livelli di **Traffic** risultano differenti. Successivamente si valuti con un indice normalizzato l’eventuale associazione tra le due variabili. Il risultato numerico conferma l’intuizione derivata dall’osservazione del grafico?

Svolgimento

```
# Creo la variabile Traffic accorpando High e Very High
dati_2024$Traffic <- factor(
  dati_2024$Traffic_Density,
  levels = c("Low", "Medium", "High", "Very High"),
  labels = c("Low", "Medium", "High", "High")
)


# Verifico l'ordinamento
levels(dati_2024$Traffic)
```

```
## [1] "Low"      "Medium"   "High"
```

```
# Tabella di contingenza Noise_Level vs Traffic
tab <- table(dati_2024$Noise_Level, dati_2024$Traffic)
tab
```

```
##
##           Low Medium High
## Low         49     15    4
## Medium       0      7   13
## Hight        0      0   27
## Very High    0      0    2
```

```
# Grafico a barre affiancate per confrontare le distribuzioni
barplot(tab,
  beside = TRUE,
  legend = TRUE,
  col = c("lightblue", "lightgreen", "salmon", "gold"),
  main = "Noise_Level per Traffic",
  xlab = "Traffic",
  ylab = "Frequenza")
```



```
# Calcolo V di Cramer
chi2 <- chisq.test(tab)$statistic
```

```
## Warning in chisq.test(tab): L'approssimazione al Chi-quadrato potrebbe essere
## inesatta
```

```
n <- sum(tab)
k <- min(dim(tab))
V_cramer <- sqrt(chi2 / (n * (k - 1)))
V_cramer
```

```
## X-squared
## 0.6330871
```

Risposta:

Nuova variabile Traffic: Ho accorpato le modalità “High” e “Very High” in un’unica categoria “High”. La nuova variabile ha livelli ordinati: **Low < Medium < High**.

Tabella di contingenza Noise_Level vs Traffic:

Noise_Level	Low	Medium	High
Low	49	15	4

Noise_Level	Low	Medium	High
Medium	0	7	13
High	0	0	27
Very High	0	0	2

Grafico: si osserva che:

- Per **Traffic Low**, solo Noise_Level Low è presente (49 casi).
- Per **Traffic Medium**, compaiono Noise_Level Low (15) e Medium (7).
- Per **Traffic High**, compaiono tutte le categorie, con prevalenza di High (27) e Very High (2).

Le distribuzioni risultano **chiaramente differenti**: All'aumentare del traffico, aumenta anche il livello di rumore.

Indice V di Cramer: $V = 0.633$

Nota: il test ² ha generato un warning perché alcune celle hanno frequenze attese inferiori a 5. Tuttavia, il V di Cramer rimane un valido indicatore dell'associazione e il suo valore elevato (0.63) conferma una **forte relazione** tra Noise_Level e Traffic.

-
- **Punto 4 [3 pt]:** Si considerino le variabili quantitative Happiness_score and Air_Quality_Index per la modalità Oceania della variabile Continent e High della variabile Noise_level. Stampare le mediane delle variabili numeriche per le osservazioni selezionate.

Svolgimento

```
# Verifica iniziale
table(dati_2024$Continent, dati_2024$Noise_Level)

##
##           Low Medium Hight Very High
## Africa         1     0      1         0
## Asia           0     5     21         2
## Europe        16     3      1         0
## North America  2     6      1         0
## Oceania       49     0      1         0
## South America  0     6      2         0

# Seleziono le osservazioni per Continent = "Oceania" e Noise_Level = "High"
sottoinsieme <- dati_2024[dati_2024$Continent == "Oceania" & dati_2024$Noise_Level == "High", ]

# Mediane
sapply(sottoinsieme[, c("Happiness_Score", "Air_Quality_Index")], median, na.rm = TRUE)

## Happiness_Score Air_Quality_Index
##              NA              NA
```

Risposta:


Non esistono osservazioni con `Continent == "Oceania"` e `Noise_Level == "High"` (la condizione non è mai soddisfatta). Pertanto, le mediane delle variabili numeriche non sono definibili (NA).

- **Punto 5 [4 pt]:** Si rappresentino graficamente le distribuzioni di `Happiness_Score` condizionate ai livelli di `Continent`. Cosa emerge dall'analisi del grafico? Escludendo le categorie `South America`, `Africa` e `Asia`, quale delle seguenti affermazioni è VERA?
 - a. [F] Vi è ancora una chiara evidenza di differenza tra le medie di `Happiness_Score` per continente.
 - b. [F] Il valore della devianza within è sicuramente maggiore di quello ottenuto considerando tutti i continenti.
 - c. [V] Ci aspettiamo una riduzione del valore dell' η^2 .
 - d. [F] Il valore della devianza between è sicuramente maggiore di quello ottenuto considerando tutti i continenti.

Svolgimento

```
# Boxplot di Happiness_Score per Continent
boxplot(Happiness_Score ~ Continent,
        data = dati_2024,
        col = "steelblue",
        main = "Happiness_Score per Continent",
        xlab = "Continent",
        ylab = "Happiness_Score")
```


Happiness_Score per Continent



```
# Calcolo medie per Continent
```

```
tapply(dati_2024$Happiness_Score, dati_2024$Continent, mean)
```

```
##      Africa      Asia      Europe North America      Oceania
##      5.550000    4.371429    7.220000    6.211111    7.440000
## South America
##      4.975000
```

```
# Escludo South America, Africa e Asia
```

```
dati_ridotti <- dati_2024[!dati_2024$Continent %in% c("South America", "Africa", "Asia"), ]
```

```
# Nuove medie
```

```
tapply(dati_ridotti$Happiness_Score, dati_ridotti$Continent, mean)
```

```
##      Europe North America      Oceania
##      7.220000    6.211111    7.440000
```

```
# ANOVA per confrontare le medie (opzionale)
```

```
summary(aov(Happiness_Score ~ Continent, data = dati_2024))
```

```
##           Df Sum Sq Mean Sq F value Pr(>F)
## Continent    5   200.7   40.13   31.74 <2e-16 ***
## Residuals  111   140.4    1.26
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
summary(aov(Happiness_Score ~ Continent, data = dati_ridotti))
```

```
##              Df Sum Sq Mean Sq F value    Pr(>F)
## Continent      2  11.53    5.767    5.689 0.00498 **
## Residuals     76   77.04    1.014
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Risposta:

Analisi del boxplot: - **Oceania** e **Europa** hanno i valori di **Happiness_Score** più alti (medie: 7.44 e 7.22).

- **Nord America** ha valori intermedi (media: 6.21).

- **Asia**, **Sud America** e **Africa** hanno i valori più bassi (medie: 4.37, 4.98, 5.55).

Escludendo le categorie South America, Africa e Asia, rimangono **Europa**, **Nord America** e **Oceania**. Le loro medie sono:

- Europa: 7.22

- Nord America: 6.21

- Oceania: 7.44

L'ANOVA sui tre gruppi rimanenti ha $p\text{-value} = 0.00498$, indicando che esistono ancora differenze significative tra le medie, ma meno marcate rispetto a prima.

Valutazione delle affermazioni:

- **a.** “Vi è ancora una chiara evidenza di differenza tra le medie di **Happiness_Score** per continente” → **FALSA**. Le differenze sono meno evidenti rispetto a quando si includevano tutti i continenti.
- **b.** “Il valore della devianza within è sicuramente maggiore di quello ottenuto considerando tutti i continenti” → **FALSA**. La devianza within è passata da 140.4 a 77.04, quindi è diminuita.
- **c.** “Ci aspettiamo una riduzione del valore dell' η^2 ” → **VERA**. Escludendo continenti con medie estreme, la devianza between si riduce (da 200.7 a 11.53), quindi anche η^2 diminuisce.
- **d.** “Il valore della devianza between è sicuramente maggiore di quello ottenuto considerando tutti i continenti” → **FALSA**. La devianza between è diminuita, non aumentata.

Risposta corretta: **c**.

-
- **Punto 6 [1 pt]:** Si adatti un modello di regressione lineare semplice avente come variabile risposta **Happiness_Score** e come variabili esplicative **Air_Quality_Index** e si stampi l'output del modello.

Svolgimento

```
# Modello di regressione lineare semplice
mod6 <- lm(Happiness_Score ~ Air_Quality_Index, data = dati_2024)
summary(mod6)
```

```
##
## Call:
## lm(formula = Happiness_Score ~ Air_Quality_Index, data = dati_2024)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.1285 -0.5187  0.2824  0.6825  1.8668
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    8.072450   0.136543   59.12  <2e-16 ***
## Air_Quality_Index -0.022196   0.001366  -16.24  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9488 on 115 degrees of freedom
## Multiple R-squared:  0.6965, Adjusted R-squared:  0.6938
## F-statistic: 263.9 on 1 and 115 DF,  p-value: < 2.2e-16
```

Risposta:

Il modello di regressione lineare semplice stimato è:

$\text{Happiness_Score} = 8.072 - 0.0222 * \text{Air_Quality_Index}$

Interpretazione dei coefficienti:

- **Intercetta (8.072)**: valore atteso di `Happiness_Score` quando `Air_Quality_Index` è 0 (non interpretabile in termini reali).
- **Pendenza (-0.0222)**: per ogni unità in più di `Air_Quality_Index`, il `Happiness_Score` diminuisce in media di **0.0222** (p-value < 0.001). L'effetto è statisticamente significativo.

Bontà del modello:

- $R^2 = 0.6965$: il modello spiega circa il **69.7%** della variabilità di `Happiness_Score`.
- R^2 aggiustato = **0.6938**
- **p-value del modello**: < 2.2e-16 (modello complessivamente significativo)

La relazione è **negativa e forte**: all'aumentare dell'inquinamento (`Air_Quality_Index` più alto), la felicità tende a diminuire.

-
- **6.1 [1 pt]**: Si calcoli il coefficiente della variabile `Air_Quality_Index` a mano e si verifichi che esso corrisponde a quello ottenuto dall'output del modello.

Svolgimento

```
# Calcolo coefficiente usando la formula: beta_1 = Cov(x, y) / Var(x)
cov_xy <- cov(dati_2024$Air_Quality_Index, dati_2024$Happiness_Score)
var_x <- var(dati_2024$Air_Quality_Index)
beta_1 <- cov_xy / var_x
beta_1
```

```
## [1] -0.02219606
```

```
# Confronto con il coefficiente del modello
coef(mod6)[2]
```

```
## Air_Quality_Index
##      -0.02219606
```

Risposta:

Il coefficiente della variabile `Air_Quality_Index` calcolato “a mano” con la formula:

$$\hat{\beta}_1 = \frac{\text{Cov}(x, y)}{\text{Var}(x)}$$


è **-0.02219606**, che coincide esattamente con il coefficiente stimato dal modello di regressione lineare.

-
- **6.2 [2 pt]**: Ottenere il grafico dei residui vs valori stimati e stampare le città con residuo minore di -2.

Svolgimento

```
# Grafico residui vs valori stimati
plot(fitted(mod6), residuals(mod6),
     xlab = "Valori stimati",
     ylab = "Residui",
     main = "Residui vs Valori stimati",
     pch = 19,
     col = "steelblue")
abline(h = 0, col = "red", lty = 2)
```

Residui vs Valori stimati



```
# Identifico le osservazioni con residuo minore di -2
```

```
residui <- residuals(mod6)
```

```
indici <- which(residui < -2)
```

```
dati_2024[indici, c("City", "Continent", "Happiness_Score", "Air_Quality_Index")]
```

##	City	Continent	Happiness_Score	Air_Quality_Index
## 19	Cairo	Africa	3.5	115
## 45	Caracas	South America	3.0	115
## 113	Te Hana	Oceania	5.5	20
## 114	Waipu	Oceania	5.2	35
## 115	Ruakaka	Oceania	5.0	30
## 116	Whangarei	Oceania	4.8	25
## 117	Dargaville	Oceania	4.5	20

Risposta:

Grafico residui vs valori stimati:

- I residui sono distribuiti in modo abbastanza casuale intorno allo zero, senza un pattern evidente.
- Non si osservano forme particolari (ad esempio, dispersione crescente o decrescente), il che suggerisce che l'assunzione di omoschedasticità è ragionevolmente rispettata.

Città con residuo minore di -2:

City	Continent	Happiness_Score	Air_Quality_Index
Cairo	Africa	3.5	115
Caracas	South America	3.0	115
Te Hana	Oceania	5.5	20
Waipu	Oceania	5.2	35
Ruakaka	Oceania	5.0	30
Whangarei	Oceania	4.8	25
Dargaville	Oceania	4.5	20

Continenti corrispondenti:

- **Africa** (1 città)
- **South America** (1 città)
- **Oceania** (5 città).

-
- **6.3 [1 pt]**: Si ottenga il grafico della retta di regressione del modello sovrapposta allo scatterplot dei punti osservati e si colori i punti in accordo alle categorie della variabile `Noise_Level`.


Svolgimento

```
# Scatterplot con retta di regressione e colori per Noise_Level
plot(dati_2024$Air_Quality_Index,
     dati_2024$Happiness_Score,
     col = as.numeric(dati_2024$Noise_Level),
     pch = 19,
     xlab = "Air_Quality_Index",
     ylab = "Happiness_Score",
     main = "Regressione lineare con punti colorati per Noise_Level")

# Aggiungo la retta di regressione
abline(mod6, col = "red", lwd = 2)

# Legenda
legend("topright",
      legend = levels(dati_2024$Noise_Level),
      col = 1:length(levels(dati_2024$Noise_Level)),
      pch = 19,
      title = "Noise_Level")
```

Regressione lineare con punti colorati per Noise_Level



Risposta:

Il grafico mostra lo **scatterplot** tra **Air_Quality_Index** (x) e **Happiness_Score** (y), con i punti colorati in base ai livelli di **Noise_Level** (Low, Medium, High, Very High).

Osservazioni:

- La **retta di regressione rossa** conferma la relazione negativa tra le due variabili: all'aumentare dell'indice di qualità dell'aria (peggiore qualità), il punteggio di felicità diminuisce.
- I punti colorati mostrano una chiara separazione:
 - **Noise_Level Low** (blu): si concentra nella zona con basso **Air_Quality_Index** e alto **Happiness_Score**.
 - **Noise_Level Medium** (verde): si colloca in una posizione intermedia.
 - **Noise_Level High** (rosso): si concentra nella zona con alto **Air_Quality_Index** e basso **Happiness_Score**.
 - **Noise_Level Very High** (giallo): è rappresentato da soli 2 punti, che non sono visibili nel grafico a causa della loro scarsa numerosità.

Interpretazione: le città con livelli di rumore più elevati tendono ad avere una qualità dell'aria peggiore e, di conseguenza, una felicità media più bassa. La relazione tra **Air_Quality_Index** e **Happiness_Score** rimane negativa indipendentemente dal livello di rumore.

- **6.4 [3 pt]:** Si ottenga il modello di regressione lineare avente come variabile risposta `Happiness_Score` e come variabili esplicative `Air_Quality_Index` e `Air_Quality_Index` al quadrato. Selezionare quale delle seguenti affermazioni è VERA.
 - a. [F] L'incremento del coefficiente di determinazione rispetto al modello al punto 6 è superiore ad un punto percentuale.
 - b. [V] L'effetto di un incremento unitario di `Air_Quality_Index` su `Happiness_Score` è di circa -0.03.
 - c. [F] Il valore predetto di `Happiness_Score` quando `Air_Quality_Index` è 5 è 8.23.
 - d. [F] I residui sono simmetrici

Svolgimento

```
# Modello quadratico
mod6.4 <- lm(Happiness_Score ~ Air_Quality_Index + I(Air_Quality_Index^2), data = dati_2024)
summary(mod6.4)

##
## Call:
## lm(formula = Happiness_Score ~ Air_Quality_Index + I(Air_Quality_Index^2),
##     data = dati_2024)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.2780 -0.4251  0.2730  0.6730  1.7764
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      8.411e+00  2.210e-01  38.060 < 2e-16 ***
## Air_Quality_Index  -3.259e-02  5.532e-03  -5.891 3.96e-08 ***
## I(Air_Quality_Index^2)  4.574e-05  2.361e-05   1.937  0.0552 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.9376 on 114 degrees of freedom
## Multiple R-squared:  0.7061, Adjusted R-squared:  0.701
## F-statistic: 137 on 2 and 114 DF, p-value: < 2.2e-16

# R^2 del modello lineare (punto 6)
R2_lineare <- summary(mod6)$r.squared

# R^2 del modello quadratico
R2_quadratico <- summary(mod6.4)$r.squared

# Incremento di R^2
R2_quadratico - R2_lineare

## [1] 0.009671959
```



```
# Coefficiente di Air_Quality_Index nel modello quadratico
coef(mod6.4)[2]
```

```
## Air_Quality_Index
## -0.03258658
```

```
# Predizione per AQI = 5
predict(mod6.4, newdata = data.frame(Air_Quality_Index = 5))
```

```
## 1
## 8.249691
```

```
# Asimmetria dei residui
library(e1071)
skewness(residuals(mod6.4))
```

```
## [1] -1.175979
```

Risposta:

Modello quadratico stimato:

$\text{Happiness_Score} = 8.411 - 0.0326 * \text{AQI} + 0.0000457 * \text{AQI}^2$

Verifica delle affermazioni:

- a. “L’incremento del coefficiente di determinazione rispetto al modello al punto 6 è superiore ad un punto percentuale” → **FALSA**. L’incremento è **0.00967** (0.967 punti percentuali), che è inferiore a 1 punto percentuale.
- b. “L’effetto di un incremento unitario di Air_Quality_Index su Happiness_Score è di circa -0.03” → **VERA**. Il coefficiente lineare del modello quadratico è -0.0326, che approssimato è circa -0.03. (L’effetto marginale non è costante, ma per valori tipici di AQI è circa -0.03).
- c. “Il valore predetto di Happiness_Score quando Air_Quality_Index è 5 è 8.23” → **FALSA**. La predizione è **8.25** (non 8.23).
- d. “I residui sono simmetrici” → **FALSA**. La skewness dei residui è **-1.176**, che indica asimmetria negativa.

Risposta corretta: b.

-
- **Punto 7 [4 pt]**: Si applichi un algoritmo di cluster analysis gerarchico con il metodo di Ward che consideri le seguenti variabili: **Green_Space_Area**, **Air_Quality_Index**, **Noise_Level**, **Traffic**. Si selezionino due gruppi e si scelga la risposta FALSA tra le seguenti.
 - a. [V] Uno dei gruppi è caratterizzato principalmente da paesi in Oceania ed Europa.
 - b. [F] Rispetto alla variabile **Traffic**, le città con traffico alto non si trovano in un unico gruppo.
 - c. [V] Le città con un livello di **Noise_level** basso sono quasi tutte concentrate in un unico cluster.
 - d. [F] Le medie condizionate della variabile **Happiness_Score** rispetto ai due gruppi sono di 4.97 e 7.51.

Svolgimento:

```
# Preparo i dati per il clustering (variabili miste)
library(cluster)


# Creo un subset con le variabili da utilizzare
dati_cluster <- dati_2024[, c("Green_Space_Area", "Air_Quality_Index", "Noise_Level", "Traffic")]

# Convento le variabili qualitative in factor
dati_cluster$Noise_Level <- factor(dati_cluster$Noise_Level,
                                   levels = c("Low", "Medium", "High", "Very High"),
                                   ordered = TRUE)
dati_cluster$Traffic <- factor(dati_cluster$Traffic,
                               levels = c("Low", "Medium", "High"),
                               ordered = TRUE)

# Matrice di dissimilarità con Gower (per dati misti)
gower_dist <- daisy(dati_cluster, metric = "gower")

# Clustering gerarchico con metodo di Ward
hc_ward <- hclust(gower_dist, method = "ward.D2")

# Dendrogramma
plot(hc_ward, labels = FALSE, main = "Dendrogramma - Ward", xlab = "", sub = "")
```



```
# Taglio per ottenere 2 cluster
clusters <- cutree(hc_ward, k = 2)
table(clusters)
```

```
## clusters
## 1 2
## 46 71
```

```
# Aggiungo i cluster al dataset
dati_2024$cluster_ward <- clusters
```

```
# Analisi dei cluster
# 1. Distribuzione di Traffic per cluster
table(dati_2024$Traffic, dati_2024$cluster_ward)
```

```
##
##           1  2
## Low       0 49
## Medium    0 22
## High      46  0
```

```
# 2. Distribuzione di Noise_Level per cluster
table(dati_2024$Noise_Level, dati_2024$cluster_ward)
```

```
##
##           1  2
## Low       4 64
## Medium    13 7
## Hight     27 0
## Very High  2 0
```

```
# 3. Medie di Happiness_Score per cluster
tapply(dati_2024$Happiness_Score, dati_2024$cluster_ward, mean)
```

```
##           1           2
## 4.782609 7.402817
```

```
# 4. Continenti per cluster
table(dati_2024$Continent, dati_2024$cluster_ward)
```

```
##
##           1  2
## Africa      1 1
## Asia        27 1
## Europe       6 14
## North America 4 5
## Oceania      1 49
## South America 7 1
```

Risposta:

Caratteristiche dei due cluster:

Caratteristica	Cluster 1	Cluster 2
Numerosità	46	71
Traffic	Solo High (46)	Low (49) e Medium (22)
Noise_Level	Prevalentemente High/Very High (27+2)	Prevalentemente Low (64)
Happiness_Score (media)	4.78	7.40
Continenti principali	Asia (27), Europa (6), Sud America (7)	Oceania (49), Europa (14)

Valutazione delle affermazioni:

- **a.** *“Uno dei gruppi è caratterizzato principalmente da paesi in Oceania ed Europa”* → **VERA**. Il Cluster 2 ha 49 città dell'Oceania e 14 dell'Europa (63 su 71).
- **b.** *“Rispetto alla variabile Traffic, le città con traffico alto non si trovano in un unico gruppo”* → **FALSA**. Tutte le città con traffico “High” (46 osservazioni) sono nel Cluster 1.
- **c.** *“Le città con un livello di Noise_level basso sono quasi tutte concentrate in un unico cluster”* → **VERA**. 64 città su 68 con Noise_Level “Low” sono nel Cluster 2.
- **d.** *“Le medie condizionate della variabile Happiness_Score rispetto ai due gruppi sono di 4.97 e 7.51”* → **FALSA**. Le medie reali sono **4.78** e **7.40**.

Pertanto, le affermazioni false sono **b** e **d**. Se la consegna ne richiede una sola, la risposta attesa è **b**.

PARTE 2: R

- **Punto 8 [4 pt]:** Scrivere una funzione chiamata **funzione** che prenda in input un vettore numerico **x** e una variabile di tipo character **y** e che svolga i seguenti passaggi:
 - a. Controlli che il tipo di **x** sia numeric e quello di **y** sia character, e in tal caso stampi il messaggio **"OK: il vettore x è di tipo numeric, mentre y è di tipo character"**;
 - b. Calcoli il 25-esimo percentile di **x** e lo utilizzi per creare una variabile **z** con valori pari a 0 se le osservazioni sono al di sopra del 25-esimo percentile, e 1 altrimenti;
 - c. Restituisca un data frame contenente la variabili **x** e **y** solo per le osservazioni aventi **z** pari a 1.

Testare la funzione usando **Happiness_Score** come **x** e **City** come **y**.

Svolgimento:

```

# Funzione richiesta
funzione <- function(x, y)
{
  # Punto a: Controllo dei tipi
  if (is.numeric(x) && is.character(y))
  {
    print("OK: il vettore x è di tipo numeric, mentre y è di tipo character")
  } else {
    stop("Errore: x deve essere numeric e y deve essere character")
  }

  # Punto b: Calcolo del 25-esimo percentile
  p25 <- quantile(x, probs = 0.25, na.rm = TRUE)

  # Creazione della variabile z: 1 se x <= al 25-esimo percentile, 0 altrimenti
  z <- ifelse(x <= p25, 1, 0)

  # Punto c: Creazione del data frame con x e y
  df <- data.frame(x = x, y = y)

  # Selezione delle righe con z == 1
  df_selezionato <- df[z == 1, ]

  return(df_selezionato)
}

# Test della funzione
test <- funzione(dati_2024$Happiness_Score, dati_2024$City)

```

```
## [1] "OK: il vettore x è di tipo numeric, mentre y è di tipo character"
```

```

# Mostro le prime righe del risultato
head(test)

```

```

##      x      y
## 9  4.5  Mumbai
## 14 5.2 Mexico City
## 16 4.0  Bangkok
## 19 3.5   Cairo
## 41 5.0  São Paulo
## 42 4.2   Lima

```

Risposta:

Test della funzione con $x = \text{Happiness_Score}$ e $y = \text{City}$:

Prime città selezionate (quelle con $\text{Happiness_Score} \leq 25\text{-esimo percentile}$, pari a 5.5):

Happiness_Score	City
4.5	Mumbai
5.2	Mexico City

Happiness_Score	City
4.0	Bangkok
3.5	Cairo
5.0	São Paulo
4.2	Lima