

Soluzione - Tutorato 3

15-06-2026

Esercizio 1

Caricare il dataset `student_performance_data.csv` (di cui potete trovare i dettagli su Kaggle). Poi:

1. Tipologia delle variabili

Classificare tutte le variabili del dataset indicandone:

- **Tipo:** qualitativa / quantitativa
- **Sottotipo:** nominale (dicotomica o meno) / ordinale / discreta / continua

Svolgimento

```
# Carico dataset
studenti <- read.csv("student_performance_data.csv")

# Prime righe
head(studenti)
```

```
##   student_id gender study_hours_per_day attendance_percentage assignment_score
## 1    100000   Male           4.54             69.98             36.47
## 2    100001 Female           5.26             84.80             34.25
## 3    100002   Male           8.69             73.76             72.29
## 4    100003   Male           4.06             45.00             97.63
## 5    100004   Male           8.83             51.13             65.19
## 6    100005 Female           1.79             53.16             33.61
##   midterm_score final_exam_score participation_score internet_access
## 1         70.70          53.10           17.96             Yes
## 2         27.92          87.17           11.29             No
## 3         70.92          99.61           76.10             No
## 4         31.73          88.85           33.55             No
## 5         78.28          54.23           88.99             No
## 6         54.26          79.79           58.23             No
##   extra_classes parent_education sleep_hours overall_score grade
## 1           No         Master      8.09      52.3480      D
## 2           Yes         Bachelor      4.73      53.9485      D
## 3           Yes           PhD       8.73      82.0375      B
## 4           No         Bachelor      8.22      66.4110      C
## 5           No         Bachelor      8.59      65.6005      C
## 6           No         Bachelor      5.43      59.3525      C
```

```
# Struttura
str(studenti)
```

```
## 'data.frame': 10000 obs. of 14 variables:
## $ student_id : int 100000 100001 100002 100003 100004 100005 100006 100007 100008 100009
## $ gender : chr "Male" "Female" "Male" "Male" ...
## $ study_hours_per_day : num 4.54 5.26 8.69 4.06 8.83 ...
## $ attendance_percentage: num 70 84.8 73.8 45 51.1 ...
## $ assignment_score : num 36.5 34.2 72.3 97.6 65.2 ...
## $ midterm_score : num 70.7 27.9 70.9 31.7 78.3 ...
## $ final_exam_score : num 53.1 87.2 99.6 88.8 54.2 ...
## $ participation_score : num 18 11.3 76.1 33.5 89 ...
## $ internet_access : chr "Yes" "No" "No" "No" ...
## $ extra_classes : chr "No" "Yes" "Yes" "No" ...
## $ parent_education : chr "Master" "Bachelor" "PhD" "Bachelor" ...
## $ sleep_hours : num 8.09 4.73 8.73 8.22 8.59 5.43 2.84 6.35 5.12 6.33 ...
## $ overall_score : num 52.3 53.9 82 66.4 65.6 ...
## $ grade : chr "D" "D" "B" "C" ...
```

```
# Statistiche
summary(studenti)
```

```
## student_id gender study_hours_per_day attendance_percentage
## Min. :100000 Length:10000 Min. : 1.000 Min. : 40.00
## 1st Qu.:102500 Class :character 1st Qu.: 3.240 1st Qu.: 55.57
## Median :105000 Mode :character Median : 5.440 Median : 70.74
## Mean :105000 Mean : 5.525 Mean : 70.48
## 3rd Qu.:107499 3rd Qu.: 7.780 3rd Qu.: 85.20
## Max. :109999 Max. :28.860 Max. :100.00
## NA's :87 NA's :106
## assignment_score midterm_score final_exam_score participation_score
## Min. :30.00 Min. : 25.00 Min. : 30.01 Min. :10.00
## 1st Qu.:47.32 1st Qu.: 43.52 1st Qu.: 47.40 1st Qu.:32.95
## Median :64.77 Median : 62.05 Median : 65.21 Median :55.05
## Mean :64.72 Mean : 62.32 Mean : 64.98 Mean :55.10
## 3rd Qu.:81.76 3rd Qu.: 81.23 3rd Qu.: 82.50 3rd Qu.:77.76
## Max. :99.99 Max. :100.00 Max. :100.00 Max. :99.99
##
## internet_access extra_classes parent_education sleep_hours
## Length:10000 Length:10000 Length:10000 Min. :2.235
## Class :character Class :character Class :character 1st Qu.:5.200
## Mode :character Mode :character Mode :character Median :6.510
## Mean :6.489
## 3rd Qu.:7.790
## Max. :9.000
## NA's :104
## overall_score grade
## Min. :33.26 Length:10000
## 1st Qu.:56.53 Class :character
## Median :63.78 Mode :character
## Mean :63.83
## 3rd Qu.:71.17
## Max. :96.88
```

```
## NA's :104
```

```
# Controllo NA  
colSums(is.na(studenti))
```

```
##          student_id          gender  study_hours_per_day  
##              0              0              87  
## attendance_percentage  assignment_score  midterm_score  
##              106              0              0  
##      final_exam_score  participation_score  internet_access  
##              0              0              0  
##      extra_classes      parent_education      sleep_hours  
##              0              0              104  
##      overall_score          grade  
##              104              0
```

Risposte

- a): student_id è una variabile **quantitativa discreta**.
 - b): gender è una variabile **qualitativa nominale**.
 - c): study_hours_per_day è una variabile **quantitativa continua**.
 - d): attendance_percentage è una variabile **quantitativa continua**.
 - e): assignment_score, midterm_score, final_exam_score e participation_score sono variabili **quantitative continue**.
 - f): internet_access ed extra_classes sono variabili **qualitative nominali dicotomiche**.
 - g): parent_education è una variabile **qualitativa nominale**.
 - h): sleep_hours e overall_score sono variabili **quantitative continue**.
 - i): grade è una variabile **qualitativa ordinale**.
-

2. Ricodifica delle variabili

- a) Dopo aver verificato la presenza di NA (come sono rappresentati e quanti sono per variabile?), rimuovere dal dataset le osservazioni contenenti almeno un valore mancante;
- b) Alcune variabili qualitative possono essere trasformate in factor direttamente, altre no; perché?
- c) Dopo aver trasformato le variabili qualitative in factor, riordinare i livelli ove necessario;
- d) Si consideri la variabile **study_hours_per_day** e si aggiunga al dataset una nuova variabile **study_time** che abbia, per ogni osservazione:
 - low se **study_hours_per_day** è minore di 3,

- medium se è compresa tra 3 e 6,
- high altrimenti.

e) Si consideri la variabile `attendance_percentage` e si aggiunga al dataset una nuova variabile `attendance` che abbia, per ogni osservazione:

- low se `attendance_percentage` è minore di 60,
- medium se è compresa tra 60 e 80,
- high altrimenti.

Svolgimento

```
# Controllo NA
colSums(is.na(studenti))
```

```
##           student_id           gender  study_hours_per_day
##              0              0              87
## attendance_percentage  assignment_score  midterm_score
##           106              0              0
##   final_exam_score  participation_score  internet_access
##              0              0              0
##   extra_classes  parent_education  sleep_hours
##              0              0              104
##   overall_score           grade
##           104              0
```

```
# Rimuovo righe con NA
studenti_clean <- na.omit(studenti)
```

```
# Trasformo variabili in factor
studenti_clean$gender <- as.factor(studenti_clean$gender)
studenti_clean$internet_access <- as.factor(studenti_clean$internet_access)
studenti_clean$extra_classes <- as.factor(studenti_clean$extra_classes)
studenti_clean$parent_education <- as.factor(studenti_clean$parent_education)
```

```
# Trasformo grade in factor ORDINATO
studenti_clean$grade <- factor(
  studenti_clean$grade,
  levels = c("F", "D", "C", "B", "A"),
  ordered = TRUE
)
```

```
# Nuova variabile study_time
studenti_clean$study_time <- cut(
  studenti_clean$study_hours_per_day,
  breaks = c(-Inf, 3, 6, Inf),
  labels = c("low", "medium", "high")
)
```

```
# Nuova variabile attendance
studenti_clean$attendance <- cut(
  studenti_clean$attendance_percentage,
  breaks = c(-Inf, 60, 80, Inf),
  labels = c("low", "medium", "high")
)
```

Risposte

a): I valori mancanti sono rappresentati come **NA**. Sono presenti in:

- study_hours_per_day (87),
- attendance_percentage (106),
- sleep_hours (104)
- overall_score (104).

Le osservazioni contenenti almeno un valore mancante sono state rimosse dal dataset.

b): Le variabili qualitative possono essere trasformate in factor quando rappresentano categorie. Tuttavia, alcune variabili (come grade) non possono essere trasformate direttamente perché sono **ordinali** e richiedono un ordine tra i livelli.

c): Dopo la trasformazione in factor, i livelli devono essere riordinati per le variabili ordinali (ad esempio grade), in modo da rispettare l'ordine logico (es. A > B > C > D).

d): È stata creata la variabile study_time che classifica study_hours_per_day in **low**, **medium** e **high**.

e): È stata creata la variabile attendance che classifica attendance_percentage in **low**, **medium** e **high**.

3. Analisi delle variabili

a) Considerare le variabili overall_score, study_hours_per_day e sleep_hours e calcolarne:

- indici di **posizione**;
- indici di **dispersione**;
- indici di **simmetria**.

b) Costruire la tabella delle frequenze assolute e relative di study_time e attendance e rappresentarle con uno strumento grafico appropriato;

c) Costruire la tabella di contingenza di study_time e attendance con la variabile grade e rappresentarle con uno strumento grafico appropriato;

d) Costruire la tabella contenente la distribuzione di grade condizionata a study_time; cosa possiamo dire?

e) Calcolare le medie di overall_score per gruppo rispetto a study_time e attendance; quale gruppo ha la media più alta?

- f) Costruire i boxplot di `overall_score` condizionato a `study_time` e a `attendance`; cosa possiamo dire?
- g) Calcolare la media di `overall_score` per ogni combinazione di `study_time` e `attendance`; esiste un effetto combinato tra le due variabili?
- h) Considerare la distribuzione di `overall_score` e:
- rappresentarla tramite istogramma e curva di densità, aggiungendo al plot anche una linea rossa ad indicarne la media;
 - costruire la funzione di ripartizione empirica e confrontarla con una distribuzione teorica;
 - costruire un grafico quantile-quantile.

Svolgimento

a) Indici di posizione, dispersione e simmetria

```
# Funzione per calcolare indici principali
indici_variabile <- function(x) {
  c(
    media = mean(x),
    mediana = median(x),
    minimo = min(x),
    massimo = max(x),
    primo_quartile = quantile(x, 0.25),
    terzo_quartile = quantile(x, 0.75),
    varianza = var(x),
    deviazione_standard = sd(x),
    IQR = IQR(x),
    simmetria = mean((x - mean(x))^3) / sd(x)^3
  )
}

# Indici per overall_score
indici_variabile(studenti_clean$overall_score)
```

```
##          media          mediana          minimo          massimo
##    63.819405892    63.787250000    33.263500000    96.879500000
## primo_quartile.25% terzo_quartile.75%          varianza deviazione_standard
##    56.512125000    71.160500000    104.565106547    10.225708120
##          IQR          simmetria
##    14.648375000    -0.002428871
```

```
# Indici per study_hours_per_day
indici_variabile(studenti_clean$study_hours_per_day)
```

```
##          media          mediana          minimo          massimo
##    5.5241328    5.4300000    1.0000000    28.8600000
## primo_quartile.25% terzo_quartile.75%          varianza deviazione_standard
##    3.2300000    7.7775000    7.6316226    2.7625392
##          IQR          simmetria
##    4.5475000    0.7941345
```

```
# Indici per sleep_hours
indici_variabile(studenti_clean$sleep_hours)
```

```
##          media          mediana          minimo          massimo
##      6.48560327      6.51000000      2.23500000      9.00000000
## primo_quartile.25% terzo_quartile.75%      varianza deviazione_standard
##      5.20000000      7.79000000      2.17354464      1.47429462
##          IQR          simmetria
##      2.59000000      -0.03431299
```

Risposte

- overall_score ha media **63.82**, con distribuzione quasi simmetrica (simmetria 0) e dispersione moderata (deviazione standard **10.23**).
 - study_hours_per_day ha media **5.52**, con distribuzione asimmetrica a destra (simmetria **0.79**) e maggiore variabilità.
 - sleep_hours ha media **6.49**, con distribuzione quasi simmetrica e dispersione contenuta (deviazione standard **1.47**).
-

b) Tabelle frequenze e grafici

```
# Frequenze study_time
freq_study <- table(studenti_clean$study_time)
freq_study
```

```
##
##      low medium   high
##    2164   3261   4181
```

```
prop.table(freq_study)
```

```
##
##      low   medium   high
## 0.2252759 0.3394753 0.4352488
```


```
# Frequenze attendance
freq_att <- table(studenti_clean$attendance)
freq_att
```

```
##
##      low medium   high
##    3079   3226   3301
```


```
prop.table(freq_att)
```

```
##  
##      low   medium    high  
## 0.3205288 0.3358318 0.3436394
```

```
# Grafici  
barplot(freq_study, col = "lightblue", main = "Study Time")
```



```
barplot(freq_att, col = "lightgreen", main = "Attendance")
```

Risposte

- study_time presenta una maggiore frequenza nella categoria **high (43.52%)**, seguita da **medium (33.95%)** e **low (22.53%)**.
- attendance è distribuita in modo abbastanza uniforme tra **low (32.05%)**, **medium (33.58%)** e **high (34.36%)**.

c) Tabelle di contingenza


```
# study_time vs grade
tab_study_grade <- table(studenti_clean$study_time, studenti_clean$grade)
tab_study_grade
```

```
##
##      F      D      C      B      A
## low   13   385   981   550   34
## medium 17   593  1508   762   42
## high  22   760  1890  1033   57
```


```
# attendance vs grade
tab_att_grade <- table(studenti_clean$attendance, studenti_clean$grade)
tab_att_grade
```

```
##
##           F      D      C      B      A
## low       32   704 1387   621   17
## medium    17   567 1514   791   42
## high       3   467 1478   933   74
```

```
# Grafici
barplot(tab_study_grade, beside = TRUE, legend = TRUE, col = rainbow(3))
```



```
barplot(tab_att_grade, beside = TRUE, legend = TRUE, col = rainbow(3))
```



Risposte

- Nella relazione tra **study_time** e **grade**, si osserva che all'aumentare del tempo di studio cresce la frequenza dei voti più alti (in particolare **B** e **C**).
- Nella relazione tra **attendance** e **grade**, non emerge una differenza molto marcata: le distribuzioni dei voti risultano abbastanza simili tra i diversi livelli di frequenza.

d) Distribuzione condizionata

```
# Distribuzione grade condizionata a study_time
prop.table(tab_study_grade, margin = 1)
```

```
##
##           F           D           C           B           A
## low    0.006622517 0.196128375 0.499745288 0.280183393 0.017320428
## medium 0.005817933 0.202943190 0.516084873 0.260780287 0.014373717
## high   0.005847953 0.202020202 0.502392344 0.274587985 0.015151515
```

Risposta

La distribuzione dei voti risulta abbastanza simile tra i diversi livelli di **study_time**. Non si osservano differenze molto marcate, anche se i voti intermedi (in particolare **B** e **C**) sono i più frequenti in tutti i gruppi.

e) Medie per gruppo

```
# Media overall_score per study_time
studenti_clean %>%
  group_by(study_time) %>%
  summarise(media = mean(overall_score))
```

```
## # A tibble: 3 x 2
##   study_time media
##   <fct>      <dbl>
## 1 low        64.1
## 2 medium     63.7
## 3 high       63.8
```

```
# Media overall_score per attendance
studenti_clean %>%
  group_by(attendance) %>%
  summarise(media = mean(overall_score))
```

```
## # A tibble: 3 x 2
##   attendance media
##   <fct>      <dbl>
## 1 low        62.0
## 2 medium     63.9
## 3 high       65.5
```


Risposte

- Per **study_time**, le medie sono molto simili tra i gruppi, con valori leggermente più alti per **low** (64.08).
- Per **attendance**, la media più alta si osserva per il gruppo **high** (65.46), seguito da **medium** (63.92) e **low** (61.96).


Il gruppo con la media più alta è quindi **attendance high**.

f) Boxplot

```
# Boxplot overall_score per study_time
boxplot(overall_score ~ study_time,
        data = studenti_clean,
        col = "lightblue",
        main = "Score vs Study Time")
```



```
# Boxplot overall_score per attendance
boxplot(overall_score ~ attendance,
        data = studenti_clean,
        col = "lightgreen",
        main = "Score vs Attendance")
```



Risposte

- Per `study_time`, i boxplot risultano molto simili tra i gruppi, con differenze poco marcate nei valori mediani.
 - Per `attendance`, si osserva un leggero aumento dei valori di `overall_score` passando da **low** a **high**, suggerendo che una maggiore frequenza sia associata a risultati migliori.
-

g) Effetto combinato

```
studenti_clean %>%  
  group_by(study_time, attendance) %>%  
  summarise(media = mean(overall_score), .groups = "drop")
```

```
## # A tibble: 9 x 3  
##   study_time attendance media  
##   <fct>      <fct>      <dbl>  
## 1 low       low        62.4
```

## 2	low	medium	64.3
## 3	low	high	65.4
## 4	medium	low	61.7
## 5	medium	medium	63.9
## 6	medium	high	65.3
## 7	high	low	61.9
## 8	high	medium	63.8
## 9	high	high	65.6

Risposta

Si osserva che la media di `overall_score` aumenta principalmente al crescere di **attendance**, indipendentemente dal livello di `study_time`.

Non emerge un forte effetto combinato tra le due variabili, ma l'effetto della frequenza (attendance) risulta più rilevante rispetto al tempo di studio.


h) Distribuzione `overall_score`

```
# Istogramma + densità
hist(studenti_clean$overall_score,
      probability = TRUE,
      col = "lightblue",
      main = "Distribuzione overall_score")


lines(density(studenti_clean$overall_score), col = "red", lwd = 2)

# linea media
abline(v = mean(studenti_clean$overall_score), col = "red", lwd = 2)
```


Distribuzione overall_score



```
# ECDF
plot(ecdf(studenti_clean$overall_score),
     main = "ECDF overall_score")
```

```
# QQ plot  
qqnorm(studenti_clean$overall_score)  
qqline(studenti_clean$overall_score, col = "red")
```



Risposte

- L'istogramma mostra una distribuzione **circa simmetrica e unimodale**, con forma simile a una distribuzione normale.
- La curva di densità conferma una buona approssimazione a una distribuzione normale, con valori concentrati intorno alla media.
- La funzione di ripartizione empirica (ECDF) presenta un andamento regolare e crescente, coerente con una distribuzione continua.
- Il grafico quantile-quantile (QQ plot) mostra che i punti sono generalmente allineati alla retta, con leggere deviazioni nelle code.

Si può quindi concludere che la distribuzione di `overall_score` è **approssimativamente normale**.
