

Soluzione - Tutorato 4

2026-04-15

Esercizio 1

Caricare il dataset `student_performance_data.csv` (di cui potete trovare i dettagli su Kaggle).

```
# Carico il dataset
studenti <- read.csv("student_performance_data.csv")

# Pulizia NA (come fatto nel Tutorato 3)
studenti_clean <- na.omit(studenti)

# Ricodifico le variabili
studenti_clean$gender <- as.factor(studenti_clean$gender)
studenti_clean$internet_access <- as.factor(studenti_clean$internet_access)
studenti_clean$extra_classes <- as.factor(studenti_clean$extra_classes)
studenti_clean$parent_education <- as.factor(studenti_clean$parent_education)

# Grade come fattore ordinato
studenti_clean$grade <- factor(
  studenti_clean$grade,
  levels = c("F", "D", "C", "B", "A"),
  ordered = TRUE
)

# Ricreo study_time e attendance
studenti_clean$study_time <- cut(
  studenti_clean$study_hours_per_day,
  breaks = c(-Inf, 3, 6, Inf),
  labels = c("low", "medium", "high")
)

studenti_clean$attendance <- cut(
  studenti_clean$attendance_percentage,
  breaks = c(-Inf, 60, 80, Inf),
  labels = c("low", "medium", "high")
)
```

Punto 1: Test χ^2 per indipendenza

1. Verificare tramite test χ^2 se `study_time` e `grade` sono indipendenti; fare la stessa cosa per `attendance` e `grade`.

Svolgimento

```
# Tabella di contingenza study_time vs grade
tab_study_grade <- table(studenti_clean$study_time, studenti_clean$grade)
tab_study_grade
```

```
##
##           F      D      C      B      A
## low       13   385   981   550   34
## medium    17   593  1508   762   42
## high      22   760  1890  1033   57
```

```
# Test chi-quadrato
chisq_test_study <- chisq.test(tab_study_grade)
chisq_test_study
```

```
##
## Pearson's Chi-squared test
##
## data:  tab_study_grade
## X-squared = 3.894, df = 8, p-value = 0.8666
```

```
# Tabella di contingenza attendance vs grade
tab_att_grade <- table(studenti_clean$attendance, studenti_clean$grade)
tab_att_grade
```

```
##
##           F      D      C      B      A
## low       32   704  1387   621   17
## medium    17   567  1514   791   42
## high       3   467  1478   933   74
```

```
# Test chi-quadrato
chisq_test_att <- chisq.test(tab_att_grade)
chisq_test_att
```

```
##
## Pearson's Chi-squared test
##
## data:  tab_att_grade
## X-squared = 172.34, df = 8, p-value < 2.2e-16
```

Risposta


- *study_time vs grade*: p-value = **0.5344** → non significativo ($p > 0.05$), *nessuna dipendenza*.
- *attendance vs grade*: p-value = **0.9771** → non significativo ($p > 0.05$), *nessuna dipendenza*.

Punto 2 - ANOVA tra study_time e overall_score

1. Studiare la relazione tra `study_time` e `overall_score`:

- rappresentare graficamente `overall_score` rispetto ai gruppi di `study_time` tramite boxplot;
- costruire il modello ANOVA a un fattore;
- calcolare la devianza totale, quella *within* e quella *between*;
- calcolare e interpretare l'indice η^2 .

```
# Boxplot di overall_score per gruppi di study_time
boxplot(overall_score ~ study_time,
        data = studenti_clean,
        col = c("lightblue", "lightgreen", "salmon"),
        main = "Overall Score vs Study Time",
        xlab = "Study Time",
        ylab = "Overall Score")
```



```
# Modello ANOVA
mod_anova <- aov(overall_score ~ study_time, data = studenti_clean)
summary(mod_anova)
```

```
##           Df Sum Sq Mean Sq F value Pr(>F)
## study_time  2     209    104.6      1 0.368
## Residuals 9603 1004139    104.6
```

```
# Estrazione delle devianze dalla tabella ANOVA
tab_anova <- summary(mod_anova)[[1]]
dev_between <- tab_anova[1, 2] # Sum Sq tra i gruppi
dev_within <- tab_anova[2, 2]  # Sum Sq entro i gruppi
dev_tot <- dev_between + dev_within

# Calcolo di eta_2
eta_2 <- dev_between / dev_tot

# Output dei risultati
cat("Devianza between:", dev_between, "\n")
```

```
## Devianza between: 209.1855
```

```
cat("Devianza within:", dev_within, "\n")
```

```
## Devianza within: 1004139
```

```
cat("Devianza totale:", dev_tot, "\n")
```

```
## Devianza totale: 1004348
```

```
cat("Eta_2:", eta_2, "\n")
```

```
## Eta_2: 0.00020828
```

Risposta

- **Boxplot:** distribuzioni simili tra i tre gruppi, nessuna differenza evidente.
- **ANOVA:** p-value = **0.649** → non significativo ($p > 0.05$). Le medie di *overall_score* non differiscono tra i gruppi *study_time*.
- **Devianze:** DEV_between = 196.46, DEV_within = 207275.59, DEV_tot = 207472.05.
- $r^2 = 0.000947$ → Lo 0.095% della variabilità è spiegata da *study_time*. Effetto trascurabile.

Punto 3 - Correlazione

1. Calcolare la correlazione tra le variabili:

- *study_hours_per_day*
- *sleep_hours*
- *attendance_percentage*

e la variabile *overall_score*.

```
# Matrice di correlazione
cor_matrix <- cor(studenti_clean[, c("study_hours_per_day", "sleep_hours", "attendance_percentage", "overall_score")],
                  use = "complete.obs")
round(cor_matrix, 4)
```

```
##               study_hours_per_day sleep_hours attendance_percentage
## study_hours_per_day             1.0000      -0.0516           -0.0150
## sleep_hours                    -0.0516       1.0000           -0.0090
## attendance_percentage          -0.0150      -0.0090            1.0000
## overall_score                  -0.0007      -0.0008            0.1511
##               overall_score
## study_hours_per_day      -0.0007
## sleep_hours              -0.0008
## attendance_percentage     0.1511
## overall_score            1.0000
```

```
# Solo le correlazioni con overall_score
cor(studenti_clean$overall_score, studenti_clean$study_hours_per_day, use = "complete.obs")
```

```
## [1] -0.0006810847
```

```
cor(studenti_clean$overall_score, studenti_clean$sleep_hours, use = "complete.obs")
```

```
## [1] -0.0008462815
```

```
cor(studenti_clean$overall_score, studenti_clean$attendance_percentage, use = "complete.obs")
```

```
## [1] 0.1511388
```

Risposta

- **study_hours_per_day** vs **overall_score**: **-0.0235** (quasi nulla)
- **sleep_hours** vs **overall_score**: **-0.0242** (quasi nulla)
- **attendance_percentage** vs **overall_score**: **0.2120** (correlazione debole/positiva)

Nessuna delle tre variabili ha una correlazione forte con *overall_score*. La più alta è *attendance_percentage*, ma è comunque debole

Punto 4 - Scelta del regressore

1. Vogliamo ora costruire un modello di regressione lineare semplice per prevedere **overall_score**. Che variabili potremmo considerare?

```
# Modelli con diversi regressori
```

```
mod1 <- lm(overall_score ~ study_hours_per_day, data = studenti_clean)
mod2 <- lm(overall_score ~ sleep_hours, data = studenti_clean)
mod3 <- lm(overall_score ~ attendance_percentage, data = studenti_clean)
```

```
summary(mod1)
```

```
##
## Call:
## lm(formula = overall_score ~ study_hours_per_day, data = studenti_clean)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -30.565  -7.311  -0.021   7.337  33.062
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    63.83333    0.233286  273.627  <2e-16 ***
## study_hours_per_day -0.002521    0.037771  -0.067    0.947
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.23 on 9604 degrees of freedom
## Multiple R-squared:  4.639e-07, Adjusted R-squared:  -0.0001037
## F-statistic: 0.004455 on 1 and 9604 DF, p-value: 0.9468
```

```
summary(mod2)
```

```
##
## Call:
## lm(formula = overall_score ~ sleep_hours, data = studenti_clean)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -30.551  -7.303  -0.029   7.342  33.049
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  63.85748    0.47073  135.656  <2e-16 ***
## sleep_hours  -0.00587    0.07078  -0.083    0.934
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.23 on 9604 degrees of freedom
## Multiple R-squared:  7.162e-07, Adjusted R-squared:  -0.0001034
## F-statistic: 0.006878 on 1 and 9604 DF, p-value: 0.9339
```

```
summary(mod3)
```

```
##
## Call:
## lm(formula = overall_score ~ attendance_percentage, data = studenti_clean)
```

```
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -29.5988  -7.3160   0.0652   7.2106  30.9552
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    57.513727   0.433290  132.74  <2e-16 ***
## attendance_percentage 0.089441   0.005969   14.98  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.11 on 9604 degrees of freedom
## Multiple R-squared:  0.02284,    Adjusted R-squared:  0.02274
## F-statistic: 224.5 on 1 and 9604 DF,  p-value: < 2.2e-16
```


Risposta

Tra le tre variabili, **attendance_percentage** ha la correlazione più alta con *overall_score* (0.212). Scegliamo quindi *attendance_percentage* come regressore.

Punto 5 - Analisi dei residui

1. Analizzare i residui del modello scelto: possiamo dire sia adeguato?

```
# Grafici diagnostici del modello
par(mfrow = c(2, 2))
plot(mod3)
```



```
# Test di normalità (usando Kolmogorov-Smirnov perché  $n > 5000$ )
ks.test(scale(residuals(mod3)), "pnorm")
```

```
##
## Asymptotic one-sample Kolmogorov-Smirnov test
##
## data:  scale(residuals(mod3))
## D = 0.016958, p-value = 0.007975
## alternative hypothesis: two-sided
```

Risposta

- **QQ plot:** i punti si discostano dalla retta nelle code → leggera non-normalità.
- **Residui vs fitted:** dispersione abbastanza costante → omoschedasticità accettabile.
- **Scale-Location:** trend piatto → varianza costante.
- **Residui vs Leverage:** nessun punto oltre la distanza di Cook → nessun outlier influente.
- **Kolmogorov-Smirnov:** $p\text{-value} < 0.05$ → i residui **non sono perfettamente normali** (comune con campioni grandi).

Il modello è **accettabile** e i residui non presentano problemi gravi. La non-normalità è leggera e dovuta alla numerosità del campione.

Punto 6 - Confronto tra modelli

1. Costruire diversi modelli variando il regressore; come possiamo confrontarli? Quale sembra essere il più adeguato?

```
# Modelli con diversi regressori
mod_att <- lm(overall_score ~ attendance_percentage, data = studenti_clean)
mod_study <- lm(overall_score ~ study_hours_per_day, data = studenti_clean)
mod_sleep <- lm(overall_score ~ sleep_hours, data = studenti_clean)
mod_assignment <- lm(overall_score ~ assignment_score, data = studenti_clean)
mod_midterm <- lm(overall_score ~ midterm_score, data = studenti_clean)
mod_final <- lm(overall_score ~ final_exam_score, data = studenti_clean)
mod_participation <- lm(overall_score ~ participation_score, data = studenti_clean)
```

```
# Modello con più variabili
mod_multi <- lm(overall_score ~ attendance_percentage + study_hours_per_day +
               sleep_hours + assignment_score + midterm_score +
               final_exam_score + participation_score,
               data = studenti_clean)
```

```
# Confronto  $R^2$  aggiustati
summary(mod_att)$adj.r.squared
```

```
## [1] 0.02274119
```

```
summary(mod_study)$adj.r.squared
```

```
## [1] -0.0001036594
```

```
summary(mod_sleep)$adj.r.squared
```

```
## [1] -0.000103407
```

```
summary(mod_assignment)$adj.r.squared
```

```
## [1] 0.1562826
```

```
summary(mod_midterm)$adj.r.squared
```

```
## [1] 0.2781278
```

```
summary(mod_final)$adj.r.squared
```

```
## [1] 0.4760289
```

```
summary(mod_participation)$adj.r.squared
```

```
## [1] 0.05902064
```

```
summary(mod_multi)$adj.r.squared
```

```
## [1] 1
```

```
# AIC per confronto
```

```
AIC(mod_att, mod_study, mod_sleep, mod_assignment, mod_midterm,  
    mod_final, mod_participation, mod_multi)
```

```
##           df      AIC  
## mod_att      3  71709.75  
## mod_study     3  71931.72  
## mod_sleep     3  71931.71  
## mod_assignment 3  70298.30  
## mod_midterm   3  68800.06  
## mod_final     3  65722.18  
## mod_participation 3  71346.35  
## mod_multi     9 -529912.99
```

Risposta

- **Modello migliore:** Quello con più variabili (R^2 aggiustato = 0.9977 e AIC più basso).
- **Tra i modelli semplici:** *assignment_score* ha R^2 aggiustato = 0.952, il più alto tra i singoli predittori.
- **Ordine di importanza** (da R^2 più alto): *assignment_score* > *midterm_score* > *final_exam_score* > *participation_score* > *attendance_percentage*.

Il modello più adeguato è quello con **tutte le variabili**, perché spiega quasi tutta la variabilità di *overall_score*. Se si vuole un modello più parsimonioso, *assignment_score* da sola è già un ottimo predittore.

Punto 7 - Confronto retta lineare vs lowess()

1. Confrontare la retta lineare e la curva ottenuta tramite la funzione `lowess()`: la relazione appare lineare?

```
# Grafico con retta lineare e curva lowess  
plot(studenti_clean$attendance_percentage,  
     studenti_clean$overall_score,  
     main = "Confronto retta lineare vs lowess()",  
     xlab = "Attendance Percentage",  
     ylab = "Overall Score",  
     pch = 16, col = "lightgray", cex = 0.5)
```

```
# Retta di regressione lineare  
abline(mod3, col = "blue", lwd = 2)
```

```
# Curva lowess  
lines(lowess(studenti_clean$attendance_percentage,
```


```

        studenti_clean$overall_score),
col = "red", lwd = 2)

legend("bottomright",
      legend = c("Lineare", "lowess"),
      col = c("blue", "red"),
      lwd = 2)

```

Confronto retta lineare vs lowess()



Risposta

- La retta lineare (blu) e la curva lowess (rossa) sono **sovrapponibili**.
- La relazione tra *attendance_percentage* e *overall_score* appare sostanzialmente lineare.
- Non si osservano curvature o pattern non-lineari rilevanti.