

Tutorato 5

Sara Trabucco

20 Maggio 2026

Caricare il dataset `marketing_campaign.csv` (che trovate anche su Kaggle); poi:

Preprocessing del dataset

- Classificare le principali variabili del dataset; che variabili potrebbero essere più adatte ad una cluster analysis (considerando che l'obiettivo è una *customer personality analysis*, utile per le aziende per comprendere la propria clientela)?
- Verificare la presenza di valori mancanti (dove compaiono, quanti sono, etc.) e rimuoverli dal dataset;
- Analizzare le variabili qualitative, trasformarle in factor e ricodificare i livelli;
- Creare le variabili:
 - `Age` (età del cliente)
 - `Total_spending` (spesa totale su tutti i prodotti)
 - `Total_purchases` (numero totale degli acquisti)
- Standardizzare (ove opportuno) le variabili;

Analisi esplorativa

- Considerare le variabili `Income`, `Age`, `Total_spending`, `Total_purchases`, `NumWebVisitsMonth` e calcolare indici di posizione, indici di dispersione, rappresentarne graficamente la distribuzione e analizzare eventuali outlier;
- Costruire scatterplot e matrice di correlazione tra le principali variabili quantitative; che relazioni emergono?
- Calcolare la matrice delle distanze utilizzando la distanza euclidea e distanza di Manhattan;
- Che misura di *dissimilarità* è appropriato usare con variabili qualitative?

Clustering gerarchico

- Applicare clustering gerarchico utilizzando *single linkage*, *complete linkage*, *average linkage* e *Ward*;
- Per ciascun metodo rappresentare il dendrogramma; cosa si può osservare?
- Utilizzando il metodo di Ward, scegliere un numero appropriato di cluster;

K-means

- Applicare l'algoritmo K-means ai dati standardizzati; determinare un numero appropriato di cluster considerando:
 - il *metodo del gomito* (Elbow Method);

- il *silhouette score*;
- Una volta scelto K:
 - rappresentare graficamente i cluster;
 - analizzare i centroidi;

PAM

- Applicare PAM agli stessi dati; confrontare poi PAM e K-means rispetto alla robustezza agli outlier, interpretabilità e struttura dei cluster;
- Applicare PAM utilizzando una matrice di dissimilarità basata su Gower e confrontare i risultati con PAM ottenuto al punto precedente;

DBSCAN

- Applicare DBSCAN scegliendo *opportunamente* **eps** e **minPts**; identificare cluster e rumore e identificare graficamente i risultati.
- DBSCAN individua clienti anomali? Quali vantaggi ha rispetto a K-means?

PCA

- Applicare l'analisi delle componenti principali (PCA) ai dati standardizzati;
- Si produca un grafico contenente la fedeltà della proiezione per numero di componenti e le osservazioni sulle prime due componenti;
- Rappresentare i cluster ottenuti tramite K-means sulle prime due componenti: emergono gruppi chiaramente separati?

Confronto tra algoritmi

- Confrontare:
 - clustering gerarchico
 - K-means
 - PAM
 - DBSCAN
 utilizzando silhouette, dimensione dei cluster, interpretabilità e sensibilità agli outlier.
- Quale algoritmo sembra essere più adatto per questo dataset?