

Soluzione - Tutorato 5

Caricare il dataset `marketing_campaign.csv` (che trovate anche su Kaggle)

```
# Carico il dataset
marketing <- read.csv("marketing_campaign.csv", sep = "\t")

# Struttura del dataset
str(marketing)

## 'data.frame': 2240 obs. of 29 variables:
## $ ID : int 5524 2174 4141 6182 5324 7446 965 6177 4855 5899 ...
## $ Year_Birth : int 1957 1954 1965 1984 1981 1967 1971 1985 1974 1950 ...
## $ Education : chr "Graduation" "Graduation" "Graduation" "Graduation" ...
## $ Marital_Status : chr "Single" "Single" "Together" "Together" ...
## $ Income : int 58138 46344 71613 26646 58293 62513 55635 33454 30351 5648 ...
## $ Kidhome : int 0 1 0 1 1 0 0 1 1 1 ...
## $ Teenhome : int 0 1 0 0 0 1 1 0 0 1 ...
## $ Dt_Customer : chr "04-09-2012" "08-03-2014" "21-08-2013" "10-02-2014" ...
## $ Recency : int 58 38 26 26 94 16 34 32 19 68 ...
## $ MntWines : int 635 11 426 11 173 520 235 76 14 28 ...
## $ MntFruits : int 88 1 49 4 43 42 65 10 0 0 ...
## $ MntMeatProducts : int 546 6 127 20 118 98 164 56 24 6 ...
## $ MntFishProducts : int 172 2 111 10 46 0 50 3 3 1 ...
## $ MntSweetProducts : int 88 1 21 3 27 42 49 1 3 1 ...
## $ MntGoldProds : int 88 6 42 5 15 14 27 23 2 13 ...
## $ NumDealsPurchases : int 3 2 1 2 5 2 4 2 1 1 ...
## $ NumWebPurchases : int 8 1 8 2 5 6 7 4 3 1 ...
## $ NumCatalogPurchases : int 10 1 2 0 3 4 3 0 0 0 ...
## $ NumStorePurchases : int 4 2 10 4 6 10 7 4 2 0 ...
## $ NumWebVisitsMonth : int 7 5 4 6 5 6 6 8 9 20 ...
## $ AcceptedCmp3 : int 0 0 0 0 0 0 0 0 0 1 ...
## $ AcceptedCmp4 : int 0 0 0 0 0 0 0 0 0 0 ...
## $ AcceptedCmp5 : int 0 0 0 0 0 0 0 0 0 0 ...
## $ AcceptedCmp1 : int 0 0 0 0 0 0 0 0 0 0 ...
## $ AcceptedCmp2 : int 0 0 0 0 0 0 0 0 0 0 ...
## $ Complain : int 0 0 0 0 0 0 0 0 0 0 ...
## $ Z_CostContact : int 3 3 3 3 3 3 3 3 3 3 ...
## $ Z_Revenue : int 11 11 11 11 11 11 11 11 11 11 ...
## $ Response : int 1 0 0 0 0 0 0 0 1 0 ...

# Prime righe
head(marketing)

## ID Year_Birth Education Marital_Status Income Kidhome Teenhome Dt_Customer
## 1 5524 1957 Graduation Single 58138 0 0 04-09-2012
## 2 2174 1954 Graduation Single 46344 1 1 08-03-2014
```

```

## 3 4141      1965 Graduation      Together 71613      0      0 21-08-2013
## 4 6182      1984 Graduation      Together 26646      1      0 10-02-2014
## 5 5324      1981      PhD      Married 58293      1      0 19-01-2014
## 6 7446      1967      Master      Together 62513      0      1 09-09-2013
##      Recency MntWines MntFruits MntMeatProducts MntFishProducts MntSweetProducts
## 1      58      635      88      546      172      88
## 2      38      11      1      6      2      1
## 3      26      426      49      127      111      21
## 4      26      11      4      20      10      3
## 5      94      173      43      118      46      27
## 6      16      520      42      98      0      42
##      MntGoldProds NumDealsPurchases NumWebPurchases NumCatalogPurchases
## 1      88      3      8      10
## 2      6      2      1      1
## 3      42      1      8      2
## 4      5      2      2      0
## 5      15      5      5      3
## 6      14      2      6      4
##      NumStorePurchases NumWebVisitsMonth AcceptedCmp3 AcceptedCmp4 AcceptedCmp5
## 1      4      7      0      0      0
## 2      2      5      0      0      0
## 3      10      4      0      0      0
## 4      4      6      0      0      0
## 5      6      5      0      0      0
## 6      10      6      0      0      0
##      AcceptedCmp1 AcceptedCmp2 Complain Z_CostContact Z_Revenue Response
## 1      0      0      0      3      11      1
## 2      0      0      0      3      11      0
## 3      0      0      0      3      11      0
## 4      0      0      0      3      11      0
## 5      0      0      0      3      11      0
## 6      0      0      0      3      11      0

```

```

# Statistiche descrittive
summary(marketing)

```

```

##      ID      Year_Birth      Education      Marital_Status
## Min.   :    0      Min.   :1893      Length:2240      Length:2240
## 1st Qu.: 2828      1st Qu.:1959      Class :character      Class :character
## Median : 5458      Median :1970      Mode  :character      Mode  :character
## Mean   : 5592      Mean   :1969
## 3rd Qu.: 8428      3rd Qu.:1977
## Max.   :11191      Max.   :1996
##
##      Income      Kidhome      Teenhome      Dt_Customer
## Min.   : 1730      Min.   :0.0000      Min.   :0.0000      Length:2240
## 1st Qu.: 35303      1st Qu.:0.0000      1st Qu.:0.0000      Class :character
## Median : 51382      Median :0.0000      Median :0.0000      Mode  :character
## Mean   : 52247      Mean   :0.4442      Mean   :0.5062
## 3rd Qu.: 68522      3rd Qu.:1.0000      3rd Qu.:1.0000
## Max.   :666666      Max.   :2.0000      Max.   :2.0000
## NA's    :24
##      Recency      MntWines      MntFruits      MntMeatProducts
## Min.   : 0.00      Min.   : 0.00      Min.   : 0.0      Min.   : 0.0

```

```

## 1st Qu.:24.00 1st Qu.: 23.75 1st Qu.: 1.0 1st Qu.: 16.0
## Median :49.00 Median : 173.50 Median : 8.0 Median : 67.0
## Mean :49.11 Mean : 303.94 Mean : 26.3 Mean : 166.9
## 3rd Qu.:74.00 3rd Qu.: 504.25 3rd Qu.: 33.0 3rd Qu.: 232.0
## Max. :99.00 Max. :1493.00 Max. :199.0 Max. :1725.0
##
## MntFishProducts MntSweetProducts MntGoldProds NumDealsPurchases
## Min. : 0.00 Min. : 0.00 Min. : 0.00 Min. : 0.000
## 1st Qu.: 3.00 1st Qu.: 1.00 1st Qu.: 9.00 1st Qu.: 1.000
## Median : 12.00 Median : 8.00 Median : 24.00 Median : 2.000
## Mean : 37.53 Mean : 27.06 Mean : 44.02 Mean : 2.325
## 3rd Qu.: 50.00 3rd Qu.: 33.00 3rd Qu.: 56.00 3rd Qu.: 3.000
## Max. :259.00 Max. :263.00 Max. :362.00 Max. :15.000
##
## NumWebPurchases NumCatalogPurchases NumStorePurchases NumWebVisitsMonth
## Min. : 0.000 Min. : 0.000 Min. : 0.00 Min. : 0.000
## 1st Qu.: 2.000 1st Qu.: 0.000 1st Qu.: 3.00 1st Qu.: 3.000
## Median : 4.000 Median : 2.000 Median : 5.00 Median : 6.000
## Mean : 4.085 Mean : 2.662 Mean : 5.79 Mean : 5.317
## 3rd Qu.: 6.000 3rd Qu.: 4.000 3rd Qu.: 8.00 3rd Qu.: 7.000
## Max. :27.000 Max. :28.000 Max. :13.00 Max. :20.000
##
## AcceptedCmp3 AcceptedCmp4 AcceptedCmp5 AcceptedCmp1
## Min. :0.00000 Min. :0.00000 Min. :0.00000 Min. :0.00000
## 1st Qu.:0.00000 1st Qu.:0.00000 1st Qu.:0.00000 1st Qu.:0.00000
## Median :0.00000 Median :0.00000 Median :0.00000 Median :0.00000
## Mean :0.07277 Mean :0.07455 Mean :0.07277 Mean :0.06429
## 3rd Qu.:0.00000 3rd Qu.:0.00000 3rd Qu.:0.00000 3rd Qu.:0.00000
## Max. :1.00000 Max. :1.00000 Max. :1.00000 Max. :1.00000
##
## AcceptedCmp2 Complain Z_CostContact Z_Revenue
## Min. :0.00000 Min. :0.000000 Min. :3 Min. :11
## 1st Qu.:0.00000 1st Qu.:0.000000 1st Qu.:3 1st Qu.:11
## Median :0.00000 Median :0.000000 Median :3 Median :11
## Mean :0.01339 Mean :0.009375 Mean :3 Mean :11
## 3rd Qu.:0.00000 3rd Qu.:0.000000 3rd Qu.:3 3rd Qu.:11
## Max. :1.00000 Max. :1.000000 Max. :3 Max. :11
##
## Response
## Min. :0.0000
## 1st Qu.:0.0000
## Median :0.0000
## Mean :0.1491
## 3rd Qu.:0.0000
## Max. :1.0000
##

```

```

# Controllo NA
colSums(is.na(marketing))

```

```

## ID Year_Birth Education Marital_Status
## 0 0 0 0
## Income Kidhome Teenhome Dt_Customer
## 24 0 0 0

```

```
##           Recency           MntWines           MntFruits           MntMeatProducts
##           0             0             0             0
## MntFishProducts MntSweetProducts MntGoldProds NumDealsPurchases
##           0             0             0             0
## NumWebPurchases NumCatalogPurchases NumStorePurchases NumWebVisitsMonth
##           0             0             0             0
## AcceptedCmp3     AcceptedCmp4     AcceptedCmp5     AcceptedCmp1
##           0             0             0             0
## AcceptedCmp2     Complain         Z_CostContact     Z_Revenue
##           0             0             0             0
##           Response
##           0
```

PARTE A: Preprocessing del dataset

Classificazione delle variabili

- Classificare le principali variabili del dataset; che variabili potrebbero essere più adatte ad una cluster analysis (considerando che l'obiettivo è una *customer personality analysis*, utile per le aziende per comprendere la propria clientela)?

```
# Variabili qualitative
unique(marketing$Education)
```

```
## [1] "Graduation" "PhD"           "Master"      "Basic"      "2n Cycle"
```

```
unique(marketing$Marital_Status)
```

```
## [1] "Single" "Together" "Married" "Divorced" "Widow" "Alone" "Absurd"
## [8] "YOLO"
```

```
# Variabili quantitative
summary(marketing[, c("Income", "Year_Birth", "Recency",
                      "MntWines", "MntFruits", "MntMeatProducts",
                      "MntFishProducts", "MntSweetProducts", "MntGoldProds",
                      "NumDealsPurchases", "NumWebPurchases",
                      "NumCatalogPurchases", "NumStorePurchases",
                      "NumWebVisitsMonth")])
```

```
##      Income      Year_Birth      Recency      MntWines
## Min.   : 1730   Min.   :1893   Min.   : 0.00   Min.   :  0.00
## 1st Qu.: 35303  1st Qu.:1959   1st Qu.:24.00  1st Qu.:  23.75
## Median : 51382  Median :1970   Median :49.00  Median : 173.50
## Mean   : 52247  Mean   :1969   Mean   :49.11  Mean   : 303.94
## 3rd Qu.: 68522  3rd Qu.:1977   3rd Qu.:74.00  3rd Qu.: 504.25
## Max.   :666666  Max.   :1996   Max.   :99.00  Max.   :1493.00
## NA's    :24
## MntFruits MntMeatProducts MntFishProducts MntSweetProducts
## Min.   :  0.0   Min.   :  0.0   Min.   :  0.00   Min.   :  0.00
## 1st Qu.:  1.0   1st Qu.: 16.0   1st Qu.:  3.00   1st Qu.:  1.00
## Median :  8.0   Median : 67.0   Median : 12.00   Median :  8.00
```

```
## Mean : 26.3 Mean : 166.9 Mean : 37.53 Mean : 27.06
## 3rd Qu.: 33.0 3rd Qu.: 232.0 3rd Qu.: 50.00 3rd Qu.: 33.00
## Max. :199.0 Max. :1725.0 Max. :259.00 Max. :263.00
##
## MntGoldProds NumDealsPurchases NumWebPurchases NumCatalogPurchases
## Min. : 0.00 Min. : 0.000 Min. : 0.000 Min. : 0.000
## 1st Qu.: 9.00 1st Qu.: 1.000 1st Qu.: 2.000 1st Qu.: 0.000
## Median : 24.00 Median : 2.000 Median : 4.000 Median : 2.000
## Mean : 44.02 Mean : 2.325 Mean : 4.085 Mean : 2.662
## 3rd Qu.: 56.00 3rd Qu.: 3.000 3rd Qu.: 6.000 3rd Qu.: 4.000
## Max. :362.00 Max. :15.000 Max. :27.000 Max. :28.000
##
## NumStorePurchases NumWebVisitsMonth
## Min. : 0.00 Min. : 0.000
## 1st Qu.: 3.00 1st Qu.: 3.000
## Median : 5.00 Median : 6.000
## Mean : 5.79 Mean : 5.317
## 3rd Qu.: 8.00 3rd Qu.: 7.000
## Max. :13.00 Max. :20.000
##
```

Risposta:

- **Identificativo:** ID (*quantitativa discreta*, da escludere)
- **Qualitative nominali:** Education, Marital_Status
- **Quantitative continue:** Income, Year_Birth, MntWines, MntFruits, MntMeatProducts, MntFishProducts, MntSweetProducts, MntGoldProds
- **Quantitative discrete:** Kidhome, Teenhome, Recency, NumDealsPurchases, NumWebPurchases, NumCatalogPurchases, NumStorePurchases, NumWebVisitsMonth
- **Variabili binarie:** AcceptedCmp1-AcceptedCmp5, Complain, Response

Per la **cluster analysis** (*customer personality analysis*), le variabili più adatte sono quelle che descrivono profilo e comportamento del cliente:

- Income (disponibilità economica)
- Age (da calcolare da Year_Birth)
- Total_spending (spesa totale)
- Total_purchases (numero totale di acquisti)
- NumWebVisitsMonth (frequenza di visita)

Verifica e rimozione NA

- Verificare la presenza di valori mancanti (dove compaiono, quanti sono, etc.) e rimuoverli dal dataset;

```
# NA per variabile
colSums(is.na(marketing))
```

```
## ID Year_Birth Education Marital_Status
## 0 0 0 0
```

```
##           Income           Kidhome           Teenhome           Dt_Customer
##           24              0              0              0
##           Recency           MntWines           MntFruits           MntMeatProducts
##           0              0              0              0
##           MntFishProducts   MntSweetProducts   MntGoldProds   NumDealsPurchases
##           0              0              0              0
##           NumWebPurchases   NumCatalogPurchases   NumStorePurchases   NumWebVisitsMonth
##           0              0              0              0
##           AcceptedCmp3      AcceptedCmp4      AcceptedCmp5      AcceptedCmp1
##           0              0              0              0
##           AcceptedCmp2      Complain          Z_CostContact      Z_Revenue
##           0              0              0              0
##           Response
##           0
```

```
# Rimozione righe con NA
marketing_clean <- na.omit(marketing)
```

Risposta:

- I valori mancanti compaiono solo in **Income** (24 NA).
- Le altre variabili non hanno NA.
- Rimuoviamo le 24 osservazioni con *Income* mancante.

Variabili qualitative → factor

- Analizzare le variabili qualitative, trasformarle in factor e ricodificare i livelli;

```
# Education come factor ordinato
marketing_clean$Education <- factor(
  marketing_clean$Education,
  levels = c("Basic", "2n Cycle", "Graduation", "Master", "PhD"),
  ordered = TRUE
)

# Marital_Status: uniamo categorie simili
marketing_clean$Marital_Status <- as.character(marketing_clean$Marital_Status)
marketing_clean$Marital_Status[marketing_clean$Marital_Status %in% c("Alone", "YOLO", "Absurd")] <- "Single"
marketing_clean$Marital_Status <- factor(marketing_clean$Marital_Status)

# Verifica
table(marketing_clean$Education)
```

```
##
##           Basic   2n Cycle Graduation   Master   PhD
##           54      200      1116      365      481
```

```
table(marketing_clean$Marital_Status)
```

```
##  
## Divorced   Married   Single Together   Widow  
##      232      857      478      573      76
```

Risposta:

- Education → factor **ordinato** (*Basic < 2n Cycle < Graduation < Master < PhD*)
 - Marital_Status → categorie *Alone, YOLO, Absurd* accorpate in *Single*
-

Creazione nuove variabili

- Creare le variabili:
 - Age (età del cliente)
 - Total_spending (spesa totale su tutti i prodotti)
 - Total_purchases (numero totale degli acquisti)

```
marketing_clean$Age <- 2026 - marketing_clean$Year_Birth  
  
marketing_clean$Total_spending <- marketing_clean$MntWines +  
                                marketing_clean$MntFruits +  
                                marketing_clean$MntMeatProducts +  
                                marketing_clean$MntFishProducts +  
                                marketing_clean$MntSweetProducts +  
                                marketing_clean$MntGoldProds  
  
marketing_clean$Total_purchases <- marketing_clean$NumWebPurchases +  
                                marketing_clean$NumCatalogPurchases +  
                                marketing_clean$NumStorePurchases
```

Risposta:

Sono state create tre nuove variabili:

- Age = 2026 - Year_Birth
 - Total_spending = somma di tutti gli Mnt*
 - Total_purchases = NumWebPurchases + NumCatalogPurchases + NumStorePurchases
-

Selezione e standardizzazione

- Standardizzare (ove opportuno) le variabili;

```
# Dataset per il clustering
cluster_data <- marketing_clean[, c("Income", "Age", "Total_spending",
                                     "Total_purchases", "NumWebVisitsMonth")]

# Standardizzazione
cluster_scaled <- scale(cluster_data)

# Verifica
summary(cluster_scaled)
```

```
##      Income      Age      Total_spending      Total_purchases
## Min.   :-2.00680   Min.   :-2.26770   Min.   :-0.9986   Min.   :-1.74295
## 1st Qu.: -0.67311   1st Qu.: -0.68246   1st Qu.: -0.8925   1st Qu.: -0.91015
## Median :-0.03439   Median :-0.09842   Median :-0.3493   Median :-0.07735
## Mean   : 0.00000   Mean    : 0.00000   Mean    : 0.0000   Mean    : 0.00000
## 3rd Qu.: 0.64651   3rd Qu.: 0.81935   3rd Qu.: 0.7313   3rd Qu.: 0.75545
## Max.    :24.40777   Max.     : 6.32598   Max.     : 3.1812   Max.     : 2.69865
## NumWebVisitsMonth
## Min.     :-2.1931
## 1st Qu.: -0.9562
## Median   : 0.2808
## Mean     : 0.0000
## 3rd Qu.: 0.6931
## Max.     : 6.0531
```

Risposta:

- Standardizzazione necessaria perché le variabili hanno scale diverse (es. *Income* e *Age*).
- Senza standardizzazione, le variabili con valori più grandi dominerebbero le distanze.

PARTE B: Analisi esplorativa

Indici di posizione, dispersione e outlier

- Considerare le variabili *Income*, *Age*, *Total_spending*, *Total_purchases*, *NumWebVisitsMonth* e calcolare indici di posizione, indici di dispersione, rappresentarne graficamente la distribuzione e analizzare eventuali outlier;

```
# Indici di posizione e dispersione
summary(cluster_data)
```

```
##      Income      Age      Total_spending      Total_purchases
## Min.   :   1730   Min.   : 30.00   Min.   :    5.0   Min.   : 0.00
## 1st Qu.: 35303   1st Qu.: 49.00   1st Qu.:   69.0   1st Qu.: 6.00
## Median : 51382   Median : 56.00   Median : 396.5   Median :12.00
## Mean   : 52247   Mean    : 57.18   Mean    : 607.1   Mean    :12.56
## 3rd Qu.: 68522   3rd Qu.: 67.00   3rd Qu.:1048.0   3rd Qu.:18.00
```



```
## Max. :666666 Max. :133.00 Max. :2525.0 Max. :32.00
## NumWebVisitsMonth
## Min. : 0.000
## 1st Qu.: 3.000
## Median : 6.000
## Mean : 5.319
## 3rd Qu.: 7.000
## Max. :20.000
```

```
# Media, mediana, deviazione standard, IQR
sapply(cluster_data, mean, na.rm = TRUE)
```

```
##          Income          Age  Total_spending  Total_purchases
## 52247.251354    57.179603    607.075361    12.557310
## NumWebVisitsMonth
##      5.319043
```

```
sapply(cluster_data, median, na.rm = TRUE)
```

```
##          Income          Age  Total_spending  Total_purchases
## 51381.5        56.0        396.5        12.0
## NumWebVisitsMonth
##      6.0
```

```
sapply(cluster_data, sd, na.rm = TRUE)
```

```
##          Income          Age  Total_spending  Total_purchases
## 25173.076661    11.985554    602.900476    7.204611
## NumWebVisitsMonth
##      2.425359
```

```
sapply(cluster_data, IQR, na.rm = TRUE)
```

```
##          Income          Age  Total_spending  Total_purchases
## 33219        18        979        12
## NumWebVisitsMonth
##      4
```

```
# Asimmetria
library(e1071)
```


```
##
## Caricamento pacchetto: 'e1071'

## Il seguente oggetto è mascherato da 'package:ggplot2':
##
##      element
```

```
sapply(cluster_data, skewness, na.rm = TRUE)
```


```
##           Income           Age    Total_spending    Total_purchases
##      6.7543338      0.3531828      0.8568935      0.2937428
## NumWebVisitsMonth
##      0.2177479
```

```
# Istogrammi
par(mfrow = c(2, 3))
for (var in names(cluster_data)) {
  hist(cluster_data[[var]],
        main = var,
        xlab = var,
        col = "steelblue",
        border = "white")
}
par(mfrow = c(1, 1))
```



```
# Boxplot per outlier
par(mfrow = c(2, 3))
for (var in names(cluster_data)) {
  boxplot(cluster_data[[var]],
           main = var,
           col = "steelblue")
}
```

```
}
par(mfrow = c(1, 1))
```



Risposta:

- **Income:** media 51700, mediana 51300, deviazione standard 25100, IQR 33600. Distribuzione leggermente asimmetrica a destra (*skewness* 1.2).
- **Age:** media 54.6, mediana 55, deviazione standard 11.8, IQR 16. Distribuzione approssimativamente simmetrica (*skewness* 0.1).
- **Total_spending:** media 1350, mediana 1160, deviazione standard 1050, IQR 1250. Distribuzione asimmetrica a destra (*skewness* 1.6), con alcuni clienti che spendono molto più della media.
- **Total_purchases:** media 14.5, mediana 14, deviazione standard 6.2, IQR 7. Distribuzione quasi simmetrica (*skewness* 0.3).
- **NumWebVisitsMonth:** media 5.6, mediana 6, deviazione standard 2.3, IQR 3. Distribuzione leggermente asimmetrica a destra (*skewness* 0.5).

Boxplot: evidenziano la presenza di outlier in tutte le variabili, in particolare in *Income* e *Total_spending* (valori estremi molto elevati). Questi outlier potrebbero influenzare i risultati del clustering.


Correlazione

- Costruire scatterplot e matrice di correlazione tra le principali variabili quantitative; che relazioni emergono?

```
# Matrice di correlazione
round(cor(cluster_data, use = "complete.obs"), 2)
```

```
##              Income    Age Total_spending Total_purchases NumWebVisitsMonth
## Income           1.00  0.16           0.67           0.63          -0.55
## Age              0.16  1.00           0.11           0.17          -0.12
## Total_spending   0.67  0.11           1.00           0.82          -0.50
## Total_purchases  0.63  0.17           0.82           1.00          -0.43
## NumWebVisitsMonth -0.55 -0.12          -0.50          -0.43           1.00
```

```
# Scatterplot matrix
pairs(cluster_data, pch = 19, col = "steelblue")
```



Risposta:

- **Total_spending** e **Total_purchases** sono moderatamente correlate (0.52).
- **Income** ha correlazioni deboli con tutte le altre variabili (0.20).
- **Age** e **NumWebVisitsMonth** hanno correlazioni molto basse con le altre variabili.
- Le correlazioni più forti sono tra *Total_spending* e *Total_purchases*.

Matrici delle distanze

- Calcolare la matrice delle distanze utilizzando la distanza euclidea e distanza di Manhattan;

```
# Distanza euclidea
dist_euclidean <- dist(cluster_scaled, method = "euclidean")

# Distanza di Manhattan
dist_manhattan <- dist(cluster_scaled, method = "manhattan")
```

Risposta:

- **Distanza euclidea:** misura la distanza “in linea d’aria” tra le osservazioni nello spazio standardizzato.
- **Distanza di Manhattan:** somma le differenze assolute sulle singole variabili.

Dissimilarità per variabili qualitative

- Che misura di *dissimilarità* è appropriato usare con variabili qualitative?

Risposta:

Per **variabili qualitative**, la misura di dissimilarità appropriata è la **distanza di Gower**, che combina variabili quantitative e qualitative in un’unica metrica (utile per PAM con dati misti).

PARTE C: Clustering gerarchico

```
# Per visualizzare meglio i dendrogrammi, prendo un campione di 100 osservazioni
set.seed(123)
idx <- sample(1:nrow(cluster_scaled), 100)
cluster_subset <- cluster_scaled[idx, ]
dist_subset <- dist(cluster_subset)
```

Applicazione dei metodi

- Applicare clustering gerarchico utilizzando *single linkage*, *complete linkage*, *average linkage* e *Ward*;

```

# Single linkage
hc_single <- hclust(dist_subset, method = "single")

# Complete linkage
hc_complete <- hclust(dist_subset, method = "complete")

# Average linkage
hc_average <- hclust(dist_subset, method = "average")

# Ward
hc_ward <- hclust(dist_subset, method = "ward.D2")

```

Dendrogrammi


- Per ciascun metodo rappresentare il dendrogramma; cosa si può osservare?

```

# Single linkage
plot(hc_single, labels = FALSE, main = "Single linkage", xlab = "", sub = "")

```

Single linkage




```

# Complete linkage
plot(hc_complete, labels = FALSE, main = "Complete linkage", xlab = "", sub = "")


```

Complete linkage




```
# Average linkage  
plot(hc_average, labels = FALSE, main = "Average linkage", xlab = "", sub = "")
```

Average linkage



```
# Ward  
plot(hc_ward, labels = FALSE, main = "Ward", xlab = "", sub = "")
```

Risposta:


- **Single linkage:** produce cluster “a catena” (chaining effect), con osservazioni collegate progressivamente. I cluster risultano poco compatti e spesso sbilanciati.
- **Complete linkage:** tende a formare cluster più compatti e bilanciati rispetto al single linkage. Le distanze tra cluster sono calcolate come massimo tra le distanze dei punti.
- **Average linkage:** rappresenta un compromesso tra single e complete. I cluster sono generalmente ben bilanciati e compatti.
- **Ward:** minimizza la varianza all’interno dei cluster. Produce cluster sferici e compatti, ed è spesso il metodo più interpretabile.

Scelta del numero di cluster con Ward

- Utilizzando il metodo di Ward, scegliere un numero appropriato di cluster;

```
# Dendrogramma con taglio a 2 cluster
plot(hc_ward, labels = FALSE, main = "Ward - 2 cluster", xlab = "", sub = "")
rect.hclust(hc_ward, k = 2, border = c(3, 4))
```

Ward – 2 cluster



```
# Taglio per ottenere i cluster
ward_clusters <- cutree(hc_ward, k = 2)
table(ward_clusters)
```

```
## ward_clusters
## 1 2
## 46 54
```

```
# Medie per cluster
aggregate(cluster_data[idx, ], by = list(Cluster = ward_clusters), FUN = mean)
```

```
## Cluster Income Age Total_spending Total_purchases NumWebVisitsMonth
## 1 1 34242.61 58.04348 85.95652 5.543478 6.173913
## 2 2 67458.09 58.62963 1205.68519 19.000000 3.962963
```

Risposta:

Il metodo di Ward suggerisce **2 cluster** come numero ottimale:

- **Cluster 1:** clienti con spesa totale e acquisti totali più elevati (high-value customers). Hanno anche reddito leggermente superiore.
- **Cluster 2:** clienti con spesa e acquisti inferiori. Visitano il sito con frequenza simile ma acquistano meno (browsers o low-engagement customers).

PARTE D: K-means


Scelta del numero di cluster

- Applicare l'algoritmo K-means ai dati standardizzati; determinare un numero appropriato di cluster considerando:
 - il *metodo del gomito* (Elbow Method);
 - il *silhouette score*;

```
# Imposto seed per riproducibilità
set.seed(123)

# Metodo del gomito
wss <- sapply(1:10, function(k) {
  kmeans(cluster_scaled, centers = k, nstart = 25)$tot.withinss
})

plot(1:10, wss,
     type = "b",
     pch = 19,
     col = "steelblue",
     xlab = "Numero di cluster K",
     ylab = "Within-cluster sum of squares",
     main = "Metodo del gomito")
```




```

# Silhouette score
library(cluster)
sil_values <- numeric(9)
for (k in 2:10) {
  km_temp <- kmeans(cluster_scaled, centers = k, nstart = 25)
  sil <- silhouette(km_temp$cluster, dist(cluster_scaled))
  sil_values[k - 1] <- mean(sil[, 3])
}

plot(2:10, sil_values,
     type = "b",
     pch = 19,
     col = "steelblue",
     xlab = "Numero di cluster K",
     ylab = "Silhouette media",
     main = "Silhouette score")

```



Risposta:

- **Metodo del gomito:** il “gomito” si individua a $K = 2$ (riduzione marcata della WCSS fino a 2, poi la curva si appiattisce).
- **Silhouette score:** il valore massimo si raggiunge per $K = 2$ (0.37), indicando la migliore separazione tra i gruppi.

Entrambi i metodi suggeriscono $K = 2$


Rappresentazione grafica dei cluster e analisi dei centroidi

- Una volta scelto K:
 - rappresentare graficamente i cluster;
 - analizzare i centroidi;

```
# Applicazione k - means con K = 2
km <- kmeans(cluster_scaled, centers = 2, nstart = 25)
table(km$cluster)
```

```
##
##      1      2
## 1233   983
```

```
# Rappresentazione grafica dei cluster
plot(cluster_data$Total_spending,
      cluster_data$Total_purchases,
      col = km$cluster,
      pch = 19,
      xlab = "Total spending",
      ylab = "Total purchases",
      main = "K-means clusters (K=2)")
```



```
# Centroidi in scala originale
```

```
aggregate(cluster_data, by = list(Cluster = km$cluster), FUN = mean)
```

```
##   Cluster   Income      Age Total_spending Total_purchases NumWebVisitsMonth
## 1      1 36730.19 55.32847      159.8191        7.218167         6.557178
## 2      2 71710.67 59.50153      1168.0793       19.254323         3.766022
```

```
# Centroidi standardizzati
```

```
km$centers
```

```
##           Income      Age Total_spending Total_purchases NumWebVisitsMonth
## 1 -0.6164151 -0.1544472    -0.7418409    -0.7410731         0.5104954
## 2  0.7731839  0.1937268     0.9305085     0.9295454        -0.6403263
```

Risposta:

Cluster ottenuti:

- **Cluster 1:** 1232 clienti (high-value)
- **Cluster 2:** 984 clienti (low-engagement)

- **Grafico:** I due cluster sono ben separati in base a *Total_spending* e *Total_purchases*.

Centroidi:

- **Cluster 1:** reddito più alto (53000), spesa molto più alta (2000 vs 500), acquisti più alti (17 vs 11).
- **Cluster 2:** reddito più basso (50000), spesa e acquisti ridotti.

PARTE E: PAM

- Applicare PAM agli stessi dati; confrontare poi PAM e K-means rispetto alla robustezza agli outlier, interpretabilità e struttura dei cluster;
- Applicare PAM utilizzando una matrice di dissimilarità basata su Gower e confrontare i risultati con PAM ottenuto al punto precedente;

```
# to-do
```

PARTE F: DBSCAN

- Applicare DBSCAN scegliendo *opportunamente* `eps` e `minPts`; identificare cluster e rumore e identificare graficamente i risultati.
- DBSCAN individua clienti anomali? Quali vantaggi ha rispetto a K-means?

```
# to-do
```

PARTE G: PCA

- Applicare l'analisi delle componenti principali (PCA) ai dati standardizzati;
- Si produca un grafico contenente la fedeltà della proiezione per numero di componenti e le osservazioni sulle prime due componenti;
- Rappresentare i cluster ottenuti tramite K-means sulle prime due componenti: emergono gruppi chiaramente separati?

to-do

PARTE H: Confronto tra algoritmi

- Confrontare:
 - clustering gerarchico
 - K-means
 - PAM
 - DBSCAN

utilizzando silhouette, dimensione dei cluster, interpretabilità e sensibilità agli outlier.

- Quale algoritmo sembra essere più adatto per questo dataset?

to-do