


Esercitazione Data Analytics

Alessio Matessi - SM321657

Soluzione risolta: 03 - 07 - 2026

Riportare di seguito i comandi e le risposte necessarie allo svolgimento dell'esame. **I file html e Rmd entrambi vanno consegnati tramite moodle.**

1. Accertarsi che il file compili correttamente prima di iniziare l'esame
2. Compilare (e salvare!) spesso
3. Se non si riesce a risolvere l'errore di compilazione, utilizzare `eval = F` nel chunk (si veda l'esempio dove è stata inclusa la tilde per vostra convenienza)



PARTE 1: R

Esercizio 1: Scrivere una funzione che prenda in input un numero intero $n > 10$. La funzione, dopo aver controllato che l'argomento rispetti la condizione richiesta, genererà un `data.frame` contenente n osservazioni con le seguenti variabili:

- **Eta:** valori interi casuali **compresi tra 18 e 70**;
- **Altezza:** valori generati da una **distribuzione normale** con **media 170** e **varianza 100**;
- **Peso:** valori ottenuti come **0.7 volte l'altezza meno 50**, a cui viene **aggiunto un termine casuale** ε (*rumore*) generato da una distribuzione normale con media 0 e deviazione standard 8, ossia:

$$Peso = 0.7 \times Altezza - 50 + \varepsilon$$

- **OreStudio:** valori interi casuali **compresi tra 0 e 10**;
- **Lavoro:** valori casuali che possono essere **0 o 1**; trasformare poi tale variabile in **factor** e rinominare i livelli come 0="No" e 1="Si".

La funzione, che dovrà essere chiamata **funzione**, dovrà restituire il `data.frame` generato.

Svolgimento

```

# Scrivo la funzione
funzione <- function(n){
  # Controllo che n sia intero e > 10
  if (!is.numeric(n) || n != round(n) || n <= 10) {
    stop("Errore: n deve essere un numero intero > 10")
  }

  # Genero le variabili
  Eta <- sample(18:70, n, replace = TRUE)
  Altezza <- rnorm(n, mean = 170, sd = 10) # varianza 100 -> sd 10
  epsilon <- rnorm(n, mean = 0, sd = 8)
  Peso <- 0.7 * Altezza - 50 + epsilon
  OreStudio <- sample(0:10, n, replace = TRUE)
  Lavoro <- sample(c(0, 1), n, replace = TRUE)
  Lavoro <- factor(Lavoro, levels = c(0, 1), labels = c("No", "Si"))

  # Creo il data.frame
  df <- data.frame(Eta, Altezza, Peso, OreStudio, Lavoro)
  return(df)
}

# Test veloce (senza set.seed, solo per vedere se funziona)
test_df <- funzione(15)
head(test_df)

```

```

##   Eta  Altezza    Peso OreStudio Lavoro
## 1  68 160.1042 74.62589         2     No
## 2  42 172.7877 67.65599         5     No
## 3  66 172.3254 67.74991         5     No
## 4  53 172.7991 63.70815         6     Si
## 5  51 175.2005 70.87460         3     No
## 6  35 155.2648 57.16055         8     Si

```

```
str(test_df)
```

```

## 'data.frame':   15 obs. of  5 variables:
##  $ Eta      : int  68 42 66 53 51 35 39 20 36 26 ...
##  $ Altezza   : num  160 173 172 173 175 ...
##  $ Peso      : num  74.6 67.7 67.7 63.7 70.9 ...
##  $ OreStudio: int   2 5 5 6 3 8 6 5 5 1 ...
##  $ Lavoro    : Factor w/ 2 levels "No","Si": 1 1 1 2 1 2 2 2 2 1 ...

```

Esercizio 2: Estendere la funzione del punto precedente in modo tale che restituisca una **lista** contenente:

- il `data.frame` generato;
- la media di ciascuna variabile numerica;
- la matrice di correlazione tra le variabili;
- il numero di individui con `Peso` superiore alla media del campione;

- la tabella delle frequenze assolute della variabile Lavoro;
- il `data.frame` ordinato in ordine decrescente rispetto a OreStudio.

Provare poi la funzione impostando `set.seed(123)`, $n = 50$ e estrarre la matrice di correlazione.

Svolgimento

```
# Estensione della funzione
funzione <- function(n){
  # Controllo che n sia intero e > 10
  if (!is.numeric(n) || n != round(n) || n <= 10) {
    stop("Errore: n deve essere un numero intero > 10")
  }

  # Genero le variabili
  Eta <- sample(18:70, n, replace = TRUE)
  Altezza <- rnorm(n, mean = 170, sd = 10)
  epsilon <- rnorm(n, mean = 0, sd = 8)
  Peso <- 0.7 * Altezza - 50 + epsilon
  OreStudio <- sample(0:10, n, replace = TRUE)
  Lavoro <- sample(c(0, 1), n, replace = TRUE)
  Lavoro <- factor(Lavoro, levels = c(0, 1), labels = c("No", "Si"))

  # Creo il data.frame
  df <- data.frame(Eta, Altezza, Peso, OreStudio, Lavoro)

  # Elementi aggiuntivi per la lista
  medie <- sapply(df[, sapply(df, is.numeric)], mean)
  correlazione <- cor(df[, sapply(df, is.numeric)])
  sopra_media <- sum(df$Peso > mean(df$Peso))
  tabella_lavoro <- table(df$Lavoro)
  df_ordinato <- df[order(df$OreStudio, decreasing = TRUE), ]

  # Restituisco la lista
  lista <- list(
    data = df,
    media = medie,
    correlazione = correlazione,
    sopra_media = sopra_media,
    tabella_lavoro = tabella_lavoro,
    df_ordinato = df_ordinato
  )
  return(lista)
}

# Test con set.seed(123) e n = 50
set.seed(123)
risultato <- funzione(50)

# Estraggo la matrice di correlazione
matrice_cor <- risultato$correlazione
matrice_cor
```

```
##           Eta      Altezza      Peso      OreStudio
## Eta      1.00000000 -0.03672110  0.07729732 -0.07354791
## Altezza  -0.03672110  1.00000000  0.67870687  0.05927956
## Peso      0.07729732  0.67870687  1.00000000 -0.01752440
## OreStudio -0.07354791  0.05927956 -0.01752440  1.00000000
```

PARTE 2: Analisi dei Dati

Esercizio 3: Si considerino i dati contenuti nel file `animali.csv`. Si tratta di informazioni raccolte su 300 animali. La variabile `Peso` indica il peso in kg, `Altezza` l'altezza in cm, `Eta` l'età in anni, `OreSonno` le ore medie di sonno giornaliero. Sono inoltre presenti variabili qualitative, quali `Specie`, `Sesso` e `Domestico`.

Punto 1. Quanto vale la devianza della variabile `Peso`?

Svolgimento

```
# Carico il dataset
animali <- read.csv("animali.csv", sep = "-", header = TRUE)

# Controllo veloce
str(animali)
```

```
## 'data.frame': 300 obs. of 7 variables:
## $ Specie : chr "Cane" "Coniglio" "Gatto" "Coniglio" ...
## $ Sesso : chr "F" "F" "M" "F" ...
## $ Domestico: chr "No" "Si" "Si" "Si" ...
## $ Peso : num 1.4 10.3 16.7 4.2 21 29.9 15.8 6.7 11.8 4.3 ...
## $ Altezza : num 27 25 23.7 17.9 52 56.9 27.3 19.2 35.7 29.3 ...
## $ Eta : int 13 12 6 5 9 13 4 13 13 13 ...
## $ OreSonno : num 13.7 11.6 12.6 14.8 13 12.3 14.9 13.4 11.5 10.2 ...
```

```
head(animali)
```

```
##      Specie Sesso Domestico Peso Altezza Eta OreSonno
## 1      Cane      F         No  1.4    27.0  13    13.7
## 2 Coniglio      F         Si 10.3    25.0  12    11.6
## 3      Gatto      M         Si 16.7    23.7   6    12.6
## 4 Coniglio      F         Si  4.2    17.9   5    14.8
## 5      Volpe      M         No 21.0    52.0   9    13.0
## 6      Cane      M         Si 29.9    56.9  13    12.3
```

```
# Calcolo della devianza di Peso
devianza_peso <- sum((animali$Peso - mean(animali$Peso))^2)
devianza_peso
```

```
## [1] 43915.74
```

Risposta

La **devianza** della variabile **Peso** è: **43915.74**

La devianza rappresenta la **somma degli scarti quadratici** di ogni osservazione dalla media campionaria:

$$\text{Devianza} = \sum_{i=1}^n (Peso_i - \bar{Peso})^2$$

Punto 2. Standardizzare le variabili quantitative e salvarle in un oggetto **DataScaled**, poi calcolare la matrice di covarianza delle nuove variabili. Quale coppia presenta la covarianza maggiore?

Svolgimento

```
# Carico il dataset
dati <- read.csv("animali.csv", sep = "-")

# Selezione le variabili quantitative
variabili_quant <- dati[, c("Peso", "Altezza", "Eta", "OreSonno")]

# Calcolo la matrice di correlazione (su dati standardizzati = covarianza)
matrice_cor <- cor(variabili_quant)
matrice_cor
```

```
##           Peso  Altezza      Eta  OreSonno
## Peso      1.0000000  0.9098736  0.07177598 -0.0402500
## Altezza   0.90987358  1.0000000  0.09202390 -0.0556074
## Eta       0.07177598  0.0920239  1.00000000 -0.6903311
## OreSonno -0.04025000 -0.0556074 -0.69033110  1.0000000
```

```
# Trovo la coppia con correlazione maggiore (esclusa la diagonale)
matrice_senza_diag <- matrice_cor
diag(matrice_senza_diag) <- NA

# Indice del massimo in valore assoluto
indice_max <- which.max(abs(matrice_senza_diag))
riga_max <- row(matrice_senza_diag)[indice_max]
colonna_max <- col(matrice_senza_diag)[indice_max]

# Stampo il risultato
cat("La coppia con covarianza maggiore è:",
    rownames(matrice_cor)[riga_max], "e",
    colnames(matrice_cor)[colonna_max], "\n")
```

```
## La coppia con covarianza maggiore è: Altezza e Peso
```

```
cat("Covarianza =", matrice_cor[riga_max, colonna_max], "\n")
```

```
## Covarianza = 0.9098736
```

Risposta

- **Matrice di correlazione** (su dati standardizzati = covarianza):

	Peso	Altezza	Eta	OreSonno
Peso	1.0000	0.9099	0.0718	-0.0403
Altezza	0.9099	1.0000	0.0920	-0.0556
Eta	0.0718	0.0920	1.0000	-0.6903
OreSonno	-0.0403	-0.0556	-0.6903	1.0000

- La coppia con covarianza maggiore è: **Altezza e Peso** con covarianza = **0.9099**

Punto 3. Calcolare la statistica χ^2 per valutare l'associazione tra **Sesso** e **Domestico**; possiamo concludere che tra le due variabili sono in qualche modo associate? Perché?

Svolgimento

```
# Carico il dataset
dati <- read.csv("animali.csv", sep = "-")

# Tabella di contingenza
tabella <- table(dati$Sesso, dati$Domestico)

# Test chi-quadrato
test_chi <- chisq.test(tabella)

# Output del test
test_chi

##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabella
## X-squared = 2.0089, df = 1, p-value = 0.1564
```

Risposta

Tabella di contingenza:

	Domestico = No	Domestico = Si
Sesso = F	23	73
Sesso = M	20	84

Test χ^2 :

- $\chi^2 = 2.009$
- $df = 1$
- p-value = 0.156

Conclusione: Il p-value è maggiore di 0.05, quindi **non possiamo rifiutare l'ipotesi di indipendenza** tra Sesso e Domestico. Le due variabili **non sono associate** in modo statisticamente significativo.

Esercizio 4. Creare una nuova variabile ottenuta dal prodotto logico di Specie e Domestico. Quale combinazione presenta la mediana di Peso più elevata?

Svolgimento

```
# Carico il dataset
dati <- read.csv("animali.csv", sep = "-")

# Creo la nuova variabile combinando Specie e Domestico
dati$Specie_Domestico <- interaction(dati$Specie, dati$Domestico, sep = "_")

# Calcolo la mediana di Peso per ogni combinazione
mediane <- tapply(dati$Peso, dati$Specie_Domestico, median)

# Stampo tutte le mediane
mediane
```

```
##      Cane_No Coniglio_No      Gatto_No      Volpe_No      Cane_Si Coniglio_Si
##      33.00      4.60      10.80      20.30      30.00      8.10
##      Gatto_Si      Volpe_Si
##      12.85      11.90
```

```
# Trovo la combinazione con mediana massima
combinazione_max <- names(mediane)[which.max(mediane)]
mediana_max <- max(mediane)

cat("Combinazione con mediana più elevata:", combinazione_max, "\n")
```

```
## Combinazione con mediana più elevata: Cane_No
```

```
cat("Mediana =", mediana_max, "\n")
```

```
## Mediana = 33
```

Risposta

Mediane di Peso per combinazione di Specie e Domestico:

Combinazione	Mediana Peso (kg)
Cane_No	33.00
Cane_Si	30.00
Volpe_No	20.30
Volpe_Si	11.90
Gatto_No	10.80
Gatto_Si	12.85
Coniglio_No	4.60
Coniglio_Si	8.10

La combinazione con mediana di Peso più elevata è: **Cane_No** (cani non domestici) con mediana = **33.00 kg**

Esercizio 5. Stimare una regressione lineare semplice avente come variabile di risposta **Peso** e come predittore **Altezza** e salvarla nell'oggetto **modello**:

Svolgimento

```
# Carico il dataset
dati <- read.csv("animali.csv", sep = "-")

# Modello di regressione lineare
modello <- lm(Peso ~ Altezza, data = dati)

# Output del modello
summary(modello)

##
## Call:
## lm(formula = Peso ~ Altezza, data = dati)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -13.0705  -3.7388  -0.1314   3.4441  13.1628
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -4.56066    0.67117  -6.795 5.89e-11 ***
## Altezza      0.59213    0.01564  37.858 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.037 on 298 degrees of freedom
## Multiple R-squared:  0.8279, Adjusted R-squared:  0.8273
## F-statistic: 1433 on 1 and 298 DF, p-value: < 2.2e-16
```

Punto 1 La variabile **Altezza** sembra essere significativa? Da cosa possiamo concluderlo?

Risposta:

Sì, la variabile **Altezza** è **altamente significativa**.

Motivazione:

- Il p-value associato al coefficiente di **Altezza** è $< 2e-16$, quindi **inferiore a 0.001**.
- L'ipotesi nulla (coefficiente = 0) viene **rifiutata** con elevata significatività.
- Inoltre il **test F** del modello ha p-value $< 2.2e-16$, confermando la significatività complessiva.

Punto 2 Quanto vale la percentuale di devianza spiegata?

Risposta:

La **percentuale di devianza spiegata** è: **82.79%**


- $R^2 = 0.8279$
- L'**82.79%** della variabilità di **Peso** è spiegata da **Altezza**.
- R^2 **aggiustato** = 0.8273

Punto 3 Costruire uno scatterplot delle variabili **Altezza** e **Peso** e aggiungere, in rosso, la linea di regressione ottenuta;

Svolgimento:

```
# Scatterplot con retta di regressione
plot(dati$Altezza, dati$Peso,
     xlab = "Altezza (cm)", ylab = "Peso (kg)",
     main = "Relazione tra Altezza e Peso",
     pch = 19, col = "steelblue")
abline(modello, col = "red", lwd = 2)
```

Relazione tra Altezza e Peso



Risposta:

Scatterplot di Peso vs Altezza con retta di regressione:

- **Asse x:** Altezza (cm)
- **Asse y:** Peso (kg)
- **Punti:** osservazioni in colore blu
- **Retta rossa:** retta di regressione stimata

Il grafico mostra una **relazione lineare positiva** tra altezza e peso: all'aumentare dell'altezza, il peso tende ad aumentare. I punti sono distribuiti intorno alla retta rossa con una dispersione moderata, indicando che la retta di regressione descrive bene la relazione tra le due variabili.

Punto 4 Quale delle seguenti affermazioni è corretta?

- [V] un aumento di 1cm di altezza è associato ad un aumento medio del peso di circa 0.59kg
- [F] un aumento di 1cm di altezza provoca sempre un aumento del peso di circa 0.59kg
- [F] un aumento di 1kg di peso è associato ad un aumento medio dell'altezza di 0.59cm
- [F] all'aumentare del peso l'altezza diminuisce in media di 0.59kg

Risposta:

Verifica delle affermazioni:

- **a.** “un aumento di 1cm di altezza è associato ad un aumento medio del peso di circa 0.59kg” → **VERA**.
Il coefficiente di **Altezza** è **0.59213**, che arrotondato è circa **0.59**. L’interpretazione corretta è: per ogni cm in più di altezza, il peso aumenta in media di 0.59 kg.
- **b.** “un aumento di 1cm di altezza provoca sempre un aumento del peso di circa 0.59kg” → **FALSA**.
La regressione descrive un effetto **medio**, non deterministico. La parola “sempre” rende l’affermazione errata.
- **c.** “un aumento di 1kg di peso è associato ad un aumento medio dell’altezza di 0.59cm” → **FALSA**.
Scambia il ruolo delle variabili: il modello è **Peso ~ Altezza**, quindi **Altezza** è il predittore (X) e **Peso** è la risposta (Y). L’interpretazione corretta è $X \rightarrow Y$, non $Y \rightarrow X$.
- **d.** “all’aumentare del peso l’altezza diminuisce in media di 0.59kg” → **FALSA**.
La relazione tra peso e altezza è **positiva** (coefficiente $0.59 > 0$), non negativa.


Risposta corretta: **a**.

Punto 5 Quale delle seguenti affermazioni è corretta osservando il grafico Residuals vs Fitted?

- [V] una dispersione casuale dei punti attorno a 0 suggerisce che l’assunzione di linearità sia plausibile
- [F] una dispersione casuale dei punti attorno a 0 indica che il modello è perfetto
- [F] i residui devono sempre essere tutti positivi
- [F] se i residui sono vicini a 0, allora $R^2 = 1$

Svolgimento:

```
# Grafico dei residui vs valori stimati  
plot(modello, which = 1)
```



Risposta

Verifica delle affermazioni:

- a. *“una dispersione casuale dei punti attorno a 0 suggerisce che l’assunzione di linearità sia plausibile”* → **VERA**.
Se i residui sono distribuiti casualmente intorno allo zero senza un pattern evidente, significa che il modello lineare cattura adeguatamente la relazione tra X e Y.
- b. *“una dispersione casuale dei punti attorno a 0 indica che il modello è perfetto”* → **FALSA**.
Indica solo che le assunzioni di linearità e omoschedasticità sono plausibili, non che il modello sia perfetto. Esistono comunque residui (differenze tra osservato e stimato).
- c. *“i residui devono sempre essere tutti positivi”* → **FALSA**.
I residui sono per definizione distribuiti intorno allo zero, quindi possono essere sia positivi che negativi. La loro somma (o media) è zero.
- d. *“se i residui sono vicini a 0, allora $R^2 = 1$ ”* → **FALSA**.
Residui vicini a zero indicano un buon adattamento, ma $R^2 = 1$ solo se tutti i residui sono esattamente zero (modello perfetto), cosa che nei dati reali non accade.

Risposta corretta: a.

Punto 6 Il peso previsto per un animale con altezza pari a 180cm vale circa:

- [F] 59.2kg
- [V] 102kg
- [F] 175.4kg
- [F] 82.8kg

Svolgimento:

```
# Calcolo manuale con i coefficienti del modello
previsto <- coef(modello)[1] + coef(modello)[2] * 180

# Oppure con predict()
predict(modello, newdata = data.frame(Altezza = 180))
```

```
##          1
## 102.0226
```

```
previsto
```

```
## (Intercept)
##    102.0226
```

Risposta

Verifica delle affermazioni:

- a. “59.2kg” → **FALSA**. Sottostima di circa 43 kg.
- b. “102kg” → **VERA**. Il peso previsto è **102.02 kg**, che arrotondato è 102 kg.
- c. “175.4kg” → **FALSA**. Sovrastima di circa 73 kg.
- d. “82.8kg” → **FALSA**. Sottostima di circa 19 kg.

Calcolo:

$$\text{Peso} = -4.56066 + 0.59213 \times 180 = \mathbf{102.02 \text{ kg}}$$

Risposta corretta: b.

Esercizio 6. Considerando le sole variabili quantitative standardizzate del dataset contenute nell’oggetto `DataScaled` e applicare l’algoritmo K-means con $k = 3$:

6.1 Riportare, attraverso un’istruzione di R, i centroidi ottenuti (nella scala originale);

Svolgimento

```

# Carico il dataset
dati <- read.csv("animali.csv", sep = "-")

# Seleziono le variabili quantitative
variabili_quant <- dati[, c("Peso", "Altezza", "Eta", "OreSonno")]

# Standardizzo
DataScaled <- scale(variabili_quant)

# K-means con k=3
set.seed(123)
kmeans_result <- kmeans(DataScaled, centers = 3, nstart = 25)

# Aggiungo il cluster al dataset
dati$cluster <- kmeans_result$cluster

# Calcolo le medie originali per cluster con aggregate()
centroidi_originali <- aggregate(cbind(Peso, Altezza, Eta, OreSonno) ~ cluster,
                                data = dati, FUN = mean)

centroidi_originali

```

```

##   cluster   Peso  Altezza      Eta OreSonno
## 1      1 12.77586 30.08448 11.672414 12.23190
## 2      2 13.20354 29.74513  4.292035 14.42035
## 3      3 35.60704 66.92535  9.323944 13.11268

```

Risposta

Centroidi (nella scala originale) ottenuti con `aggregate()`:

Cluster	Peso (kg)	Altezza (cm)	Eta (anni)	OreSonno
1	12.78	30.08	11.67	12.23
2	13.20	29.75	4.29	14.42
3	35.61	66.93	9.32	13.11

Osservazioni:

- **Cluster 3:** animali di **grossa taglia** (peso e altezza elevati).
- **Cluster 1 e 2:** animali di **piccola taglia** (peso e altezza bassi).
- **Cluster 2:** animali **più giovani** (4.29 anni) e con **più ore di sonno** (14.42 ore).
- **Cluster 1:** animali **più anziani** (11.67 anni) e con **meno ore di sonno** (12.23 ore).

6.2 Quanti animali appartengono a ciascun cluster?

Svolgimento:

```

# Carico il dataset
dati <- read.csv("animali.csv", sep = "-")

# Seleziono le variabili quantitative
variabili_quant <- dati[, c("Peso", "Altezza", "Eta", "OreSonno")]

# Standardizzo
DataScaled <- scale(variabili_quant)

# K-means con k=3
set.seed(123)
kmeans_result <- kmeans(DataScaled, centers = 3, nstart = 25)

# Numerosità dei cluster
table(kmeans_result$cluster)

##
##      1      2      3
## 116 113   71

```

Risposta:

Numerosità dei cluster:

Cluster	Frequenza
1	116
2	113
3	71

- I cluster 1 e 2 sono i più numerosi (116 e 113 animali), mentre il cluster 3 è il meno numeroso (71 animali).

6.3 Descrivere brevemente le caratteristiche dei cluster ottenuti;

Svolgimento

```

# Carico il dataset
dati <- read.csv("animali.csv", sep = "-")

# Seleziono le variabili quantitative
variabili_quant <- dati[, c("Peso", "Altezza", "Eta", "OreSonno")]

# Standardizzo
DataScaled <- scale(variabili_quant)

# K-means con k=3

```

```
set.seed(123)
kmeans_result <- kmeans(DataScaled, centers = 3, nstart = 25)

# Aggiungo i cluster al dataset
dati$cluster <- kmeans_result$cluster

# Medie delle variabili quantitative per cluster (scala originale)
aggregate(cbind(Peso, Altezza, Eta, OreSonno) ~ cluster, data = dati, FUN = mean)
```

```
##   cluster   Peso  Altezza    Eta OreSonno
## 1      1 12.77586 30.08448 11.672414 12.23190
## 2      2 13.20354 29.74513  4.292035 14.42035
## 3      3 35.60704 66.92535  9.323944 13.11268
```

```
# Distribuzione di Specie per cluster
table(dati$Specie, dati$cluster)
```

```
##
##           1  2  3
## Cane      18 16 68
## Coniglio  25 31  0
## Gatto     59 55  0
## Volpe     14 11  3
```

```
# Distribuzione di Domestico per cluster
table(dati$Domestico, dati$cluster)
```

```
##
##           1  2  3
## No      22 16 10
## Si     94 97 61
```

Risposta:

Caratteristiche dei cluster:

Cluster	Peso (kg)	Altezza (cm)	Eta (anni)	OreSonno	Specie prevalente	Domestico
1	12.78	30.08	11.67	12.23	Gatti (59) + Conigli (25)	Prevalentemente Si (94)
2	13.20	29.75	4.29	14.42	Gatti (55) + Conigli (31)	Prevalentemente Si (97)
3	35.61	66.93	9.32	13.11	Cani (68)	Prevalentemente Si (61)

Descrizione:

- **Cluster 1:**
 - Animali di **piccola taglia** (peso ~12.8 kg, altezza ~30 cm),

- **più anziani** (età media 11.7 anni)
 - **meno ore di sonno** (12.2 ore).
Composto principalmente da **gatti** e **conigli**, per lo più **domestici**.
 - **Cluster 2:**
 - Animali di **piccola taglia** (peso ~13.2 kg, altezza ~29.7 cm),
 - **più giovani** (età media 4.3 anni)
 - **più ore di sonno** (14.4 ore).
Composto principalmente da **gatti** e **conigli**, per lo più **domestici**.
 - **Cluster 3:**
 - Animali di **grossa taglia** (peso ~35.6 kg, altezza ~66.9 cm),
 - **età intermedia** (9.3 anni)
 - **sonno medio** (13.1 ore).
Composto prevalentemente da **cani**, per lo più **domestici**.
-

6.4 Rappresentare con uno scatterplot le variabili **Altezza** e **Peso** e colorarle rispetto all'appartenenza ai cluster ottenuti.

Svolgimento

```
# Carico il dataset
dati <- read.csv("animali.csv", sep = "-")

# Selezione le variabili quantitative
variabili_quant <- dati[, c("Peso", "Altezza", "Eta", "OreSonno")]


# Standardizzo
DataScaled <- scale(variabili_quant)

# K-means con k=3
set.seed(123)
kmeans_result <- kmeans(DataScaled, centers = 3, nstart = 25)

# Aggiungo i cluster al dataset
dati$cluster <- as.factor(kmeans_result$cluster)

# Scatterplot
plot(dati$Altezza, dati$Peso,
     col = dati$cluster,
     pch = 19,
     xlab = "Altezza (cm)",
     ylab = "Peso (kg)",
     main = "Scatterplot Peso vs Altezza per cluster")
```

```
# Legenda
legend("topleft",
      legend = c("Cluster 1", "Cluster 2", "Cluster 3"),
      col = 1:3,
      pch = 19,
      title = "Cluster")
```



Risposta:

Scatterplot di Altezza vs Peso con colori in base al cluster:

- **Asse x:** Altezza (cm)
- **Asse y:** Peso (kg)
- **Colori:**
 - **Cluster 1** (nero): animali di piccola taglia, peso moderato
 - **Cluster 2** (rosso): animali di piccola taglia, peso moderato
 - **Cluster 3** (verde): animali di grossa taglia (peso e altezza elevati)

Osservazioni:

- I **cluster 1 e 2** si sovrappongono nella zona bassa del grafico (animali piccoli), ma si distinguono per età e ore di sonno (cluster 2 più giovani e dormiglioni).
- Il **cluster 3** è ben separato e occupa la zona alta del grafico (animali grandi, principalmente cani).

- La separazione tra i cluster è netta per quanto riguarda peso e altezza, confermando che il K-means ha individuato gruppi ben distinti.