

Esercitazione Data Analytics

Nome e cognome:

N. mat.:

Riportare di seguito i comandi e le risposte necessarie allo svolgimento dell'esame. I file pdf e Rmd entrambi vanno consegnati tramite moodle.

1. Accertarsi che il file compili correttamente prima di iniziare l'esame
2. Compilare (e salvare!) spesso
3. Se non si riesce a risolvere l'errore di compilazione, utilizzare l'opzione `eval = F` nelle opzioni del chunk, ad esempio:

```
{r, eval=FALSE}  
summary(dataset)  
plot(x, y)
```

R

Esercizio 1.

Scrivere una funzione che prenda in input due scalari numerici interi $n > 10$. La funzione, dopo aver controllato che l'argomento rispetti la condizione richiesta, genererà un `data.frame` contenente n osservazioni con le seguenti variabili:

- **Eta**: valori interi casuali **compresi tra 18 e 70**;
- **Altezza**: valori generati da una **distribuzione normale** con **media 170** e **varianza 100**;
- **Peso**: valori ottenuti come **0.7 volte l'altezza meno 50**, a cui viene **aggiunto un termine casuale** ε (*rumore*) generato da una distribuzione normale con media 0 e deviazione standard 8, ossia:

$$Peso = 0.7 \times Altezza - 50 + \varepsilon$$

- **OreStudio**: valori interi casuali **compresi tra 0 e 10**;
- **Lavoro**: valori casuali che possono essere **0 o 1**; trasformare poi tale variabile in **factor** e rinominare i livelli come 0="No" e 1="Si".

La funzione, che dovrà essere chiamata **funzione**, dovrà restituire il `data.frame` generato.

```
funzione <- function(n) {  
  
  # controllo
```

```

if(n<=10) {
  print("\n dev'essere maggiore di 10");
  stop("Errore")
}

# definizione delle variabili
Eta <- sample(18:70, n, replace=T);

Altezza <- rnorm(n, 170, 10);

eps <- rnorm(n, 0, 8);
Peso <- 0.7 * Altezza - 50 + eps;

OreStudio <- sample(0:10, n, replace=T);

Lavoro <- factor(
  x = sample(0:1, n, replace=T),
  levels = c(0, 1),
  labels = c("No", "Si"));

# creazione del dataframe
data <- data.frame(
  Eta = Eta,
  Altezza = Altezza,
  Peso = Peso,
  OreStudio = OreStudio,
  Lavoro = Lavoro
)

return(data)
}

```

```
funzione(11)
```

```

##      Eta  Altezza      Peso OreStudio Lavoro
## 1    35 164.4212 70.81032         6      No
## 2    41 167.9814 54.89064         5      No
## 3    29 161.5444 60.31391         8      Si
## 4    58 162.5039 62.66515         5      No
## 5    40 159.9610 57.45022         2      Si
## 6    22 159.0113 66.34819         9      No
## 7    18 178.7293 79.76317         5      No
## 8    46 184.5427 86.73720         7      No
## 9    66 165.5624 76.68510         0      Si
## 10   62 161.0577 64.65834        10      Si
## 11   49 182.7156 79.49518         2      No

```

Esercizio 2

Estendere la funzione del punto precedente in modo tale che restituisca una **lista** contenente:

- il `data.frame` generato;
- la media di ciascuna variabile numerica;
- la matrice di correlazione tra le variabili;
- il numero di individui con `Peso` superiore alla media del campione;
- la tabella delle frequenze assolute della variabile `Lavoro`;
- il `data.frame` ordinato in ordine decrescente rispetto a `OreStudio`.

Provare poi la funzione impostando `set.seed(123)`, $n = 50$ e estrarre la matrice di correlazione.

```
funzione <- function(n) {

  if(n<=10) {
    print("n dev'essere maggiore di 10");
    stop("Errore")
  }

  Eta <- sample(18:70, n, replace=T);
  Altezza <- rnorm(n, 170, 10);
  eps <- rnorm(n, 0, 8);
  Peso <- 0.7 * Altezza - 50 + eps;
  OreStudio <- sample(0:10, n, replace=T);
  Lavoro <- factor(
    x = sample(0:1, n, replace=T),
    levels = c(0, 1),
    labels = c("No", "Si"));

  data <- data.frame(
    Eta = Eta,
    Altezza = Altezza,
    Peso = Peso,
    OreStudio = OreStudio,
    Lavoro = Lavoro
  )

  # matrice di correlazione
  numVar <- data[sapply(data, is.numeric)]
  CorMatrix <- cor(numVar)

  # media di ciascuna variabile (quantitativa)
  means <- sapply(numVar, mean)

  # numero di individui con Peso superiore alla media del campione
  meanPeso <- means[3]
  pesoMaggior <- sum(data$Peso > meanPeso)

  # la tabella delle frequenze assolute della variabile Lavoro
  freq <- table(data$Lavoro)
```

```

# il data.frame ordinato in ordine decrescente rispetto a OreStudio
orderedData <- data[order(data$OreStudio, decreasing = T), ]

return(list(Data = data,
            Medie = means,
            CorMatrix = CorMatrix,
            PesoMaggiore = pesoMaggior,
            Freq = freq,
            DatiOrdinati = orderedData))
}

```

```
set.seed(123)
```

```
dati <- funzione(50)
dati[[3]]
```

```
##              Eta      Altezza      Peso      OreStudio
## Eta          1.00000000 -0.03672110  0.07729732 -0.07354791
## Altezza      -0.03672110  1.00000000  0.67870687  0.05927956
## Peso         0.07729732  0.67870687  1.00000000 -0.01752440
## OreStudio    -0.07354791  0.05927956 -0.01752440  1.00000000
```

Analisi dei Dati

Si considerino i dati contenuti nel file `animali.csv`. Si tratta di informazioni raccolte su 300 animali. La variabile `Peso` indica il peso in kg, `Altezza` l'altezza in cm, `Eta` l'età in anni, `OreSonno` le ore medie di sonno giornaliere. Sono inoltre presenti variabili qualitative, quali `Specie`, `Sesso` e `Domestico`.

```
Animali <- read.csv("animali.csv", sep = "-")
str(Animali)
```

```
## 'data.frame':    300 obs. of  7 variables:
## $ Specie      : chr  "Cane" "Coniglio" "Gatto" "Coniglio" ...
## $ Sesso       : chr  "F" "F" "M" "F" ...
## $ Domestico   : chr  "No" "Si" "Si" "Si" ...
## $ Peso        : num  1.4 10.3 16.7 4.2 21 29.9 15.8 6.7 11.8 4.3 ...
## $ Altezza     : num  27 25 23.7 17.9 52 56.9 27.3 19.2 35.7 29.3 ...
## $ Eta         : int  13 12 6 5 9 13 4 13 13 13 ...
## $ OreSonno    : num  13.7 11.6 12.6 14.8 13 12.3 14.9 13.4 11.5 10.2 ...
```

```
summary(Animali)
```

```
##      Specie           Sesso           Domestico           Peso
## Length:300      Length:300      Length:300      Min.    : 1.00
## Class :character Class :character Class :character 1st Qu.: 9.40
## Mode  :character Mode  :character Mode  :character Median :16.05
##                                     Mean   :18.34
##                                     3rd Qu.:26.35
##                                     Max.   :56.40
##      Altezza           Eta           OreSonno
## Min.    :11.20      Min.    : 1.000      Min.    : 9.40
## 1st Qu.:25.00      1st Qu.: 5.000      1st Qu.:12.30
```

```
## Median :31.90    Median : 8.000    Median :13.30
## Mean   :38.68    Mean   : 8.337    Mean   :13.26
## 3rd Qu.:51.50    3rd Qu.:13.000    3rd Qu.:14.20
## Max.   :95.00    Max.   :15.000    Max.   :16.90
```

1. Quanto vale la devianza della variabile **Peso**?

```
dev <- sum( (Animali$Peso-mean(Animali$Peso))^2 ); dev
```

```
## [1] 43915.74
```

```
# o (nrow(Animali)-1) * var(Animali$Peso)
```

2. Standardizzare le variabili quantitative e salvarle in un oggetto **DataScaled**, poi calcolare la matrice di covarianza delle nuove variabili. Quale coppia presenta la covarianza maggiore?

```
numVar <- Animali[sapply(Animali, is.numeric)]
```

```
DataScaled <- scale(numVar)
```

```
covMatrix <- cov(DataScaled); covMatrix
```

```
##           Peso    Altezza      Eta   OreSonno
## Peso      1.0000000  0.9098736  0.07177598 -0.0402500
## Altezza   0.90987358  1.0000000  0.09202390 -0.0556074
## Eta       0.07177598  0.0920239  1.00000000 -0.6903311
## OreSonno -0.04025000 -0.0556074 -0.69033110  1.0000000
```

3. Calcolare la statistica χ^2 per valutare l'associazione tra **Sesso** e **Domestico**; possiamo concludere che tra le due variabili sono in qualche modo associate? Perché?

```
chisq.test(Animali$Sesso, Animali$Domestico)
```

```
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  Animali$Sesso and Animali$Domestico
## X-squared = 2.0089, df = 1, p-value = 0.1564
```

```
# oppure
# tab <- table(Animali$Sesso, Animali$Domestico)
# chisq.test(tab)
```

Non ci sono evidenze statisticamente significative per affermare l'esistenza di un'associazione tra **Sesso** e **Domestico** (si guarda al p -value: se è maggiore di una certa soglia, di solito 0.1, 0.01, 0.05, significa che non sembrano esserci prove per rifiutare l'ipotesi nulla, che in questo caso è che le due variabili siano indipendenti).

4. Creare una nuova variabile ottenuta dal prodotto logico di **Specie** e **Domestico**. Quale gruppo presenta la mediana di **Peso** più elevata?

```
# prodotto logico
Animali$Gruppo <- paste(
  Animali$Specie,
  Animali$Domestico,
  sep = " - "
```

```
)

# mediane del peso
mediane <- tapply(
  Animali$Peso,
  Animali$Gruppo,
  median
); mediane

##      Cane - No      Cane - Si Coniglio - No Coniglio - Si      Gatto - No
##      33.00      30.00      4.60      8.10      10.80
##      Gatto - Si      Volpe - No      Volpe - Si
##      12.85      20.30      11.90
```

```
# oppure
# aggregate(Peso ~ Gruppo, data=Animali, median)

# gruppo con mediana massima
gruppoMax <- names(which.max(mediane)); gruppoMax
```

```
## [1] "Cane - No"
```

Oppure direttamente:

```
mediane <- tapply(
  Animali$Peso,
  paste(Animali$Specie, Animali$Domestico),
  median
)

names(which.max(mediane))
```

```
## [1] "Cane No"
```

5. Stimare una regressione lineare semplice avente come variabile di risposta `Peso` e come predittore `Altezza` e salvarla nell'oggetto `modello`:

```
modello <- lm(Peso ~ Altezza, data=Animali)

summary(modello)

##
## Call:
## lm(formula = Peso ~ Altezza, data = Animali)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -13.0705  -3.7388  -0.1314   3.4441  13.1628
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -4.56066    0.67117  -6.795 5.89e-11 ***
## Altezza      0.59213    0.01564  37.858 < 2e-16 ***
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.037 on 298 degrees of freedom
## Multiple R-squared:  0.8279, Adjusted R-squared:  0.8273
## F-statistic: 1433 on 1 and 298 DF,  p-value: < 2.2e-16
```

5.1 La variabile *Altezza* sembra essere significativa? Da cosa possiamo concluderlo?

Sì, perché nel test che verifica se la variabile *Altezza* contribuisca a spiegare la variabile *Peso* il p -value risulta essere molto piccolo, indicando che c'è evidenza che l'ipotesi nulla (cioè che *Altezza* non è significativa, ossia $\beta_{Altezza} \equiv 0$) non regga.

5.2 Quanto vale la percentuale di devianza spiegata?

```
summary(modello)$r.squared * 100
```


```
## [1] 82.78699
```

Quindi il modello spiega circa l'82.8% della devianza.

5.3 Costruire uno scatterplot delle variabili *Altezza* e *Peso* e aggiungere, in rosso, la linea di regressione ottenuta;

```
plot(Animali$Altezza,
     Animali$Peso)

abline(modello, col="red")
```



5.4 Quale delle seguenti affermazioni è corretta?

- ☒ un aumento di 1cm di altezza è associato ad un aumento medio del peso di circa 0.59kg
- ☐ un aumento di 1cm di altezza provoca sempre un aumento del peso di circa 0.59kg
- ☐ un aumento di 1kg di peso è associato ad un aumento medio dell'altezza di 0.59cm

☐ all'aumentare del peso l'altezza diminuisce in media di 0.59kg

5.5 Quale delle seguenti affermazioni è corretta osservando il grafico Residuals vs Fitted?

☒ una dispersione casuale dei punti attorno a 0 suggerisce che l'assunzione di linearità sia plausibile

☐ una dispersione casuale dei punti attorno a 0 indica che il modello è perfetto

☐ i residui devono sempre essere tutti positivi

☐ se i residui sono vicini a 0, allora $R^2 = 1$

5.6 Il peso previsto per un animale con altezza pari a 180cm vale circa:

☐ 59.2kg

☒ 102kg

☐ 175.4kg

☐ 82.8kg

```
predict(modello, newdata = data.frame(Altezza = 180))
```

```
##          1
## 102.0226
```

6. Considerando le sole variabili quantitative standardizzate del dataset contenute nell'oggetto `DataScaled` e applicare l'algoritmo K-means con $k = 3$;

```
km3 <- kmeans(DataScaled, centers = 3, nstart = 25)
```

```
km3
```

```
## K-means clustering with 3 clusters of sizes 116, 71, 113
```

```
##
```

```
## Cluster means:
```

```
##      Peso  Altezza      Eta  OreSonno
## 1 -0.4591445 -0.4613324  0.7501099 -0.7665229
## 2  1.4247381  1.5169616  0.2220091 -0.1128076
## 3 -0.4238553 -0.4795550 -0.9095168  0.8577522
```

```
##
```

```
## Clustering vector:
```

```
## [1] 1 1 1 3 2 2 3 1 1 1 3 1 3 3 3 1 2 2 1 1 1 3 3 1 3 1 1 1 1 3 3 1 3 3 2 3 1
## [38] 2 2 1 2 3 3 1 3 3 3 1 2 1 2 3 3 2 3 1 1 1 3 1 1 2 1 2 3 1 3 3 1 3 1 3 3 1
## [75] 1 2 1 3 3 2 2 1 3 3 2 1 1 1 3 3 3 3 2 1 2 2 1 2 1 3 3 3 1 3 3 3 3 1 3 1 2
## [112] 1 1 3 3 1 3 1 1 3 3 2 1 3 1 1 2 2 2 1 3 1 3 3 3 3 3 3 1 3 2 3 2 3 1 1 2 2
## [149] 3 1 3 3 3 2 2 1 1 2 1 2 3 3 3 3 1 1 3 3 1 2 3 2 1 3 3 3 1 1 1 3 1 2 1 2 1
## [186] 3 2 1 3 1 1 2 3 1 2 3 3 3 2 1 2 3 3 1 1 1 1 2 2 1 1 2 2 3 2 1 1 1 3 1 2 1
## [223] 1 1 2 1 3 3 3 1 1 1 1 2 2 3 2 3 2 1 1 1 2 1 2 3 1 1 3 1 1 2 1 2 1 3 3 3 1
## [260] 3 3 1 1 1 1 1 2 2 2 3 3 3 1 2 3 3 3 3 2 1 3 2 1 2 1 1 2 2 2 3 3 2 3 3 3 3
## [297] 1 2 2 3
```

```
##
```

```
## Within cluster sum of squares by cluster:
```

```
## [1] 155.8367 164.7947 157.9906
```

```
## (between_SS / total_SS = 60.0 %)
```

```
##
```

```
## Available components:
```



```
##
## [1] "cluster"      "centers"      "totss"      "withinss"    "tot.withinss"
## [6] "betweenss"    "size"        "iter"      "ifault"
```

6.1 Riportare, attraverso un'istruzione di R, i centroidi ottenuti (nella scala originale);

```
km3$centers * attr(DataScaled, "scaled:scale") + attr(DataScaled, "scaled:center")
```

```
##      Peso  Altezza      Eta OreSonno
## 1 12.775862 12.64309 11.672414 24.40106
## 2 65.207916 36.72472 13.563789  7.83501
## 3  6.451778 29.74513  7.317703 14.42035
```

6.2 Quanti animali appartengono a ciascun cluster?

```
km3$size
```

```
## [1] 116  71 113
```

```
table(km3$cluster)
```

```
##
##  1  2  3
## 116 71 113
```

6.3 Descrivere brevemente le caratteristiche dei cluster ottenuti;

```
aggregate(numVar, by=list(Cluster = km3$cluster), mean)
```

```
##  Cluster      Peso  Altezza      Eta OreSonno
## 1      1 12.77586 30.08448 11.672414 12.23190
## 2      2 35.60704 66.92535  9.323944 13.11268
## 3      3 13.20354 29.74513  4.292035 14.42035
```

6.4 Rappresentare in uno scatterplot le variabili Altezza e Peso e colorarle rispetto all'appartenenza ai cluster ottenuti.

```
plot(Animali$Altezza, Animali$Peso, col=km3$cluster)
```

