

Esercitazione Data Analytics

Nome e cognome:

N. mat.:

Riportare di seguito i comandi e le risposte necessarie allo svolgimento dell'esame. I file pdf e Rmd entrambi vanno consegnati tramite moodle.

1. Accertarsi che il file compili correttamente prima di iniziare l'esame
2. Compilare (e salvare!) spesso
3. Se non si riesce a risolvere l'errore di compilazione, utilizzare l'opzione `eval = F` nelle opzioni del chunk, ad esempio:

```
{r, eval=FALSE}  
summary(dataset)  
plot(x, y)
```

R

Esercizio 1.

Scrivere una funzione che prenda in input un numero intero $n > 10$. La funzione, dopo aver controllato che l'argomento rispetti la condizione richiesta, genererà un `data.frame` contenente n osservazioni con le seguenti variabili:

- **Eta**: valori interi casuali **compresi tra 18 e 70**;
- **Altezza**: valori generati da una **distribuzione normale** con **media 170** e **varianza 100**;
- **Peso**: valori ottenuti come **0.7 volte l'altezza meno 50**, a cui viene **aggiunto un termine casuale** ε (*rumore*) generato da una distribuzione normale con media 0 e deviazione standard 8, ossia:

$$Peso = 0.7 \times Altezza - 50 + \varepsilon$$

- **OrreStudio**: valori interi casuali **compresi tra 0 e 10**;
- **Lavoro**: valori casuali che possono essere **0 o 1**; trasformare poi tale variabile in **factor** e rinominare i livelli come 0="No" e 1="Si".

La funzione, che dovrà essere chiamata **funzione**, dovrà restituire il `data.frame` generato.

Esercizio 2

Estendere la funzione del punto precedente in modo tale che restituisca una **lista** contenente:

- il `data.frame` generato;
- la media di ciascuna variabile numerica;
- la matrice di correlazione tra le variabili;
- il numero di individui con **Peso** superiore alla media del campione;
- la tabella delle frequenze assolute della variabile **Lavoro**;
- il `data.frame` ordinato in ordine decrescente rispetto a **OreStudio**.

Provare poi la funzione impostando `set.seed(123)`, $n = 50$ e estrarre la matrice di correlazione.

Analisi dei Dati

Si considerino i dati contenuti nel file `animali.csv`. Si tratta di informazioni raccolte su 300 animali. La variabile **Peso** indica il peso in kg, **Altezza** l'altezza in cm, **Eta** l'età in anni, **OreSonno** le ore medie di sonno giornaliero. Sono inoltre presenti variabili qualitative, quali **Specie**, **Sesso** e **Domestico**.

1. Quanto vale la devianza della variabile **Peso**?
2. Standardizzare le variabili quantitative e salvarle in un oggetto `DataScaled`, poi calcolare la matrice di covarianza delle nuove variabili. Quale coppia presenta la covarianza maggiore?
3. Calcolare la statistica χ^2 per valutare l'associazione tra **Sesso** e **Domestico**; possiamo concludere che tra le due variabili sono in qualche modo associate? Perché?
4. Creare una nuova variabile ottenuta dal prodotto logico di **Specie** e **Domestico**. Quale combinazione presenta la mediana di **Peso** più elevata?
5. Stimare una regressione lineare semplice avente come variabile di risposta **Peso** e come predittore **Altezza** e salvarla nell'oggetto `modello`:

5.1 La variabile **Altezza** sembra essere significativa? Da cosa possiamo concluderlo?

5.2 Quanto vale la percentuale di devianza spiegata?

5.3 Costruire uno scatterplot delle variabili **Altezza** e **Peso** e aggiungere, in rosso, la linea di regressione ottenuta;

5.4 Quale delle seguenti affermazioni è corretta?

- ☐ un aumento di 1cm di altezza è associato ad un aumento medio del peso di circa 0.59kg
- ☐ un aumento di 1cm di altezza provoca sempre un aumento del peso di circa 0.59kg
- ☐ un aumento di 1kg di peso è associato ad un aumento medio dell'altezza di 0.59cm
- ☐ all'aumentare del peso l'altezza diminuisce in media di 0.59kg

5.5 Quale delle seguenti affermazioni è corretta osservando il grafico Residuals vs Fitted?

- ☐ una dispersione casuale dei punti attorno a 0 suggerisce che l'assunzione di linearità sia plausibile
- ☐ una dispersione casuale dei punti attorno a 0 indica che il modello è perfetto
- ☐ i residui devono sempre essere tutti positivi

☐ se i residui sono vicini a 0, allora $R^2 = 1$

5.6 Il peso previsto per un animale con altezza pari a 180cm vale circa:

☐ 59.2kg

☐ 102kg

☐ 175.4kg

☐ 82.8kg

6. Considerando le sole variabili quantitative standardizzate del dataset contenute nell'oggetto `DataScaled` e applicare l'algoritmo K-means con $k = 3$:

6.1 Riportare, attraverso un'istruzione di R, i centroidi ottenuti (nella scala originale);

6.2 Quanti animali appartengono a ciascun cluster?

6.3 Descrivere brevemente le caratteristiche dei cluster ottenuti;

6.4 Rappresentare con uno scatterplot le variabili `Altezza` e `Peso` e colorarle rispetto all'appartenenza ai cluster ottenuti.