

Esercitazione 2

Sara Trabucco

3 Giugno 2026

Nome e cognome:

N. mat.:

Riportare di seguito i comandi e le risposte necessarie allo svolgimento dell'esame. I file pdf e Rmd entrambi vanno consegnati tramite moodle.

1. Accertarsi che il file compili correttamente prima di iniziare l'esame
2. Compilare (e salvare!) spesso
3. Se non si riesce a risolvere l'errore di compilazione, utilizzare l'opzione `eval = F` nelle opzioni del chunk, ad esempio:

```
{r, eval=FALSE}  
summary(dataset)  
plot(x, y)
```

R

Esercizio 1.

Scrivere una funzione che prenda in input tre vettori numerici della stessa lunghezza: **pressione**, **colesterolo** e **glicemia**.

La funzione, denominata `classifica_pazienti()` deve verificare che gli input siano corretti e poi:

- creare una variabile **Rischio** con tre livelli:
 - *Basso* se **pressione** è minore di 130, **colesterolo** è minore di 200 e **glicemia** è minore di 100;
 - *Medio* se almeno una ed al massimo una è fuori da una delle soglie fissate al punto precedente;
 - *Alto* se due condizioni o più sono fuori dalle medesime soglie.
- restituire una lista composta da un dataframe contenente le variabili originali e la nuova variabile **Rischio** e dalla tabella delle frequenze assolute di **Rischio**

Analisi dei Dati

Si considerino i dati contenuti nel file `salute.csv`. Si tratta di un dataset composto da dati raccolti su 387 pazienti, in particolare 8 (**Eta**, **BMI**, **Pressione**, **Colesterolo**, **AttivitaFisica**, **Glicemia**, **Sesso**, **Fumatore**).

1. Calcolare media, mediana e deviazione standard della variabile **Pressione**;
2. Costruire un boxplot di **Pressione** rispetto a **Fumatore**. Cosa si osserva?

3. Calcolare la matrice di correlazione tra le variabili quantitative. Quale coppia presenta la correlazione più alta?
4. Calcolare il test χ^2 tra **Sesso** e **Fumatore**. Le due variabili risultano associate? Perché?
5. Stimare il modello di regressione lineare con variabile di risposta **Pressione** e come regressori **Eta**, **BMI**, **Fumatore**:
 - 5.1 Quali variabili sono statisticamente significative?
 - 5.2 Interpretare il coefficiente associato a **FumatoreSi**;
 - 5.3 Calcolare la percentuale di devianza spiegata dal modello;
 - 5.4 Prevedere la pressione per un paziente fumatore con un'età di 50 anni ed un BMI di 27.
6. Standardizzare le variabili quantitative del dataset e salvarle in un oggetto **DataScaled**;
7. Applicare clustering gerarchico a **DataScaled** utilizzando il metodo di Ward:
 - 7.1 Rappresentare il dendrogramma;
 - 7.2 Costruire il plot delle altezze e, rispetto a tale grafico, scegliere un numero appropriato di cluster e motivarne il perché;
 - 7.3 Riportare la numerosità di ciascun gruppo ottenuto;
 - 7.4 Descrivere brevemente le caratteristiche dei cluster ottenuti considerando le medie delle variabili quantitative.
8. Applicare PCA alle variabili standardizzate:
 - 8.1 Quanta variabilità viene spiegata dalle prime due componenti?
 - 8.2 Costruire un grafico delle prime due componenti e colorarlo rispetto ai cluster ottenuti in precedenza; i gruppi sembrano ben separati?