

TUTORATO 7 - Esercitazione Data Analytics

Alessio Matessi - SM321657

Soluzione risolta: 06 - 07 - 2026

Riportare di seguito i comandi e le risposte necessarie allo svolgimento dell'esame. **I file html e Rmd entrambi vanno consegnati tramite moodle.**

1. Accertarsi che il file compili correttamente prima di iniziare l'esame
2. Compilare (e salvare!) spesso
3. Se non si riesce a risolvere l'errore di compilazione, utilizzare `eval = F` nel chunk (si veda l'esempio dove è stata inclusa la tilde per vostra convenienza)

PARTE 1: R

Esercizio 1: Scrivere una funzione che prenda in input tre vettori numerici della stessa lunghezza: `pressione`, `colesterolo` e `glicemia`.

La funzione, denominata `classifica_pazienti()` deve verificare che gli input siano corretti e poi:

- **Punto 1:** creare una variabile `Rischio` con tre livelli:
 - *Basso* se `pressione` è minore di 130, `colesterolo` è minore di 200 e `glicemia` è minore di 100;
 - *Medio* se almeno una ed al massimo una è fuori da una delle soglie fissate al punto precedente;
 - *Alto* se due condizioni o più sono fuori dalle medesime soglie.
- **Punto 2:** Restituire una lista composta da un dataframe contenente le variabili originali e la nuova variabile `Rischio` e dalla tabella delle frequenze assolute di `Rischio`

Svolgimento:

```
## - PUNTO 1 -

# Scrivo la funzione che classifica i pazienti
classifica_pazienti <- function(pressione, colesterolo, glicemia)
{

  # Controllo che siano vettori numerici
  if (!is.numeric(pressione) ||
      !is.numeric(colesterolo) ||
      !is.numeric(glicemia))
  {
```

```

    stop("Errore: tutti gli input devono essere vettori numerici")
  }

  # Controllo che abbiano stessa lunghezza
  if (length(pressione) != length(colesterolo) ||
      length(pressione) != length(glicemia))
  {
    stop("Errore: i vettori devono avere la stessa lunghezza")
  }

  # In R TRUE=1 e FALSE=0. Sommo le condizioni per contare quante soglie sono superate
  out <- (pressione >= 130) + (colesterolo >= 200) + (glicemia >= 100)

  # Classificazione del rischio
  Rischio <- ifelse(out == 0, "Basso",
                    ifelse(out == 1, "Medio", "Alto"))

  # Trasformo in factor ordinato (Basso < Medio < Alto)
  Rischio <- factor(Rischio, levels = c("Basso", "Medio", "Alto"), ordered = TRUE)

  ## - PUNTO 2 -

  # Creo il dataframe con le variabili originali + Rischio
  df <- data.frame(pressione, colesterolo, glicemia, Rischio)

  # Tabella delle frequenze assolute di Rischio
  tabella <- table(Rischio)

  # Restituisco la lista
  return(list(dataframe = df, frequenze = tabella))
}

# Test della funzione
pressione_test <- c(120, 135, 145, 125)
colesterolo_test <- c(180, 210, 220, 190)
glicemia_test <- c(95, 98, 110, 105)

risultato_test <- classifica_pazienti(pressione_test, colesterolo_test, glicemia_test)

# Stampo il dataframe
risultato_test$dataframe

##   pressione colesterolo glicemia Rischio
## 1      120         180       95   Basso
## 2      135         210       98    Alto
## 3      145         220      110    Alto
## 4      125         190      105   Medio

# Stampo le frequenze
risultato_test$frequenze

```

```
## Rischio
## Basso Medio Alto
##      1      1      2
```

Risposta

Test con vettori di esempio:

pressione	colesterolo	glicemia	Rischio
120	180	95	Basso
135	210	98	Alto
145	220	110	Alto
125	190	105	Medio

Tabella frequenze assolute di Rischio:

Rischio	Frequenza
Basso	1
Medio	1
Alto	2

- La funzione controlla correttamente gli input.
- La variabile **Rischio** viene classificata secondo le regole richieste.
- La lista restituita contiene il dataframe e la tabella delle frequenze.

PARTE 2: Analisi dei Dati

Esercizio 2: Si considerino i dati contenuti nel file `salute.csv`. Si tratta di un dataset composto da dati raccolti su 387 pazienti, in particolare 8 (Eta, BMI, Pressione, Colesterolo, AttivitaFisica, Glicemia, Sesso, Fumatore).

- **Punto 1:** Calcolare media, mediana e deviazione standard della variabile **Pressione**;

Svolgimento:

```
# Carico il dataset
dati <- read.csv("salute.csv", sep = "|")

# Preprocessing: rimuovo le righe con NA
dati <- na.omit(dati)

# Punto 1: media, mediana e deviazione standard di Pressione
media_pressione <- mean(dati$Pressione)
mediana_pressione <- median(dati$Pressione)
sd_pressione <- sd(dati$Pressione)
```

```
# Stampo i risultati
media_pressione
```

```
## [1] 145.7231
```

```
mediana_pressione
```

```
## [1] 146
```

```
sd_pressione
```

```
## [1] 15.89424
```

Risposta

Statistiche descrittive della variabile **Pressione** (dopo rimozione NA):

Statistica	Valore
Media	145.72 mmHg
Mediana	146 mmHg
Deviazione standard	15.89 mmHg


La pressione media dei pazienti è di circa **145.7 mmHg**, con una mediana molto simile (**146 mmHg**), indicando una distribuzione approssimativamente simmetrica. La deviazione standard di **15.89 mmHg** mostra una variabilità moderata intorno alla media.

-
- **Punto 2:** Costruire un boxplot di **Pressione** rispetto a **Fumatore**. Cosa si osserva?

Svolgimento:

```
# Carico il dataset e rimuovo i NA
dati <- read.csv("salute.csv", sep = "|")
dati <- na.omit(dati)

# Boxplot di Pressione rispetto a Fumatore
boxplot(Pressione ~ Fumatore,
        data = dati,
        col = c("lightblue", "salmon"),
        main = "Pressione per Fumatore",
        xlab = "Fumatore",
        ylab = "Pressione (mmHg)")
```



Risposta

Osservazioni:

- I **fumatori** (Si) presentano una **pressione mediana più alta** rispetto ai non fumatori (No).
- La **variabilità** (larghezza dei box) è simile tra i due gruppi.
- Nel gruppo dei **non fumatori** è presente un **outlier** (un punto oltre il baffo superiore), indicando un individuo che non fuma ma ha pressione molto alta.
- Nel gruppo dei **fumatori** non si osservano outlier evidenti.

Conclusione: I fumatori tendono ad avere pressione più alta rispetto ai non fumatori. La presenza di un outlier nel gruppo dei non fumatori suggerisce che alcuni individui si discostano dal comportamento medio.

-
- **Punto 3:** Calcolare la matrice di correlazione tra le variabili quantitative. Quale coppia presenta la correlazione più alta?

Svolgimento:

```

# Carico il dataset e rimuovo i NA
dati <- read.csv("salute.csv", sep = "|")
dati <- na.omit(dati)

# Seleziono le variabili quantitative
dati_quant <- dati[, c("Eta", "BMI", "AttivitaFisica", "Pressione", "Colesterolo", "Glicemia")]

# Matrice di correlazione
matrice_cor <- cor(dati_quant)
matrice_cor

```

```

##              Eta              BMI AttivitaFisica  Pressione Colesterolo
## Eta          1.00000000  0.3373496   -0.02054248  0.71496439  0.74683152
## BMI          0.33734957  1.0000000   -0.24547833  0.41897153  0.41502538
## AttivitaFisica -0.02054248 -0.2454783    1.00000000 -0.02562925 -0.06760503
## Pressione     0.71496439  0.4189715   -0.02562925  1.00000000  0.58801152
## Colesterolo   0.74683152  0.4150254   -0.06760503  0.58801152  1.00000000
## Glicemia      0.62621133  0.4375413   -0.30548007  0.48440697  0.49662998
##              Glicemia
## Eta          0.6262113
## BMI          0.4375413
## AttivitaFisica -0.3054801
## Pressione     0.4844070
## Colesterolo   0.4966300
## Glicemia      1.0000000

```

Risposta

Matrice di correlazione tra le variabili quantitative:

	Eta	BMI	AttivitaFisica	Pressione	Colesterolo	Glicemia
Eta	1.0000	0.3373	-0.0205	0.7150	0.7468	0.6262
BMI	0.3373	1.0000	-0.2455	0.4190	0.4150	0.4375
AttivitaFisica	-0.0205	-0.2455	1.0000	-0.0256	-0.0676	-0.3055
Pressione	0.7150	0.4190	-0.0256	1.0000	0.5880	0.4844
Colesterolo	0.7468	0.4150	-0.0676	0.5880	1.0000	0.4966
Glicemia	0.6262	0.4375	-0.3055	0.4844	0.4966	1.0000

La coppia con correlazione più alta è: **Eta** e **Colesterolo** con correlazione = **0.7468**

Osservazioni:

- Eta ha correlazioni positive forti con Colesterolo (0.75), Pressione (0.71) e Glicemia (0.63).
- BMI ha correlazioni moderate con tutte le variabili (0.34-0.44).
- AttivitaFisica ha correlazioni negative con BMI (-0.25) e Glicemia (-0.31).
- Pressione e Colesterolo sono moderatamente correlate (0.59).

-
- **Punto 4:** Calcolare il test χ^2 tra Sesso e Fumatore. Le due variabili risultano associate? Perché?

Svolgimento:

```
# Carico il dataset e rimuovo i NA
dati <- read.csv("salute.csv", sep = "|")
dati <- na.omit(dati)

# Tabella di contingenza Sesso vs Fumatore
tabella <- table(dati$Sesso, dati$Fumatore)

# Test chi-quadrato
test_chi <- chisq.test(tabella)

# Output del test
test_chi
```

```
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  tabella
## X-squared = 0.73957, df = 1, p-value = 0.3898
```

Risposta

Tabella di contingenza:

	Fumatore = No	Fumatore = Si
Sesso = F	104	52
Sesso = M	120	49

Test χ^2 :

- $\chi^2 = 0.7396$
- $df = 1$
- $p\text{-value} = 0.3898$

Conclusione:

Il p-value è **maggiore di 0.05**, quindi **non possiamo rifiutare l'ipotesi di indipendenza** tra Sesso e Fumatore. Le due variabili **non risultano associate** in modo statisticamente significativo: il fatto di essere maschio o femmina non sembra influenzare la probabilità di essere fumatore.

-
- **Punto 5:** Stimare il modello di regressione lineare con variabile di risposta **Pressione** e come regressori Eta, BMI, Fumatore:

Svolgimento:

```

# Carico il dataset e rimuovo i NA
dati <- read.csv("salute.csv", sep = "|")
dati <- na.omit(dati)

# Modello di regressione lineare
modello <- lm(Pressione ~ Eta + BMI + Fumatore, data = dati)

# Output del modello
summary(modello)

##
## Call:
## lm(formula = Pressione ~ Eta + BMI + Fumatore, data = dati)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -29.506  -6.920  -0.167   7.915  26.009
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  92.08326    4.01847   22.915  < 2e-16 ***
## Eta           0.55394    0.03255   17.017  < 2e-16 ***
## BMI           1.10313    0.20244    5.449 1.01e-07 ***
## FumatoreSi    7.10173    1.23024    5.773 1.84e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.23 on 321 degrees of freedom
## Multiple R-squared:  0.5895, Adjusted R-squared:  0.5856
## F-statistic: 153.6 on 3 and 321 DF,  p-value: < 2.2e-16

```

5.1 Quali variabili sono statisticamente significative?

Risposta:

Modello di regressione lineare:

$$\text{Pressione} = 92.08 + 0.55 \cdot \text{Eta} + 1.10 \cdot \text{BMI} + 7.10 \cdot \text{FumatoreSi}$$

Tutte le variabili sono statisticamente significative:

Variabile	p-value	Significatività
Eta	< 2e-16	***
BMI	1.01e-07	***
FumatoreSi	1.84e-08	***

Tutte hanno p-value < **0.001**, quindi contribuiscono in modo significativo a spiegare la variabilità della pressione.

5.2 Interpretare il coefficiente associato a FumatoreSi;

Risposta:

- **Coefficiente stimato:** 7.10
- **Significatività:** p-value = 1.84e-08 (***)

Interpretazione:

A parità di **età** e **BMI**, un paziente **fumatore** ha una pressione **mediamente più alta di 7.10 mmHg** rispetto a un paziente **non fumatore**.

- La categoria di riferimento (baseline) è **Fumatore = No**.
 - Il coefficiente positivo indica che il fumo è associato a un **aumento della pressione**.
 - L'effetto è **statisticamente significativo** (p-value < 0.001).
-

5.3 Calcolare la percentuale di devianza spiegata dal modello;

Risposta:

- **$R^2 = 0.5895$** → il modello spiega il **58.95%** della variabilità di **Pressione**.
 - **R^2 aggiustato = 0.5856** (simile a R^2 , indica che il modello non ha predittori ridondanti).
 - Il modello è **complessivamente significativo** (p-value < 2.2e-16)
-

5.4 La pressione per un paziente fumatore con un'età di 50 anni ed un BMI di 27 prevista dal modello è circa:

- **[F]** 150 mmHg
- **[F]** 170 mmHg
- **[V]** 157 mmHg
- **[F]** 162 mmHg

Svolgimento:

```
# Previsione per un paziente fumatore con Eta=50 e BMI=27
predict(modello, newdata = data.frame(Eta = 50, BMI = 27, Fumatore = "Si"))
```

```
##          1
## 156.6665
```

Risposta:

Verifica delle affermazioni:

- a.: “150 mmHg”* → **FALSA**. Sottostima di circa 6.7 mmHg.
- b.: “170 mmHg”* → **FALSA**. Sovrastima di circa 13.3 mmHg.
- c.: “157 mmHg”* → **VERA**. Il peso previsto è **156.67 mmHg**, che arrotondato è 157 mmHg.
- d.: “162 mmHg”* → **FALSA**. Sovrastima di circa 5.3 mmHg.

Calcolo:

$$\text{Pressione} = 92.08 + 0.55 \times 50 + 1.10 \times 27 + 7.10 \times \text{FumatoreSi} = \mathbf{156.67 \text{ mmHg}}$$

Risposta corretta: c. 157 mmHg

5.5 Stimare il modello che ha la stessa variabile di risposta ma come predittore e l'interazione tra BMI e Fumatore; possiamo dire che l'effetto del BMI sulla pressione cambia tra fumatori e non fumatori? Perché?

Svolgimento:

```
# Carico il dataset e rimuovo i NA
dati <- read.csv("salute.csv", sep = "|")
dati <- na.omit(dati)

# Modello con interazione tra BMI e Fumatore
modello_int <- lm(Pressione ~ BMI * Fumatore, data = dati)

# Output del modello
summary(modello_int)
```

```
##
## Call:
## lm(formula = Pressione ~ BMI * Fumatore, data = dati)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -32.152 -10.375  -0.653   9.578  39.354
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    99.0550     6.9126  14.330  < 2e-16 ***
## BMI             2.1511     0.3303   6.512 2.87e-10 ***
## FumatoreSi      0.7848    11.3561   0.069   0.945
## BMI:FumatoreSi  0.3104     0.5449   0.570   0.569
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## Residual standard error: 14.1 on 321 degrees of freedom
## Multiple R-squared:  0.2199, Adjusted R-squared:  0.2126
## F-statistic: 30.16 on 3 and 321 DF,  p-value: < 2.2e-16
```

Risposta

Modello con interazione tra BMI e Fumatore:

$$\text{Pressione} = 99.06 + 2.15 \cdot \text{BMI} + 0.78 \cdot \text{FumatoreSi} + 0.31 \cdot (\text{BMI} \times \text{FumatoreSi})$$

Interpretazione del termine di interazione:

- Il coefficiente di BMI:FumatoreSi è **0.3104** con p-value = **0.569**.
- Poiché il p-value è **maggiore di 0.05**, il termine di interazione **non è statisticamente significativo**.

Conclusione:

Non possiamo dire che l'effetto del BMI sulla pressione cambi tra fumatori e non fumatori. L'effetto del BMI è simile nei due gruppi.

Confronto con il modello precedente:

Modello	R ²
Senza interazione (Eta + BMI + Fumatore)	0.5895
Con interazione (BMI * Fumatore)	0.2199

Il modello senza interazione spiega molta più variabilità perché include anche l'**età**, che è il predittore più importante per la pressione.

5.6 Quale delle seguenti affermazioni è corretta?

- [V] Il termine BMI:FumatoreSi indica se l'effetto del BMI sulla pressione è diverso tra fumatori e non
- [F] Il termine BMI:FumatoreSi elimina l'effetto principale del BMI
- [F] Il termine BMI:FumatoreSi rappresenta la media del BMI nei fumatori
- [F] Il termine BMI:FumatoreSi indica la correlazione tra BMI e fumo

Risposta

Verifica delle affermazioni:

- **a.:** “Il termine BMI:FumatoreSi indica se l'effetto del BMI sulla pressione è diverso tra fumatori e non” → **VERA**. Il termine di interazione misura proprio se la relazione tra BMI e pressione cambia a seconda del fatto che il paziente sia fumatore o meno.

- **b.:** “Il termine *BMI:FumatoreSi* elimina l’effetto principale del BMI” → **FALSA**. Il termine di interazione si aggiunge all’effetto principale, non lo elimina. L’effetto principale del BMI rimane nel modello (coefficiente 2.15).
- **c.:** “Il termine *BMI:FumatoreSi* rappresenta la media del BMI nei fumatori” → **FALSA**. Il termine di interazione è un prodotto tra due variabili, non una media. La media del BMI nei fumatori si calcola con `mean()`.
- **d.:** “Il termine *BMI:FumatoreSi* indica la correlazione tra BMI e fumo” → **FALSA**. La correlazione tra BMI e fumo si calcola con `cor()`. Il termine di interazione misura l’effetto differenziale del BMI sulla pressione tra fumatori e non fumatori.

Risposta corretta: a.

- **Punto 6:** Standardizzare le variabili quantitative del dataset e salvarle in un oggetto `DataScaled`;

Svolgimento:

```
# Standardizzo le variabili quantitative
dati <- read.csv("salute.csv", sep="|")
dati <- na.omit(dati)

# Selezione le variabili quantitative (escludo Sesso e Fumatore)
variabili_quant <- dati[, c("Eta", "BMI", "AttivitaFisica", "Pressione", "Colesterolo", "Glicemia")]

# Standardizzo (media 0, varianza 1)
DataScaled <- scale(variabili_quant)

# Mostro le prime righe per verifica
head(DataScaled)
```

```
##          Eta          BMI AttivitaFisica Pressione Colesterolo  Glicemia
## 1 -0.2007159 -0.96227945      0.2801753 -0.1713248  1.65436024 -0.65047908
## 2  0.8775099  1.14902271      1.4297638  0.6465817 -0.02222216 -0.02075997
## 3 -1.1172078  1.24956091     -0.1509203 -0.4859042  0.06375643 -0.11071984
## 5  0.3923083 -0.32553753      0.1364768 -0.8004836  0.14973501 -0.11071984
## 6  0.8235986 -0.05743567     -0.2467194  0.2061705  1.18147803  0.42903939
## 7  0.4462196  0.21066619     -0.1509203  1.0869929  0.83756369  0.60895914
```

Risposta

Le variabili quantitative sono state standardizzate utilizzando la funzione `scale()`, che sottrae la media e divide per la deviazione standard di ciascuna variabile.

Le prime righe del dataset standardizzato (`DataScaled`):

	Eta	BMI	AttivitaFisica	Pressione	Colesterolo	Glicemia
1	-0.201	-0.962	0.280	-0.171	1.654	-0.650

	Eta	BMI	AttivitaFisica	Pressione	Colesterolo	Glicemia
2	0.878	1.149	1.430	0.647	-0.022	-0.021
3	-1.117	1.250	-0.151	-0.486	0.064	-0.111
5	0.392	-0.326	0.136	-0.800	0.150	-0.111
6	0.824	-0.057	-0.247	0.206	1.181	0.429
7	0.446	0.211	-0.151	1.087	0.838	0.609

- **Punto 7:** Applicare clustering gerarchico a `DataScaled` utilizzando il metodo di Ward:

Svolgimento:

```
# Carico il dataset e rimuovo i NA
dati <- read.csv("salute.csv", sep = "|")
dati <- na.omit(dati)

# Seleziono le variabili quantitative
dati_quant <- dati[, c("Eta", "BMI", "AttivitaFisica", "Pressione", "Colesterolo", "Glicemia")]

# Standardizzo
DataScaled <- scale(dati_quant)


# Clustering gerarchico con Ward
distanze <- dist(DataScaled, method = "euclidean")
hcluster <- hclust(distanze, method = "ward.D2")
```

7.1 Rappresentare il dendrogramma;

Svolgimento:

```
# Dendrogramma
plot(hcluster, labels = FALSE, main = "Dendrogramma - Metodo di Ward",
     xlab = "", sub = "", ylab = "Distanza")
```

Dendrogramma – Metodo di Ward



Risposta:

Osservazioni:


- Si osserva un **salto considerevole** nell'altezza di fusione intorno a **25-30**, il che suggerisce che i cluster uniti a quel livello sono molto diversi tra loro.
- Le prime fusioni avvengono a bassa altezza, indicando che le osservazioni all'interno dei cluster sono molto simili.
- La struttura del dendrogramma suggerisce che una soluzione con **2 cluster** potrebbe essere appropriata, ma per una scelta più precisa si può osservare il plot delle altezze.

7.2 Costruire il plot delle altezze e, rispetto a tale grafico, scegliere un numero appropriato di cluster e motivarne il perché;

Svolgimento:

```
# Plot delle altezze di fusione in ordine decrescente
plot(sort(hcluster$height, decreasing = TRUE), type = "b",
     main = "Altezze di fusione",
     xlab = "Numero di cluster (passo di fusione)",
     ylab = "Altezza")
```

Altezze di fusione



Risposta:

Osservazioni:

- L'altezza di fusione è molto bassa per i primi ~250 passi (distanze tra le osservazioni simili).
- Si osserva un **salto considerevole** intorno a $h = 25$ (dopo circa 250 passi), dove le altezze aumentano bruscamente.
- Questo indica che i cluster uniti a quel livello sono molto diversi tra loro.

Scelta del numero di cluster:

- Il salto brusco intorno a $h = 25$ suggerisce che il numero ottimale di cluster sia **2**.
- Tagliando il dendrogramma a un'altezza di circa 25, si ottengono **2 cluster** ben separati.
- Oltre questo punto, le fusioni avvengono a distanze molto maggiori, indicando che gli oggetti uniti sono troppo dissimili.

Motivazione: il criterio del “salto” (o “elbow”) nel plot delle altezze indica il punto in cui la dissimilarità tra i cluster aumenta drasticamente, suggerendo di fermarsi prima di quel salto.

7.3 Riportare la numerosità di ciascun gruppo ottenuto;

Svolgimento:

```
# Taglio l'albero per ottenere 2 cluster
cluster <- cutree(hcluster, k = 2)

# Numerosità di ciascun cluster
table(cluster)
```

```
## cluster
##    1    2
## 151 174
```

Risposta:

Numerosità dei cluster (taglio a $k = 2$, altezza 25):

Cluster	Frequenza
1	151
2	174

I due cluster hanno numerosità simili: **151** osservazioni nel cluster 1 e **174** nel cluster 2. La suddivisione è bilanciata.

7.4 Descrivere brevemente le caratteristiche dei cluster ottenuti considerando le medie delle variabili quantitative.

Svolgimento:

```
# Aggiungo i cluster al dataset
dati$cluster <- cluster

# Medie delle variabili quantitative per cluster
aggregate(cbind(Eta, BMI, AttivitaFisica, Pressione, Colesterolo, Glicemia) ~ cluster,
           data = dati, FUN = mean)
```

```
##   cluster      Eta      BMI AttivitaFisica Pressione Colesterolo  Glicemia
## 1      1 67.34437 21.85894      5.262914  156.6424    234.2053 107.00662
## 2      2 38.16667 19.64080      4.986782  136.2471    199.2989  94.35057
```

Risposta

Caratteristiche dei cluster (medie delle variabili quantitative):

Cluster	Eta (anni)	BMI	AttivitaFisica	Pressione (mmHg)	Colesterolo (mg/dL)	Glicemia (mg/dL)
1	67.34	21.86	5.26	156.64	234.21	107.01
2	38.17	19.64	4.99	136.25	199.30	94.35

Descrizione:

- **Cluster 1** (151 osservazioni): persone **più anziane** (età media 67 anni), con pressione, colesterolo e glicemia **più alti**.
- **Cluster 2** (174 osservazioni): persone **più giovani** (età media 38 anni), con pressione, colesterolo e glicemia **più bassi**.

Conclusione: i due cluster si distinguono principalmente per **età** e **valori clinici**. Il cluster 1 rappresenta pazienti **anziani con valori elevati**, il cluster 2 **giovani con valori migliori**.

-
- **Punto 8:** Applicare PCA alle variabili standardizzate:

Svolgimento:

```
# Carico il dataset e rimuovo i NA
dati <- read.csv("salute.csv", sep = "|")
dati <- na.omit(dati)

# Selezione le variabili quantitative
dati_quant <- dati[, c("Eta", "BMI", "AttivitaFisica", "Pressione", "Colesterolo", "Glicemia")]

# Standardizzo
DataScaled <- scale(dati_quant)

# Applico PCA
pca <- prcomp(DataScaled)

# Sommario della PCA
summary(pca)
```

```
## Importance of components:
##              PC1      PC2      PC3      PC4      PC5      PC6
## Standard deviation  1.7814 1.0698 0.8060 0.66925 0.6402 0.41827
## Proportion of Variance 0.5289 0.1907 0.1083 0.07465 0.0683 0.02916
## Cumulative Proportion 0.5289 0.7196 0.8279 0.90254 0.9708 1.00000
```

8.1 Quanta variabilità viene spiegata dalle prime due componenti?

Risposta:

Variabilità spiegata dalle prime due componenti:

Componente	Varianza spiegata	Varianza cumulata
PC1	52.89%	52.89%
PC2	19.07%	71.96%

Le prime due componenti principali spiegano complessivamente il **71.96%** della variabilità totale dei dati.

- La **PC1** da sola spiega più della metà della variabilità (52.89%).
- La **PC2** aggiunge un ulteriore 19.07%.
- Le restanti 4 componenti spiegano solo il 28.04% residuo.

8.2 Costruire un grafico delle prime due componenti e colorarlo rispetto ai cluster ottenuti in precedenza; i gruppi sembrano ben separati?

Svolgimento:

```
# Carico il dataset e rimuovo i NA
dati <- read.csv("salute.csv", sep = "|")
dati <- na.omit(dati)

# Selezione le variabili quantitative
dati_quant <- dati[, c("Eta", "BMI", "AttivitaFisica", "Pressione", "Colesterolo", "Glicemia")]

# Standardizzo
DataScaled <- scale(dati_quant)


# PCA
pca <- prcomp(DataScaled)

# Riprendo i cluster dal punto 7 (taglio a k=2)
distanze <- dist(DataScaled, method = "euclidean")
hcluster <- hclust(distanze, method = "ward.D2")
cluster <- cutree(hcluster, k = 2)

# Grafico delle prime due componenti colorato per cluster
plot(pca$x[,1], pca$x[,2],
     col = cluster,
     pch = 19,
     xlab = "PC1",
     ylab = "PC2",
     main = "PCA - Prime due componenti per cluster")

# Legenda
legend("topright",
      legend = c("Cluster 1", "Cluster 2"),
      col = 1:2,
      pch = 19,
      title = "Cluster")
```

PCA – Prime due componenti per cluster



Risposta

Grafico delle prime due componenti principali (PC1 vs PC2) colorato per cluster:

- **Asse x:** PC1 (52.89% della varianza)
- **Asse y:** PC2 (19.07% della varianza)
- **Colori:** Cluster 1 (nero) e Cluster 2 (rosso)

Osservazioni:

- I due cluster sono **ben separati** lungo la **PC1** (asse orizzontale).
- Il **Cluster 1** (nero) si trova sul lato **sinistro** della PC1, mentre il **Cluster 2** (rosso) si trova sul lato **destro**.
- La separazione è netta, con pochi punti di sovrapposizione, indicando che i cluster individuati dal clustering gerarchico corrispondono a gruppi distinti anche nello spazio delle componenti principali.
- La **PC2** (asse verticale) mostra una separazione meno marcata, ma contribuisce a distinguere ulteriormente i due gruppi.

Conclusione:

I gruppi ottenuti dal clustering gerarchico sono **ben separati** nello spazio delle prime due componenti principali, confermando che la suddivisione in 2 cluster è appropriata e che i cluster rappresentano gruppi di pazienti con caratteristiche distintive.