

Esercitazione 2

Sara Trabucco

3 Giugno 2026

Nome e cognome:

N. mat.:

Riportare di seguito i comandi e le risposte necessarie allo svolgimento dell'esame. I file pdf e Rmd entrambi vanno consegnati tramite moodle.

1. Accertarsi che il file compili correttamente prima di iniziare l'esame
2. Compilare (e salvare!) spesso
3. Se non si riesce a risolvere l'errore di compilazione, utilizzare l'opzione `eval = F` nelle opzioni del chunk, ad esempio:

```
{r, eval=FALSE}  
summary(dataset)  
plot(x, y)
```

R

Esercizio 1.

Scrivere una funzione che prenda in input tre vettori numerici della stessa lunghezza: **pressione**, **colesterolo** e **glicemia**.

La funzione, denominata `classifica_pazienti()` deve verificare che gli input siano corretti e poi:

- creare una variabile **Rischio** con tre livelli:
 - *Basso* se **pressione** è minore di 130, **colesterolo** è minore di 200 e **glicemia** è minore di 100;
 - *Medio* se almeno una ed al massimo una è fuori da una delle soglie fissate al punto precedente;
 - *Alto* se due condizioni o più sono fuori dalle medesime soglie.
 - restituire una lista composta da un dataframe contenente le variabili originali e la nuova variabile **Rischio** e dalla tabella delle frequenze assolute di **Rischio**
1. Una possibile soluzione la possiamo ottenere sfruttando il fatto che, in R, `TRUE=1` e `FALSE=0` e usando `ifelse()`:

```
classifica_pazienti <- function(pressione, colesterolo, glicemia) {  
  
  # input  
  input <- list(pressione, colesterolo, glicemia)  
  
  num <- sapply(input, is.numeric) # vettore di boolean
```

```

len <- sapply(input, length) # vettore di numeric

if( !(sum(num) == 3) & (len[1] == len[2]) & (len[2] == len[3])) ) {
  stop("errore")
}

# oppure, come suggerito da un vostro collega (soluzione molto elegante):

# if( !(all(num) & all(len == len[1])) ) {
#   stop("errore")
# }

# l'i-esimo elemento vale k se k soglie vengono superate dall'i-esima osservazione
out <- (pressione >= 130) + (colesterolo >= 200) + (glicemia >= 100)

Rischio <- ifelse(
  out == 0, "Basso",
  ifelse(out == 1, "Medio", "Alto")
)

Rischio <- factor(Rischio, levels=c("Basso", "Medio", "Alto"), ordered = T)

data <- data.frame(
  Pressione=pressione,
  Colesterolo=colesterolo,
  Glicemia=glicemia,
  Rischio=Rischio
)

tab <- table(data$Rischio)

return(list(
  data = data,
  frequenze = tab
))
}

```

2. In alternativa, possiamo usare un ciclo for ed effettuare un controllo if per ogni soglia, contando ogni volta che una soglia viene superata; alla fine si decide a che categoria di rischio assegnare all'i-esima osservazione:

```

classifica_pazienti1 <- function(pressione, colesterolo, glicemia) {

  # controllo numeric
  if (!(is.numeric(pressione) & is.numeric(colesterolo) & is.numeric(glicemia))) {
    stop("Devono essere numerici!")
  }

  # controllo lunghezza
  n <- length(pressione)
  if ( !(length(colesterolo) == n & length(glicemia) == n) ) {
    stop("Devono avere la stessa lunghezza!")
  }
}

```

```

# creiamo già il dataframe con Rischio un vettore di character
data <- data.frame(
  Pressione = pressione,
  Colesterolo = colesterolo,
  Glicemia = glicemia,
  Rischio = character(n)
)

# Poi facciamo, per ogni riga, il controllo delle soglie per ciascuna variabile
for (i in 1:n) {

  count <- 0 # sarà il counter per il numero di volte che viene passata una soglia

  if (pressione[i] >= 130) {
    count <- count+1
  }
  if (colesterolo[i] >= 200) {
    count <- count+1
  }
  if (glicemia[i] >= 100) {
    count <- count+1
  }

  if (count == 1) {
    data$Rischio[i] <- "Medio"
    next # usciamo dal ciclo for
  }

  # altrimenti può essere solo alto o basso
  data$Rischio[i] <- ifelse(count > 0, "Alto", "Basso")

}

data$Rischio <- factor(data$Rischio, levels=c("Basso", "Medio", "Alto"), ordered = T)

# calcoliamo le frequenze assolute
tab <- table(data$Rischio)

return(list(
  Data=data,
  Frequenze=tab
))

}

```

Per provare:

```

pressione <- sample(80:150, 20, replace = T)
colesterolo <- sample(100:260, 20, replace = T)
glicemia <- sample(40:150, 20, replace = T)

classifica_pazienti(pressione, colesterolo, glicemia)

```

```
## $data
```

```
##      Pressione Colesterolo Glicemia Rischio
## 1      130      238      44      Alto
## 2      114      160     129     Medio
## 3      102      245     141     Alto
## 4      122      108     140     Medio
## 5      104      164      66     Basso
## 6       80      216     115     Alto
## 7      112      214     119     Alto
## 8      132      105     102     Alto
## 9      106      179      55     Basso
## 10     105      166      44     Basso
## 11      84      211      98     Medio
## 12     135      148      89     Medio
## 13      95      127     108     Medio
## 14     124      137      58     Basso
## 15      90      151     138     Medio
## 16     121      185      69     Basso
## 17     140      247     136     Alto
## 18      85      134     142     Medio
## 19     124      133     113     Medio
## 20     141      114     143     Alto
##
## $frequenze
##
## Basso Medio  Alto
##      5      8      7
```

```
classifica_pazientil(pressione, colesterolo, glicemia)
```

```
## $Data
##      Pressione Colesterolo Glicemia Rischio
## 1      130      238      44      Alto
## 2      114      160     129     Medio
## 3      102      245     141     Alto
## 4      122      108     140     Medio
## 5      104      164      66     Basso
## 6       80      216     115     Alto
## 7      112      214     119     Alto
## 8      132      105     102     Alto
## 9      106      179      55     Basso
## 10     105      166      44     Basso
## 11      84      211      98     Medio
## 12     135      148      89     Medio
## 13      95      127     108     Medio
## 14     124      137      58     Basso
## 15      90      151     138     Medio
## 16     121      185      69     Basso
## 17     140      247     136     Alto
## 18      85      134     142     Medio
## 19     124      133     113     Medio
## 20     141      114     143     Alto
##
## $Frequenze
##
## Basso Medio  Alto
```

```
##      5      8      7
```

Analisi dei Dati

Si considerino i dati contenuti nel file `salute.csv`. Si tratta di un dataset composto da dati raccolti su 387 pazienti, in particolare 8 (Eta, BMI, Pressione, Colesterolo, AttivitaFisica, Glicemia, Sesso, Fumatore).

```
Salute <- read.csv("salute.csv", sep="|") # attenzione al separatore!!
str(Salute)
```

```
## 'data.frame':    387 obs. of  8 variables:
## $ Eta           : int  48 68 31 84 59 67 60 31 42 74 ...
## $ Sesso         : chr  "F" "M" "M" "F" ...
## $ Fumatore      : chr  "Si" "No" "No" "No" ...
## $ BMI           : num  17.8 24.1 24.4 21.3 19.7 20.5 21.3 19 21.1 21.1 ...
## $ AttivitaFisica: num  5.7 8.1 4.8 6 5.4 4.6 4.8 7 4.6 0.9 ...
## $ Pressione     : int  143 156 138 177 133 149 163 147 143 156 ...
## $ Colesterolo   : int  254 215 217 NA 219 243 235 181 198 241 ...
## $ Glicemia      : int  93 100 99 111 99 105 107 84 107 130 ...
```

```
colSums(is.na(Salute))
```

```
##      Eta      Sesso      Fumatore      BMI AttivitaFisica
##      8        8        8          8          8
## Pressione Colesterolo Glicemia
##      8        8        8
```

```
Salute <- na.omit(Salute)
colSums(is.na(Salute))
```

```
##      Eta      Sesso      Fumatore      BMI AttivitaFisica
##      0        0        0          0          0
## Pressione Colesterolo Glicemia
##      0        0        0
```

1. Calcolare media, mediana e deviazione standard della variabile Pressione;

```
mean(Salute$Pressione)
```

```
## [1] 145.7231
```

```
median(Salute$Pressione)
```


```
## [1] 146
```

```
sd(Salute$Pressione)
```

```
## [1] 15.89424
```

2. Costruire un boxplot di Pressione rispetto a Fumatore. Cosa si osserva?

```
boxplot(Pressione ~ Fumatore, data=Salute)
```



La pressione sembra essere più alta per il gruppo dei fumatori rispetto al gruppo dei non fumatori; sembra esserci inoltre un outlier nel gruppo dei non fumatori (una persona che non fuma che tuttavia ha la pressione alta).

3. Calcolare la matrice di correlazione tra le variabili quantitative. Quale coppia presenta la correlazione più alta?

```
numVar <- Salute[sapply(Salute, is.numeric)]; head(numVar)
```

```
##   Eta  BMI AttivitaFisica Pressione Colesterolo Glicemia
## 1  48 17.8             5.7       143         254       93
## 2  68 24.1             8.1       156         215      100
## 3  31 24.4             4.8       138         217       99
## 5  59 19.7             5.4       133         219       99
## 6  67 20.5             4.6       149         243      105
## 7  60 21.3             4.8       163         235      107
```

```
corMatrix <- cor(numVar); corMatrix
```

```
##           Eta           BMI AttivitaFisica  Pressione Colesterolo
## Eta      1.0000000  0.3373496 -0.02054248  0.71496439  0.74683152
## BMI      0.33734957 1.0000000 -0.24547833  0.41897153  0.41502538
## AttivitaFisica -0.02054248 -0.2454783  1.00000000 -0.02562925 -0.06760503
## Pressione  0.71496439  0.4189715 -0.02562925  1.00000000  0.58801152
## Colesterolo  0.74683152  0.4150254 -0.06760503  0.58801152  1.00000000
## Glicemia    0.62621133  0.4375413 -0.30548007  0.48440697  0.49662998
##
##           Glicemia
## Eta      0.6262113
## BMI      0.4375413
## AttivitaFisica -0.3054801
## Pressione  0.4844070
## Colesterolo  0.4966300
```

```
## Glicemia          1.0000000
```

La correlazione maggiore si ha tra Eta e Colesterolo (con $\rho = 0.7468$).

4. Calcolare il test χ^2 tra Sesso e Fumatore. Le due variabili risultano associate? Perché?

```
chisq.test(Salute$Sesso, Salute$Fumatore)
```

```
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data: Salute$Sesso and Salute$Fumatore
## X-squared = 0.73957, df = 1, p-value = 0.3898
```

Essendo il p -value superiore alle soglie considerate di solito, non sembra esserci evidenza per rifiutare l'ipotesi nulla (ossia che le due variabili sono indipendenti). Non sembrano quindi essere associate.

5. Stimare il modello di regressione lineare con variabile di risposta Pressione e come regressori Eta, BMI, Fumatore:

```
modello <- lm(Pressione ~ Eta + BMI + Fumatore, data=Salute)
```

5.1 Quali variabili sono statisticamente significative?

```
summary(modello)
```

```
##
## Call:
## lm(formula = Pressione ~ Eta + BMI + Fumatore, data = Salute)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -29.506  -6.920  -0.167   7.915  26.009
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  92.08326    4.01847   22.915 < 2e-16 ***
## Eta           0.55394    0.03255   17.017 < 2e-16 ***
## BMI           1.10313    0.20244    5.449 1.01e-07 ***
## FumatoreSi    7.10173    1.23024    5.773 1.84e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.23 on 321 degrees of freedom
## Multiple R-squared:  0.5895, Adjusted R-squared:  0.5856
## F-statistic: 153.6 on 3 and 321 DF,  p-value: < 2.2e-16
```

Guardando ai t-test, possiamo vedere come in tutti i casi il p -value fosse molto piccolo, indicando quindi che tali variabili sembrano essere statisticamente significative per spiegare Pressione.

5.2 Interpretare il coefficiente associato a FumatoreSi;

A parità di BMI e Eta, essendo Fumatore una variabile categoriale, il coefficiente angolare di FumatoreSi indica, in questo caso, un aumento di ~ 7.1 mmHg nella Pressione rispetto ad un non fumatore (che è la baseline).

5.3 Calcolare la percentuale di devianza spiegata dal modello;

```
summary(modello)$r.squared*100
```

```
## [1] 58.94571
```

Il modello sembra spiegare il 59% circa della variabilità di **Pressione**.

5.4 La pressione per un paziente fumatore con un'età di 50 anni ed un BMI di 27 prevista dal modello è circa:

- ☐ 150 mmHg
- ☐ 170 mmHg
- ☒ 157 mmHg
- ☐ 162 mmHg

```
predict(modello, newdata = data.frame(BMI=27,
                                       Eta=50,
                                       Fumatore="Si"))
```

```
##          1
## 156.6665
```

5.5 Stimare il modello che ha la stessa variabile di risposta ma come predittore e l'interazione tra BMI e Fumatore; possiamo dire che l'effetto del BMI sulla pressione cambia tra fumatori e non fumatori? Perché?


```
modello_int <- lm(Pressione ~ BMI * Fumatore, data=Salute)
summary(modello_int)
```

```
##
## Call:
## lm(formula = Pressione ~ BMI * Fumatore, data = Salute)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -32.152 -10.375  -0.653   9.578  39.354
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   99.0550     6.9126  14.330 < 2e-16 ***
## BMI           2.1511     0.3303   6.512 2.87e-10 ***
## FumatoreSi     0.7848    11.3561   0.069  0.945
## BMI:FumatoreSi 0.3104     0.5449   0.570  0.569
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 14.1 on 321 degrees of freedom
## Multiple R-squared:  0.2199, Adjusted R-squared:  0.2126
## F-statistic: 30.16 on 3 and 321 DF, p-value: < 2.2e-16
```

Possiamo vedere dal `summary(modello_int)` che l'effetto del BMI sulla pressione non sembra cambiare tra fumatori e non fumatori (il termine `BMI:FumatoreSi` non sembra essere statisticamente rilevante); possiamo anche osservare che se ricaviamo due modelli `Pressione ~ BMI` per appartenenza ad una delle due categorie, le due rette sembrano essere praticamente parallele:

```
mod_si <- lm(Pressione ~ BMI, data=subset(Salute, Fumatore == "Si"))
mod_no <- lm(Pressione ~ BMI, data=subset(Salute, Fumatore == "No"))
```

```
plot(Salute$BMI,
     Salute$Pressione)
abline(mod_si, col="red")
abline(mod_no, col="green")
```



5.6 Quale delle seguenti affermazioni è corretta?

- ☒ il termine `BMI:FumatoreSi` indica se l'effetto del BMI sulla pressione è diverso tra fumatori e non
- ☐ il termine `BMI:FumatoreSi` elimina l'effetto principale del BMI
- ☐ il termine `BMI:FumatoreSi` rappresenta la media del BMI nei fumatori
- ☐ il termine `BMI:FumatoreSi` indica la correlazione tra BMI e fumo

6. Standardizzare le variabili quantitative del dataset e salvarle in un oggetto `DataScaled`;

```
DataScaled <- scale(numVar); head(DataScaled)
```

```
##          Eta          BMI AttivitaFisica  Pressione Colesterolo   Glicemia
## 1 -0.2007159 -0.96227945    0.2801753 -0.1713248  1.65436024 -0.65047908
## 2  0.8775099  1.14902271    1.4297638  0.6465817 -0.02222216 -0.02075997
## 3 -1.1172078  1.24956091   -0.1509203 -0.4859042  0.06375643 -0.11071984
## 5  0.3923083 -0.32553753    0.1364768 -0.8004836  0.14973501 -0.11071984
## 6  0.8235986 -0.05743567   -0.2467194  0.2061705  1.18147803  0.42903939
## 7  0.4462196  0.21066619   -0.1509203  1.0869929  0.83756369  0.60895914
```

7. Applicare clustering gerarchico a `DataScaled` utilizzando il metodo di Ward:


```
eu_dist <- dist(DataScaled, method="euclidean")
hcluster <- hclust(eu_dist, method="ward.D2")
hcluster
```

```
##
## Call:
## hclust(d = eu_dist, method = "ward.D2")
##
## Cluster method   : ward.D2
## Distance         : euclidean
## Number of objects: 325
```

```
# oppure
# library(cluster)
#
# hcluster <- agnes(DataScaled, method = "ward")
# hcluster
```


7.1 Rappresentare il dendrogramma;

```
plot(hcluster, labels = FALSE)
```



7.2 Costruire il plot delle altezze e, rispetto a tale grafico, scegliere un numero appropriato di cluster e motivarne il perché;


```
plot(sort(hcluster$height, decreasing = T), type="b")
```



In questo caso si ha un salto considerevole intorno a 25 che indica che, a quel punto, sono stati uniti cluster molto diversi tra loro. Per questo motivo è conveniente tagliare l'albero ad $h \approx 25$:

```
plot(hcluster, labels=FALSE)
rect.hclust(hcluster, h=25, border=c(2,3))
```

Cluster Dendrogram



7.3 Riportare la numerosità di ciascun gruppo ottenuto;

```
hc <- cutree(hcluster, h=25) # o k=2
table(hc)
```

```
## hc
##   1   2
## 151 174
```

7.4 Descrivere brevemente le caratteristiche dei cluster ottenuti considerando le medie delle variabili quantitative.

```
aggregate(numVar, by = list(Cluster = hc), mean)
```

```
##   Cluster      Eta      BMI AttivitaFisica Pressione Colesterolo  Glicemia
## 1      1 67.34437 21.85894      5.262914  156.6424    234.2053 107.00662
## 2      2 38.16667 19.64080      4.986782  136.2471    199.2989  94.35057
```

Il cluster 1 sembra essere composto da persone più vecchie con pressione, colesterolo e glicemia più alti, a differenza del cluster 2 composto da persone più giovani e con pressione, colesterolo e glicemia più bassi.

8. Applicare PCA alle variabili standardizzate:

```
pca <- prcomp(DataScaled)
```

```
# oppure
# pca <- princomp(DataScaled)
```

8.1 Quanta variabilità viene spiegata dalle prime due componenti?

```
summary(pca)
```

```
## Importance of components:
##              PC1      PC2      PC3      PC4      PC5      PC6
## Standard deviation      1.7814 1.0698 0.8060 0.66925 0.6402 0.41827
## Proportion of Variance 0.5289 0.1907 0.1083 0.07465 0.0683 0.02916
## Cumulative Proportion 0.5289 0.7196 0.8279 0.90254 0.9708 1.00000
```

```
# si guarda alla colonna riferita al numero di componenti (2 in questo caso) sulla riga di Cumulative P
# oppure
# summary(pca)$importance[3,2]
```

Viene spiegato il circa 72% della variabilità.

8.2 Costruire un grafico delle prime due componenti e colorarlo rispetto ai cluster ottenuti in precedenza; i gruppi sembrano ben separati?

```
plot(pca$x[,1],
     pca$x[,2],
     col = hc)
```

